

# *Probabilités et statistique*

## **Analyse de la variance**

### **Module 12**

*Édition 2025 © Université Joseph KI-ZERBO*



# Plan

- Introduction
- Comparaison de plusieurs moyennes
- Modèle
- Table d'analyse de la variance
- Validation du modèle

# 1. Introduction

L'analyse de variance permet de comparer simultanément les moyennes d'une variable dans plusieurs populations, en général normales et de même variance.

## ***Exemples :***

Un informaticien a 7 modèles d'ordinateurs qu'il désire comparer du point de vue de la performance.

Un médecin dispose de 3 médicaments servant à guérir une maladie. Il désire savoir s'ils sont équivalents ou si l'un d'entre eux guérit plus rapidement que les autres.

Un directeur de magasin d'appareils électroniques est intéressé à comparer 4 méthodes de publicité. Il veut savoir si ces méthodes sont équivalentes ou si l'une d'elles amène plus de clients que les autres.

## 2. Comparaison de plusieurs moyennes

a)  $Y_i \sim N(\mu_i, \sigma^2)$  avec  $i = 1, 2, \dots, a$

On suppose  $a$  populations indépendantes.

Prenons  $a$  échantillons de même taille (cas balancé), un pour chaque population à l'étude :

Population 1 :  $(y_{11}, y_{12}, \dots, y_{1n})$

Population 2 :  $(y_{21}, y_{22}, \dots, y_{2n})$

...

Population  $a$  :  $(y_{a1}, y_{a2}, \dots, y_{an})$

Voici la moyenne des observations pour le traitement  $i$  et la moyenne générale de toutes les observations :

$$y_{i.} = \sum_{j=1}^n y_{ij} \Rightarrow \bar{y}_{i.} = y_{i.} / n$$

$$y_{..} = \sum_{i=1}^a \sum_{j=1}^n y_{ij} \Rightarrow \bar{y}_{..} = y_{..} / N$$

b) Hypothèses

Soit  $H_0 : \mu_1 = \mu_2 = \dots = \mu_a$  vs  $H_1 : \text{Au moins deux des moyennes } \mu_i \text{ ne sont pas égales.}$

**Exemple :**

On veut comparer 5 modèles de voitures par rapport à leur consommation d'essence.

Sont-elles équivalentes ? Laquelle est meilleure ?

|   | Marque     | 1  | 2  | 3  | 4  |
|---|------------|----|----|----|----|
| A | Chrysler   | 22 | 23 | 22 | 21 |
| B | Volkswagen | 23 | 26 | 25 | 22 |
| C | Toyota     | 26 | 28 | 27 | 31 |
| D | Honda      | 25 | 23 | 20 | 24 |
| E | BMW        | 23 | 27 | 22 | 20 |

c) Vocabulaire :

Soit  $Y$ , la variable réponse

*Exemple* : la consommation d'essence

Facteur : Ce qui différencie les populations ou les traitements

*Exemple* : le modèle ou la marque

Unité expérimentale : Individu ou objet sur lequel la variable réponse est mesurée.

*Exemple* : automobile

Plan d'expérience : Procédure permettant d'attribuer les traitements aux unités expérimentales.

#### d) Notation

Soit  $y_{ij}$  :  $j^{\text{e}}$  observation du  $i^{\text{e}}$  traitement

*Exemple* (à partir de la diapositive 5) :  $y_{21} = 23$  ,  $y_{34} = 31$  etc ...

Exemple :

$$y_{3\bullet} = 26 + 28 + 27 + 31 = 112 \quad \Rightarrow \quad \bar{y}_3 = \frac{y_{3\bullet}}{4} = \frac{112}{4} = 28$$

Nombre total d'observations :  $N = \sum_{i=1}^a n = an$

Variabilité totale : 
$$SCT = \sum_{i=1}^a \sum_{j=1}^n (y_{ij} - \bar{y}_{..})^2$$

### 3. Modèle

Soit le modèle suivant :

$$Y_{ij} = \mu + \tau_i + \varepsilon_{ij}$$

où  $y_{ij}$  :  $j^{\text{ème}}$  observation prise lors du traitement  $i$

$\mu$  : paramètre commun à tous les traitements, appelé moyenne générale

$\tau_i$  : paramètre associé au  $i^{\text{ème}}$  traitement

$\varepsilon_{ij}$  : composante (erreur) aléatoire

Ainsi,  $Y_{ij} \sim N(\mu + \tau_i, \sigma^2)$ ,  $i = 1, 2, \dots, a$ ,  $j = 1, 2, \dots, n$ .

Contrainte *pour le cas balancé*:  $\sum_{i=1}^a \tau_i = 0$



**Exemple :**

Soit 3 populations (toutes de loi Normale) :  $N(\mu_1, \sigma^2)$ ,  $N(\mu_2, \sigma^2)$ ,  $N(\mu_3, \sigma^2)$ .

$$n_1 = n_2 = n_3 = 6$$

$$Y_{1j} \sim N(7, \sigma^2)$$

$$Y_{2j} \sim N(12, \sigma^2)$$

$$Y_{3j} \sim N(5, \sigma^2) \quad j = 1, 2, \dots, 6$$

$$Y_{ij} = \mu + \tau_i + \varepsilon_{ij} \quad i = 1, 2, 3$$

$$\mu = \frac{7 + 12 + 5}{3} = 8$$

$$\tau_1 = 7 - 8 = -1$$

$$\tau_2 = 12 - 8 = 4$$

$$\tau_3 = 5 - 8 = -3$$

$$\sum_{i=1}^3 \tau_i = -1 + 4 - 3 = 0 \Rightarrow \text{contrainte pour le cas balancé}$$

Hypothèse nulle :

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_a \Leftrightarrow H_0 : \tau_1 = \tau_2 = \dots = \tau_a$$

Partition de la somme des carrés :

$$\sum_{i=1}^a \sum_{j=1}^n (y_{ij} - \bar{y}_{..})^2 = \underbrace{\sum_{i=1}^a n(\bar{y}_{i.} - \bar{y}_{..})^2}_{\text{Variation de Y expliquée par les traitements (modèle)}} + \underbrace{\sum_{i=1}^a \sum_{j=1}^n (y_{ij} - \bar{y}_{i.})^2}_{\text{Variation de Y inexpliquée par les traitements}}$$

Variation totale de Y

$$\text{SCT} = \text{SCM} + \text{SCE}$$

SCT : Somme des carrés totale

SCM : Somme des carrés due au modèle

SCE : Somme des carrés des erreurs

## 4. Table d'analyse de la variance (ANOVA)

| Source de variation | Somme des carrés | Degrés de liberté | Carrés moyens     | F <sub>observé</sub> |
|---------------------|------------------|-------------------|-------------------|----------------------|
| Modèle              | SCM              | a – 1             | MCM = SCM/(a – 1) | MCM/MCE              |
| Erreur              | SCE              | N – a             | MCE = SCE/(N – a) |                      |
| Totale              | SCT              | N – 1             |                   |                      |

Sous  $H_0$ , nous avons :

$$F = \frac{MCM}{MCE} = \frac{SCM / (a - 1)}{SCE / (N - a)} \sim F_{a-1, N-a}$$

**Exemple :**

| Marque | 1  | 2  | 3  | 4  | $n$ | $\bar{y}_{i\bullet}$ | $n(\bar{y}_{i\bullet} - \bar{y}_{\bullet\bullet})^2$ | $\sum_{j=1}^n y_{ij}^2$ | $\sum_{j=1}^n (y_{ij} - \bar{y}_{i\bullet})^2$ |
|--------|----|----|----|----|-----|----------------------|------------------------------------------------------|-------------------------|------------------------------------------------|
| A      | 22 | 23 | 22 | 21 | 4   | 22                   | 16                                                   | 1938                    | 2                                              |
| B      | 23 | 26 | 25 | 22 | 4   | 24                   | 0                                                    | 2314                    | 10                                             |
| C      | 26 | 28 | 27 | 31 | 4   | 28                   | 64                                                   | 3150                    | 14                                             |
| D      | 25 | 23 | 20 | 24 | 4   | 23                   | 4                                                    | 2130                    | 14                                             |
| E      | 23 | 27 | 22 | 20 | 4   | 23                   | 4                                                    | 2142                    | 26                                             |
| Total  |    |    |    |    | 20  |                      | <b>88</b>                                            | 11674                   | <b>66</b>                                      |

Regardons maintenant la diapositive suivante pour quelques détails sur ce tableau.

$$N = \sum_{i=1}^5 n = 20$$

$$\bar{y}_{..} = \sum_{i=1}^5 \sum_{j=1}^4 y_{ij} / N = 480 / 20 = 24$$

$$SCM = \sum_{i=1}^5 \frac{y_{i.}^2}{n} - \frac{y_{..}^2}{N} = 88$$

$$SCT = \sum_{i=1}^5 \sum_{j=1}^4 y_{ij}^2 - \frac{y_{..}^2}{N} = 11674 - 480^2 / 20 = 154$$

$$SCE = SCT - SCM$$

À l'aide des résultats précédents, nous pouvons maintenant établir la table d'ANOVA pour cet exemple (voir la diapositive suivante).

## Table d'ANOVA

| Source de variation | Somme des carrés | Degrés de liberté | Carrés moyens | $F_{\text{observé}}$ |
|---------------------|------------------|-------------------|---------------|----------------------|
| Modèle              | 88               | 4                 | 22            | 5                    |
| Erreur              | 66               | 15                | 4.4           |                      |
| Total               | 154              | 19                |               |                      |

Sous  $H_0 : \tau_1 = \tau_2 = \dots = \tau_a = 0$

$$\frac{SCT}{\sigma^2} \sim \chi_{N-1}^2$$

$$\frac{SCM}{\sigma^2} \sim \chi_{a-1}^2$$

$$\frac{SCE}{\sigma^2} \sim \chi_{N-a}^2$$

Les variables  $\frac{SCM}{\sigma^2}$  et  $\frac{SCE}{\sigma^2}$  étant indépendantes alors

$$F = \frac{SCM/\sigma^2 \times (a-1)}{SCE/\sigma^2 \times (N-a)} = \frac{SCM/(a-1)}{SCE/(N-a)} \sim F_{a-1, N-a}$$

La loi de Fisher est tabulée aux pages 551 à 555 du livre de référence.

$H_0 : \mu_1 = \mu_2 = \dots = \mu_a$  vs  $H_1 : \text{au moins deux des moyennes } \mu_i \text{ ne sont pas égales.}$

$$\text{Sous } H_0 : F_{\text{observé}} = \frac{SCM/(a-1)}{SCE/(N-a)};$$

on rejette  $H_0$  au seuil  $\alpha$  si  $F_{\text{observé}} \geq F_{\alpha, a-1, N-a}$ .

**Exemple :** Consommation d'essence des modèles de voiture

$$\text{Sous } H_0 : F_{\text{observé}} = 5. \quad F_{0.05, 4, 15} = 3.055$$

On rejette donc  $H_0$  au seuil de 5 %, car  $F_{\text{observé}} > F_{0.05, 4, 15}$  ( $5 > 3.055$ ).

Ainsi, les modèles de voiture diffèrent quant à leur consommation d'essence.

## Comparaisons multiples :

On calcule d'abord la plus petite différence significative.

$$PPDS = t_{\alpha/2, N-a} \sqrt{2 \times MCE / n}$$

On ordonne en croissance les moyennes des traitements.

On déclare significativement différentes les moyennes dont l'écart est supérieur à la PPDS.

**Exemple :** La consommation d'essence

Pour  $\alpha = 0.05$ ,  $PPDS = t_{0.025, 15} \sqrt{2 \times 4.4 / 4} = 3.16$

On écrit en ordre croissant les 5 moyennes:

|             |             |             |             |             |
|-------------|-------------|-------------|-------------|-------------|
| $\bar{y}_A$ | $\bar{y}_D$ | $\bar{y}_E$ | $\bar{y}_B$ | $\bar{y}_C$ |
| 22          | 23          | 23          | 24          | 28          |

On déclare significativement différentes les moyennes dont l'écart est supérieur à la PPDS.



On constate que :

$$\mu_A < \mu_C$$

$$\mu_D < \mu_C$$

$$\mu_E < \mu_C$$

$$\mu_B < \mu_C$$

Seule la marque Toyota a une consommation d'essence différente des autres marques d'automobiles.

Ainsi, nous avons les comparaisons multiples suivantes :

|       |    |    |    |       |
|-------|----|----|----|-------|
| A     | D  | E  | B  | C     |
| 22    | 23 | 23 | 24 | 28    |
| <hr/> |    |    |    | <hr/> |

Notons qu'une ligne droite lie les moyennes qui ne sont pas significativement différentes les unes des autres.

## 5. Validation du Modèle

2 hypothèses à vérifier :

- Normalité des erreurs
- Homogénéité des variances

Nous avons le modèle suivant :

$$Y_{ij} = \mu + \tau_i + \varepsilon_{ij} \text{ avec } \varepsilon_{ij} \text{ iid } N(0, \sigma^2)$$

On vérifie ces hypothèses au moyen des résidus.

$$\text{Résidu : } e_{ij} = y_{ij} - \bar{y}_{i.}$$

**Exemple :**


| Marque | 1  | 2  | 3  | 4  | $n$ | $\bar{y}_{i.}$ | $e_{ij}$ |   |    |    |
|--------|----|----|----|----|-----|----------------|----------|---|----|----|
| A      | 22 | 23 | 22 | 21 | 4   | 22             | 0        | 1 | 0  | -1 |
| B      | 23 | 26 | 25 | 22 | 4   | 24             | -1       | 2 | 1  | -2 |
| C      | 26 | 28 | 27 | 31 | 4   | 28             | -2       | 0 | -1 | 3  |
| D      | 25 | 23 | 20 | 24 | 4   | 23             | 2        | 0 | -3 | 1  |
| E      | 23 | 27 | 22 | 20 | 4   | 23             | 0        | 4 | -1 | -3 |

## Vérification de la normalité :

Cette vérification s'effectue par un diagramme en boîte ou par un histogramme des résidus.


Histogramme

|           |    |    |    |   |   |   |   |   |
|-----------|----|----|----|---|---|---|---|---|
| Valeurs   | -3 | -2 | -1 | 0 | 1 | 2 | 3 | 4 |
| Fréquence | 2  | 2  | 4  | 5 | 3 | 2 | 1 | 1 |



Il n'y a pas de problème avec la normalité car la distribution des résidus est assez symétrique et possède un seul maximum.


## Vérification de l'homogénéité des variances




Étant donné que la distribution des points est assez symétrique autour de l'axe des x, on peut conclure qu'il n'y a pas de problème d'homogénéité.

## Cas où il y a hétérogénéité

$$Y_i \sim N(\mu_i, \sigma_i^2) \quad \text{avec } i = 1, 2, \dots, a$$



La variance augmente avec la catégorie  
(tendance)



La variance est inégale

Transformations pour stabiliser la variance lorsque les points représentent une tendance systématique :

$$Y_{ij}^* = \sqrt{Y_{ij}} \quad \text{ou} \quad Y_{ij}^* = \ln(Y_{ij})$$