

Master 1 Informatique
Analyse de Données
Module 1 Introduction à l'analyse de données
Département d'Informatique

Table des matières

1	Qu'est-ce qu'une donnée ?	2
1.1	Définition formelle	2
1.2	Donnée, information, connaissance	2
1.3	Imperfectibilité des données	2
2	Typologie des données	2
2.1	Données quantitatives	2
2.2	Données qualitatives	2
2.3	Données structurées	3
2.4	Données non structurées	3
3	Pipeline d'analyse de données	3
4	Erreurs classiques	3
4.1	Corrélation vs causalité	3
4.2	Absence d'EDA	3
4.3	Problème d'échelle	3
4.4	Biais	4
5	Exercices conceptuels	4
6	Mini-étude de cas	4
6.1	Contexte	4
6.2	Formalisation	5
6.3	Analyse critique	5
7	Conclusion du module	5

1 Quest-ce qu'une donnée ?

1.1 Définition formelle

Une donnée est une représentation codée d'une observation relative à un phénomène.
On note une observation :

$$x \in \mathcal{X}$$

où $\mathcal{X}$ est un espace d'observation.

Un jeu de données multivarié s'écrit :

$$\mathcal{D} = \{(x_i^{(1)}, \dots, x_i^{(p)})\}_{i=1}^n$$

avec :

- n : nombre d'individus
- p : nombre de variables

1.2 Donnée, information, connaissance

- Donnée : observation brute
- Information : donnée contextualisée
- Connaissance : structure extraite par analyse

L'analyse de données vise le passage :

$$\text{Donnée} \rightarrow \text{Information} \rightarrow \text{Connaissance}$$

1.3 Imperfectibilité des données

Aucune donnée réelle n'est :

- complète,
- parfaitement mesurée,
- exempte de biais.

Toute donnée contient du bruit et des erreurs potentielles.

2 Typologie des données

2.1 Données quantitatives

- Discrètes : $\mathbb{N}$
- Continues : $\mathbb{R}$

2.2 Données qualitatives

- Nominale : ensemble fini non ordonné
- Ordinale : ensemble fini ordonné

2.3 Données structurées

Représentation matricielle :

$$X \in \mathbb{R}^{n \times p}$$

2.4 Données non structurées

Exemples :

- Texte
- Image
- Audio

Une image peut être modélisée comme :

$$I \in \mathbb{R}^{h \times w \times c}$$

3 Pipeline d'analyse de données

Un pipeline rigoureux comporte :

1. Formulation de la question
2. Collecte
3. Nettoyage
4. Analyse exploratoire
5. Modélisation
6. Validation
7. Interprétation
8. Communication

Un algorithme optimise une fonction mathématique ; il ne produit pas de sens.

4 Erreurs classiques

4.1 Corrélation vs causalité

$$\text{Corr}(X, Y) \neq X \rightarrow Y$$

4.2 Absence d'EDA

Ne pas explorer les données conduit à des modèles erronés.

4.3 Problème d'échelle

Sans normalisation, certaines méthodes (ex : K-means) deviennent incohérentes.

4.4 Biais

- Biais de sélection
- Biais déchantillonnage
- Variables latentes

5 Exercices conceptuels

Exercice 1

On observe :

ID	Température	Ville	Date
1	39.2	A	01/03
2	36.8	A	01/03
3	40.1	B	01/03

1. Identifier les données brutes.
2. Donner deux informations.
3. Proposer une connaissance possible.
4. Discuter sa validité.

Exercice 2

Classer :

Adresse IP, Niveau d'étude, Connexions, Score (15), Image.

6 Mini-étude de cas

6.1 Contexte

Variables observées :

- Temps de connexion
- Nombre de connexions
- Filière
- Score final
- Messages forum
- Réussite (0/1)

Question : Usage intensif améliore-t-il la réussite ?

6.2 Formalisation

$$\mathcal{D} = \{(t_i, c_i, f_i, s_i, m_i, r_i)\}_{i=1}^n$$

avec :

- $t_i \in \mathbb{R}^+$
- $c_i, m_i \in \mathbb{N}$
- $f_i \in \mathcal{F}$
- $s_i \in [0, 100]$
- $r_i \in \{0, 1\}$

6.3 Analyse critique

Une corrélation positive entre t et s n'implique pas causalité.

Biais possibles :

- Auto-sélection
- Niveau initial non observé
- Effet de filière

Une approche causale nécessiterait randomisation ou variables de contrôle.

7 Conclusion du module

L'analyse de données est :

- une discipline méthodologique,
- une discipline mathématique,
- une discipline critique.

Elle exige rigueur, prudence et interprétation.