

Master 1 Informatique

Analyse de Données

Module 2 Préparation et qualité des données

Département d'Informatique, Université Joseph KI-ZERBO

Table des matières

1	Introduction : pourquoi le prétraitement est central ?	2
2	Données manquantes	2
2.1	Formalisation	2
2.2	Typologie des mécanismes	2
2.3	Méthodes de traitement	3
3	Valeurs aberrantes	3
3.1	Définition	3
3.2	Méthodes classiques	3
3.3	Interprétation	3
4	Normalisation et standardisation	4
4.1	Problème d'échelle	4
4.2	Standardisation (Z-score)	4
4.3	Normalisation Min-Max	4
4.4	Effets sur les méthodes	4
5	Encodage des variables qualitatives	4
5.1	One-hot encoding	4
5.2	Encodage ordinal	4
5.3	Encodage basé sur la cible	5
6	Biais induits par le prétraitement	5
7	Travaux pratiques : Nettoyage d'un jeu de données réel	5
7.1	Objectif	5
7.2	Travail demandé	5
8	Discussion méthodologique	5
9	Conclusion du module	6

1 Introduction : pourquoi le prétraitement est central ?

En pratique, la majorité du temps d'un projet d'analyse de données est consacrée à la préparation des données.

Un modèle sophistiqué appliqué à des données mal préparées produit :

- des estimations biaisées,
- des résultats instables,
- des conclusions scientifiquement invalides.

Le prétraitement n'est pas une étape technique secondaire : il conditionne toute la validité de l'analyse.

2 Données manquantes

2.1 Formalisation

Soit une matrice de données :

$$X \in \mathbb{R}^{n \times p}$$

On définit une matrice indicatrice :

$$R_{ij} = \begin{cases} 1 & \text{si } X_{ij} \text{ est observé} \\ 0 & \text{sinon} \end{cases}$$

Le mécanisme de données manquantes est défini par la loi jointe de (X, R) .

2.2 Typologie des mécanismes

MCAR Missing Completely At Random

$$P(R | X) = P(R)$$

Le mécanisme de manque est indépendant des données observées et non observées.

Conséquence : La suppression complète des lignes ne biaise pas l'estimation (mais augmente la variance).

MAR Missing At Random

$$P(R | X) = P(R | X_{\text{observé}})$$

Le manque dépend des variables observées.

Exemple : les revenus manquent davantage chez les jeunes.

La suppression naïve peut induire un biais.

MNAR Missing Not At Random

$P(R | X)$ dépend des valeurs manquantes elles-mêmes

Exemple : les très hauts revenus ne sont pas déclarés.

Problème : non identifiable sans hypothèse structurelle forte.

2.3 Méthodes de traitement

- Suppression complète (listwise deletion)
- Suppression partielle (pairwise)
- Imputation moyenne/médiane
- Imputation conditionnelle (régression)
- KNN-imputation
- Imputation multiple

Toute imputation modifie la distribution originale.

3 Valeurs aberrantes

3.1 Définition

Une observation x_i est aberrante si sa distance au centre des données est grande :

$$\|x_i - \mu\| \text{ élevée}$$

ou si sa densité locale est faible.

3.2 Méthodes classiques

- Règle des 1.5 IQR
- Z-score : $|z| > 3$
- Distance de Mahalanobis :

$$d_i^2 = (x_i - \mu)^T \Sigma^{-1} (x_i - \mu)$$

- Méthodes de densité (LOF)

3.3 Interprétation

Un outlier peut être :

- une erreur de mesure,
- un cas rare valide,
- le signal le plus intéressant.

La suppression automatique est méthodologiquement dangereuse.

4 Normalisation et standardisation

4.1 Problème d'échelle

Dans les méthodes basées sur la distance :

$$\|x_i - x_j\|^2 = \sum_{k=1}^p (x_{ik} - x_{jk})^2$$

Une variable à grande échelle domine.

4.2 Standardisation (Z-score)

$$X' = \frac{X - \mu}{\sigma}$$

Propriétés :

- Moyenne nulle
- Variance unité

4.3 Normalisation Min-Max

$$X' = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

Ramène dans $[0, 1]$.

4.4 Effets sur les méthodes

La normalisation modifie :

- les distances,
- la structure géométrique,
- la variance expliquée en ACP,
- la hiérarchie des variables.

5 Encodage des variables qualitatives

5.1 One-hot encoding

Une variable à k modalités devient :

$$(x_1, \dots, x_k) \in \{0, 1\}^k$$

Attention à la colinéarité parfaite si toutes les modalités sont incluses.

5.2 Encodage ordinal

Valide uniquement si l'ordre est réel et justifié.

Attribuer arbitrairement des valeurs numériques crée une distance artificielle.

5.3 Encodage basé sur la cible

Remplacer chaque modalité par la moyenne de la variable cible.
Risque majeur : fuite d'information si mal utilisé.

6 Biais induits par le prétraitement

Exemples :

- Supprimer les lignes incomplètes $\Rightarrow$ biais de sélection
- Normaliser avant séparation train/test $\Rightarrow$ fuite d'information
- Supprimer des outliers appartenant à un groupe minoritaire

Le prétraitement modifie la distribution et donc l'inférence.

7 Travaux pratiques : Nettoyage d'un jeu de données réel

7.1 Objectif

Fournir un fichier CSV contenant :

- Valeurs manquantes
- Doublons
- Colonnes mal typées
- Valeurs aberrantes
- Erreurs de format

7.2 Travail demandé

1. Identifier les anomalies.
2. Justifier chaque décision de nettoyage.
3. Produire une version nettoyée reproductible.
4. Comparer statistiques descriptives avant/après.
5. Discuter les effets du nettoyage.

8 Discussion méthodologique

Avant toute modélisation :

- Le mécanisme de données manquantes est-il identifié ?
- Le traitement des outliers est-il justifié ?
- Les transformations ont-elles été faites après séparation train/test ?
- Les décisions sont-elles documentées et reproductibles ?

9 Conclusion du module

La préparation des données est :

- une étape mathématique,
- une étape statistique,
- une étape méthodologique,
- une étape éthique.

Elle conditionne toute validité scientifique ultérieure.