

Master 1 Informatique
Analyse de Données
Module 3 Analyse Exploratoire des Données (EDA) (5h)
Département d'Informatique

Table des matières

1	Introduction : rôle de l'EDA	2
2	Statistiques descriptives avancées	2
2.1	Limites de la moyenne et de la variance	2
2.2	Quantiles et médiane	2
2.3	Intervalle interquartile	2
2.4	Asymétrie (Skewness)	2
2.5	Kurtosis	3
2.6	Matrice de covariance	3
3	Visualisation intelligente	3
3.1	Histogrammes	3
3.2	Boxplots	3
3.3	Scatter plots	4
3.4	Heatmaps de corrélation	4
4	Ce que les graphes disent et ce qu'ils cachent	4
4.1	Exemple : Données d'Anscombe	4
4.2	Illusions visuelles	4
4.3	Causalité illusoire	4
4.4	Densité cachée	5
5	Démarche structurée d'EDA	5
6	Compétences attendues en M1	5
7	Conclusion du module	5
8	Exercices conceptuels Module 3	6
9	Corrigé magistral détaillé	8
10	Extension exploratoire : Analyse en Composantes Principales (ACP)	9
10.1	Motivation	9
10.2	Fondement mathématique	9
10.3	Importance de la standardisation	10

10.4	Implémentation en R	10
10.5	Variance expliquée	10
10.6	Interprétation des composantes	11
10.7	Projection des individus	11
10.8	Biplot	11
10.9	Expérience critique : sans standardisation	11
10.10	Ce que l'ACP montre et ce qu'elle cache	12
10.11	Discussion méthodologique	12
10.12	Lien avec le module suivant	12

1 Introduction : rôle de IEDA

L'Analyse Exploratoire des Données (EDA) est une démarche diagnostique visant à comprendre la structure d'un jeu de données avant toute modélisation.

Objectifs principaux :

- Comprendre les distributions
- Identifier anomalies et incohérences
- Détecter dépendances
- Formuler des hypothèses
- Vérifier la cohérence globale des données

LEDA n'est pas une validation statistique formelle. C'est une phase exploratoire guidant les choix ultérieurs.

2 Statistiques descriptives avancées

2.1 Limites de la moyenne et de la variance

Deux distributions différentes peuvent partager :

$$\mathbb{E}[X] = \mu, \quad \text{Var}(X) = \sigma^2$$

Sans que leurs formes soient similaires.

Les moments d'ordre 1 et 2 sont insuffisants pour décrire complètement une distribution.

2.2 Quantiles et médiane

Le quantile d'ordre α est défini par :

$$Q_\alpha = \inf\{x : F(x) \geq \alpha\}$$

La médiane est $Q_{0.5}$.

Avantage : robustesse face aux valeurs extrêmes.

2.3 Intervalle interquartile

$$IQR = Q_{0.75} - Q_{0.25}$$

Mesure robuste de dispersion.

2.4 Asymétrie (Skewness)

$$\gamma_1 = \frac{\mathbb{E}[(X - \mu)^3]}{\sigma^3}$$

- $\gamma_1 > 0$: asymétrie à droite
- $\gamma_1 < 0$: asymétrie à gauche

2.5 Kurtosis

$$\gamma_2 = \frac{\mathbb{E}[(X - \mu)^4]}{\sigma^4}$$

Indique la concentration dans les queues de distribution.

2.6 Matrice de covariance

$$\Sigma = \mathbb{E}[(X - \mu)(X - \mu)^T]$$

Elle décrit la dépendance linéaire entre variables.

La matrice de corrélation est obtenue par normalisation.

3 Visualisation intelligente

Un graphique doit être :

- adapté au type de variable,
- interprété quantitativement,
- analysé de manière critique.

3.1 Histogrammes

Permettent d'approximer la densité.

Choix crucial : largeur de classe.

Règle de FreedmanDiaconis :

$$h = 2 \frac{IQR}{n^{1/3}}$$

Problème :

- Trop peu de classes : perte d'information
- Trop de classes : bruit artificiel

3.2 Boxplots

Visualisent :

- Médiane
- IQR
- Valeurs extrêmes

Idéal pour comparer plusieurs groupes.

Limite : ne montre pas la forme détaillée de la distribution.

3.3 Scatter plots

Permettent de détecter :

- Corrélations
- Relations non linéaires
- Clusters
- Hétéroscédasticité

Limites :

- Masquage si forte densité
- Dépendances non monotones difficiles à percevoir

3.4 Heatmaps de corrélation

Matrice :

$$R_{ij} = \text{Corr}(X_i, X_j)$$

Permet :

- Détection de colinéarité
- Réduction de redondance

Limite majeure : Ne détecte que la dépendance linéaire.

4 Ce que les graphes disent et ce qu'ils cachent

4.1 Exemple : Données d'Anscombe

Quatre jeux de données peuvent avoir :

- Même moyenne
- Même variance
- Même corrélation
- Formes très différentes

Conclusion : Les statistiques numériques seules sont insuffisantes.

4.2 Illusions visuelles

- Effet d'échelle
- Surestimation visuelle de corrélations
- Détection de patterns inexistantes

4.3 Causalité illusoire

Un nuage linéaire n'implique pas :

$$X \rightarrow Y$$

4.4 Densité cachée

Superposition des points peut masquer :

- Sous-groupes
- Clusters latents

Solutions :

- Transparence
- Jitter
- Hexbin

5 Démarche structurée dEDA

1. Vérifier dimensions et types
2. Résumés robustes
3. Analyse univariée
4. Analyse bivariée
5. Détection anomalies
6. Formulation dhypothèses

6 Compétences attendues en M1

Un étudiant doit :

- Justifier le choix dun graphique
- Interpréter quantitativement
- Identifier les limites
- Refuser toute conclusion causale hâtive

7 Conclusion du module

LEDA est :

- une phase diagnostique,
- une étape de compréhension,
- une démarche critique.

Elle conditionne la validité de toute modélisation ultérieure.

8 Exercices conceptuels Module 3

Exercice 1 Moyenne identique, distribution différente

On considère deux variables X et Y telles que :

$$\mathbb{E}[X] = \mathbb{E}[Y], \quad \text{Var}(X) = \text{Var}(Y)$$

Mais X est unimodale et Y est bimodale.

1. Expliquer pourquoi moyenne et variance ne suffisent pas.
2. Proposer deux indicateurs supplémentaires permettant de distinguer les distributions.
3. Quel graphique serait le plus informatif ?
4. Discuter l'impact potentiel sur une modélisation ultérieure.

Exercice 2 Effet du nombre de classes dans un histogramme

On construit deux histogrammes d'une même variable avec :

- 5 classes
- 40 classes

1. Expliquer les effets possibles.
2. Écrire la règle de Freedman-Diaconis.
3. Pourquoi cette règle dépend-elle de n ?
4. Discuter les limites des histogrammes.

Exercice 3 Corrélation nulle mais dépendance existante

On considère :

$$Y = X^2$$

où X est centrée.

1. Calculer $\text{Corr}(X, Y)$.
2. Expliquer pourquoi elle peut être nulle.
3. Quel graphique révélera la dépendance ?
4. Quelle mesure alternative pourrait détecter cette relation ?

Exercice 4 Heatmap et colinéarité

On observe une matrice de corrélation où :

$$\text{Corr}(X_1, X_2) = 0.95$$

1. Interpréter ce résultat.
2. Quels risques pour une régression ?
3. Quelle décision possible en phase EDA ?
4. Pourquoi la corrélation ne suffit-elle pas toujours ?

Exercice 5 Données d'Anscombe

On sait que quatre jeux de données ont :

- même moyenne,
 - même variance,
 - même corrélation.
1. Pourquoi ces statistiques sont-elles insuffisantes ?
 2. Quel enseignement méthodologique en tirer ?
 3. Relier cet exemple à la notion d'EDA.

9 Corrigé magistral détaillé

Exercice 1

La moyenne et la variance sont des moments d'ordre 1 et 2. Elles ne capturent pas la forme globale.

Indicateurs supplémentaires :

- Asymétrie (skewness)
- Kurtosis
- Quantiles

Le graphique le plus informatif est un histogramme ou une densité estimée.

Impact en modélisation : Une distribution bimodale peut indiquer deux sous-populations, ce qui invalide l'hypothèse d'homogénéité.

Exercice 2

Avec 5 classes :

- Structure lissée
- Perte d'information

Avec 40 classes :

- Apparition de bruit
- Illusion de multimodalité

Règle de Freedman-Diaconis :

$$h = 2 \frac{IQR}{n^{1/3}}$$

Elle dépend de n car la précision de l'estimation augmente avec la taille de l'échantillon.

Limites : Dépendance forte au choix arbitraire du nombre de classes.

Exercice 3

$$\text{Cov}(X, X^2) = \mathbb{E}[X^3] - \mathbb{E}[X]\mathbb{E}[X^2]$$

Si X est symétrique centrée :

$$\mathbb{E}[X^3] = 0$$

Donc :

$$\text{Corr}(X, X^2) = 0$$

Malgré dépendance déterministe.

Le scatter plot révèle une forme en parabole.

Mesure alternative :

- Corrélation de Spearman
- Information mutuelle

Exercice 4

Corrélation 0.95 indique colinéarité forte.

En régression :

- Instabilité des coefficients
- Variance élevée des estimateurs

Décision possible :

- Supprimer une variable
- Réduction de dimension

La corrélation ne détecte pas dépendances non linéaires.

Exercice 5

Les statistiques numériques globales sont insuffisantes.

Enseignement : Toujours visualiser les données.

LEDA permet de détecter :

- Structures cachées
- Outliers influents
- Formes non linéaires

Conclusion : Ne jamais se contenter des résumés numériques.

10 Extension exploratoire : Analyse en Composantes Principales (ACP)

10.1 Motivation

Dans LEDA univariée et bivariée, on analyse les variables une à une ou deux à deux. Lorsque le nombre de variables p augmente, la visualisation directe devient impossible.

L'Analyse en Composantes Principales (ACP) permet :

- de résumer l'information contenue dans p variables,
- de visualiser les individus dans un espace de dimension réduite,
- d'identifier redondances et structures globales,
- d'explorer la géométrie de la matrice de covariance.

LACP est une méthode exploratoire non supervisée.

10.2 Fondement mathématique

Soit $X \in \mathbb{R}^{n \times p}$ une matrice de données centrée.

La matrice de covariance est :

$$\Sigma = \frac{1}{n} X^T X$$

LACP consiste à diagonaliser Σ :

$$\Sigma = PDP^T$$

où :

- P contient les vecteurs propres,
- D est la matrice diagonale des valeurs propres.

Les composantes principales sont les directions de variance maximale.

10.3 Importance de la standardisation

Si les variables sont déchelées différentes, il faut standardiser :

$$X' = \frac{X - \mu}{\sigma}$$

Sans standardisation, la variable de plus grande variance domine la première composante.

10.4 Implémentation en R

```
# Sélection variables numériques
num_data <- data[, c("age", "heures_etude", "score")]

# Standardisation
num_scaled <- scale(num_data)

# ACP
pca <- prcomp(num_scaled, center = FALSE, scale. = FALSE)

summary(pca)
```

10.5 Variance expliquée

La proportion de variance expliquée par la composante k est :

$$\frac{\lambda_k}{\sum_{j=1}^p \lambda_j}$$

```
var_explained <- pca$sdev^2 / sum(pca$sdev^2)
plot(var_explained, type="b",
     main="Variance expliquée",
     xlab="Composante",
     ylab="Proportion variance")
```

Interprétation :

- Forte décroissance : structure dominée par peu de dimensions.
- Décroissance lente : structure plus diffuse.

10.6 Interprétation des composantes

Les charges factorielles sont données par :

```
pca$rotation
```

Chaque composante est une combinaison linéaire :

$$Z_1 = a_1X_1 + a_2X_2 + \cdots + a_pX_p$$

Les coefficients indiquent la contribution relative des variables.

10.7 Projection des individus

```
plot(pca$x[,1], pca$x[,2],  
     col=as.factor(data$filier),  
     pch=19,  
     xlab="PC1",  
     ylab="PC2",  
     main="Projection ACP")
```

Questions d'interprétation :

- Observe-t-on une séparation par filière ?
- Existe-t-il des groupes naturels ?
- Les points extrêmes correspondent-ils aux outliers identifiés ?

10.8 Biplot

```
biplot(pca, scale=0)
```

Interprétation :

- Flèches proches : corrélation positive.
- Flèches opposées : corrélation négative.
- Longueur : contribution à la variance.

10.9 Expérience critique : sans standardisation

```
pca_no_scale <- prcomp(num_data)  
summary(pca_no_scale)
```

Comparer les résultats.

Conclusion attendue :

La variable ayant la plus grande variance domine la première composante.

10.10 Ce que IACP montre et ce quelle cache

Elle montre :

- Les directions principales de variabilité.
- La redondance entre variables.
- Une structure globale éventuelle.

Elle cache :

- Les dépendances non linéaires.
- Les structures locales.
- Les relations causales.

10.11 Discussion méthodologique

LACP est une rotation géométrique. Elle ne prouve pas l'existence de groupes. Elle ne produit pas de causalité. Elle dépend du prétraitement.

Avant d'interpréter une ACP, il faut vérifier :

- Les variables sont-elles comparables ?
- La standardisation est-elle pertinente ?
- Les composantes ont-elles un sens interprétable ?

10.12 Lien avec le module suivant

LACP prépare :

- la réduction de dimension,
- le clustering,
- la détection de structure latente.

Elle constitue une transition naturelle vers le Module 4.

11 Exercices conceptuels Analyse en Composantes Principales

Exercice 1 Maximisation de la variance

Soit $X \in \mathbb{R}^{n \times p}$ une matrice centrée. On cherche une direction $u \in \mathbb{R}^p$ telle que la variance de la projection Xu soit maximale, sous la contrainte $\|u\| = 1$.

1. Écrire la variance de Xu en fonction de Σ .
2. Montrer que le problème revient à maximiser

$$u^T \Sigma u$$

sous contrainte $\|u\| = 1$.

3. Montrer que la solution est le vecteur propre associé à la plus grande valeur propre de Σ .
4. Interpréter géométriquement ce résultat.

Exercice 2 Effet de la standardisation

On considère deux variables :

$$X_1 \in [0, 1], \quad X_2 \in [0, 1000]$$

1. Que se passe-t-il si on applique une ACP sans standardisation ?
2. Quelle matrice diagonalise-t-on dans ce cas ?
3. Pourquoi la première composante est-elle dominée par X_2 ?
4. Discuter dans quels cas la standardisation peut être discutable.

Exercice 3 Corrélation parfaite

Supposons que $X_2 = 3X_1$ exactement.

1. Calculer le rang de la matrice de covariance.
2. Combien de composantes principales non nulles existe-t-il ?
3. Interpréter la géométrie des données.
4. Quel est l'intérêt de l'ACP dans ce cas ?

Exercice 4 Interprétation des charges factorielles

On obtient :

$$Z_1 = 0.7X_1 + 0.7X_2 + 0.1X_3$$

1. Que signifie cette combinaison ?
2. Quelles variables contribuent le plus ?
3. Peut-on donner un sens interprétable à Z_1 ?
4. Quelles précautions faut-il prendre ?

Exercice 5 ACP et causalité

1. LACP permet-elle d'identifier une relation causale ?
2. Peut-elle créer l'illusion d'une structure ?
3. Pourquoi l'ACP est-elle sensible aux outliers ?
4. Relier ces points à la phase d'EDA.

12 Corrigé magistral détaillé ACP

Exercice 1

La variance de la projection est :

$$\text{Var}(Xu) = u^T \Sigma u$$

On maximise sous contrainte $\|u\| = 1$. Par multiplicateurs de Lagrange :

$$\Sigma u = \lambda u$$

Donc u est vecteur propre de Σ .

La direction de variance maximale correspond à la plus grande valeur propre.

Interprétation : LACP choisit l'axe où les données sont le plus dispersées.

Exercice 2

Sans standardisation, on diagonalise la matrice de covariance brute.

Comme $\text{Var}(X_2) \gg \text{Var}(X_1)$, la première composante s'aligne presque sur X_2 .

La standardisation est discutable si l'échelle possède un sens physique réel.

Exercice 3

Si $X_2 = 3X_1$, alors les deux variables sont colinéaires.

La matrice de covariance est de rang 1.

Une seule composante principale non nulle existe.

Géométriquement, les points sont alignés sur une droite.

LACP révèle la dimension intrinsèque.

Exercice 4

La composante Z_1 est une combinaison pondérée.

X_1 et X_2 contribuent fortement, X_3 peu.

On peut interpréter Z_1 comme un facteur commun à X_1 et X_2 .

Précaution : Les coefficients dépendent de l'échelle et du centrage.

Exercice 5

LACP ne permet aucune inférence causale.

Elle peut créer une structure visuelle même si les données sont bruitées.

Elle est sensible aux outliers car la covariance dépend fortement des valeurs extrêmes.

Lien avec EDA : Il faut analyser et nettoyer avant ACP.