

Master 1 Informatique

Analyse de Données

Module 4 Réduction de dimension et structure des données (5h)

Département d'Informatique

Table des matières

1	Motivation mathématique	2
1.1	Redondance linéaire	2
1.2	Structure latente et bruit	2
2	Analyse en Composantes Principales (ACP)	3
2.1	Formulation variationnelle	3
2.2	Interprétation géométrique	3
2.3	Variance expliquée	3
2.4	Interprétation des axes	4
3	Erreurs classiques en ACP	4
4	Limites fondamentales	4
5	Introduction à t-SNE	4
6	Introduction à UMAP	5
7	Comparaison synthétique	6
8	Conclusion	6
9	Contributions et qualité de représentation en ACP	6
9.1	Contributions	6
9.2	Qualité de représentation ($\cos^2$)	7
9.3	Différence fondamentale	8
9.4	Lecture méthodologique d'un plan factoriel	8
9.5	Erreurs fréquentes	8
9.6	Interprétation géométrique	8
9.7	Remarque avancée (niveau M1)	8
10	Exercices conceptuels Contributions et $\cos^2$	9
11	Corrigé magistral détaillé	11

1 Motivation mathématique

Soit une matrice de données :

$$X \in \mathbb{R}^{n \times p}$$

Lorsque p est grand :

- Visualisation impossible
- Instabilité des estimations
- Redondance des variables
- Amplification du bruit

Objectif :

$$f : \mathbb{R}^p \rightarrow \mathbb{R}^k \quad \text{avec } k \ll p$$

préservant la structure pertinente.

1.1 Redondance linéaire

Si :

$$X_2 = aX_1 + \varepsilon$$

alors l'information est essentiellement unidimensionnelle.




FIGURE 1 – Points alignés : dimension intrinsèque 1

1.2 Structure latente et bruit

Modèle :

$$X = S + \varepsilon$$

où S est de rang faible et ε bruit.

La réduction de dimension cherche l'espace engendré par S .

2 Analyse en Composantes Principales (ACP)

2.1 Formulation variationnelle

Soit X_c la matrice centrée :

$$\Sigma = \frac{1}{n} X_c^T X_c$$

On maximise :

$$u^T \Sigma u \quad \text{sous } \|u\| = 1$$

On obtient :

$$\Sigma u = \lambda u$$

La première composante correspond à la plus grande valeur propre.

2.2 Interprétation géométrique

ACP = rotation orthogonale vers axes de variance maximale.




FIGURE 2 – Rotation vers les axes principaux

Projection :

$$Z = X_c P$$

2.3 Variance expliquée

$$\text{Variance expliquée} = \frac{\lambda_k}{\sum_{j=1}^p \lambda_j}$$

Coude marqué faible dimension intrinsèque.




FIGURE 3 – Scree plot variance expliquée

2.4 Interprétation des axes

Chaque composante :

$$Z_1 = a_1X_1 + \dots + a_pX_p$$

Les coefficients (loadings) révèlent :

- Structure commune
- Opposition de variables
- Redondance

3 Erreurs classiques en ACP

- Oublier la standardisation
- Interpréter causalement
- Surinterpréter composantes faibles
- Ignorer les outliers
- Confondre projection 2D et séparation réelle

4 Limites fondamentales

- Méthode linéaire
- Sensible aux échelles
- Sensible aux valeurs extrêmes
- Ne détecte pas structures non linéaires

5 Introduction à t-SNE

t-SNE préserve les voisinages locaux.

Minimise :

$$KL(P||Q)$$




FIGURE 4 – Projection t-SNE

Limites :

- Axes non interprétables
- Sensible aux paramètres
- Structure globale non garantie

6 Introduction à UMAP

UMAP repose sur la géométrie des variétés.




FIGURE 5 – Projection UMAP

Avantages :

- Plus rapide

- Meilleure conservation globale
 - Plus stable que t-SNE
- Mais dépend fortement des paramètres.

7 Comparaison synthétique

Méthode	Linéaire	Interprétable	Locale	Globale
ACP	Oui	Oui	Faible	Forte
t-SNE	Non	Non	Forte	Faible
UMAP	Non	Non	Forte	Moyenne

8 Conclusion

La réduction de dimension :

- révèle la structure latente,
- simplifie la visualisation,
- ne prouve aucune causalité.

Démarche recommandée :

1. Nettoyage et standardisation
2. ACP pour structure globale
3. t-SNE / UMAP pour exploration locale
4. Interprétation critique

9 Contributions et qualité de représentation en ACP

L'interprétation correcte d'une ACP repose sur deux notions distinctes :

- la **contribution** (qui construit l'axe ?),
- la **qualité de représentation** ou $\cos^2$ (l'axe représente-t-il bien l'élément ?).

Ces notions ne doivent jamais être confondues.

9.1 Contributions

Contribution d'une variable à un axe

Soit la composante principale k :

$$Z_k = a_{1k}X_1 + \dots + a_{pk}X_p$$

où a_{jk} est la charge (loading) de la variable X_j .

La contribution de X_j à l'axe k est définie par :

$$\text{Ctr}_{jk} = \frac{a_{jk}^2}{\sum_{l=1}^p a_{lk}^2}$$

Dans le cas d'une ACP normée (vecteurs propres unitaires) :

$$\sum_{l=1}^p a_{lk}^2 = 1 \quad \Rightarrow \quad \text{Ctr}_{jk} = a_{jk}^2$$

Interprétation. Une contribution élevée signifie que la variable participe fortement à la construction de l'axe. Une contribution faible indique un rôle marginal.

Attention : la contribution ne mesure pas la corrélation brute, mais la participation à la direction propre.

Contribution d'un individu

Soit z_{ik} la coordonnée de l'individu i sur l'axe k , et λ_k la valeur propre associée. La contribution de l'individu i à l'axe k est :

$$\text{Ctr}_{ik} = \frac{z_{ik}^2}{n\lambda_k}$$

où n est le nombre d'individus.

Interprétation. Un individu ayant une contribution élevée influence fortement la direction de l'axe. Les valeurs extrêmes (outliers) ont souvent des contributions importantes.

9.2 Qualité de représentation ($\cos^2$)

La qualité de représentation mesure dans quelle proportion un axe explique la position d'un élément.

Qualité pour un individu

Pour l'individu i :

$$\cos_{ik}^2 = \frac{z_{ik}^2}{\sum_{l=1}^p z_{il}^2}$$

Le dénominateur correspond à l'inertie totale de l'individu.

Interprétation.

- $\cos^2$ proche de 1 : l'axe représente bien l'individu.
- $\cos^2$ faible : projection peu fidèle.

Un individu mal représenté ne doit pas être interprété sur ce plan.

Qualité pour une variable

Si l'on note :

$$r_{jk} = \text{Corr}(X_j, Z_k)$$

alors :

$$\cos_{jk}^2 = r_{jk}^2$$

Interprétation. Une variable est bien représentée sur un axe si son $\cos^2$ est élevé.

9.3 Différence fondamentale

Notion	Question	Interprétation
Contribution	Qui construit l'axe ?	Importance structurelle
$\cos^2$	L'axe représente-t-il bien ?	Qualité de projection

9.4 Lecture méthodologique d'un plan factoriel

Pour interpréter correctement un plan :

1. Examiner la variance expliquée.
2. Identifier les contributions fortes.
3. Vérifier les $\cos^2$.
4. Écarter les éléments mal représentés.
5. Interpréter uniquement les structures robustes.

9.5 Erreurs fréquentes

- Confondre contribution et corrélation.
- Interpréter un axe à partir d'éléments ayant un faible $\cos^2$.
- Ignorer l'influence des outliers.
- Donner une interprétation causale aux axes.

9.6 Interprétation géométrique

Le $\cos^2$ correspond au carré du cosinus de l'angle entre le vecteur représentant l'élément et l'axe factoriel.

Géométriquement :

$$\cos_{ik}^2 = \frac{\|\text{projection sur axe } k\|^2}{\|\text{vecteur total}\|^2}$$

Ainsi, le $\cos^2$ mesure la fidélité de la projection.

9.7 Remarque avancée (niveau M1)

Les contributions sont liées aux valeurs propres :

$$\sum_{i=1}^n \text{Ctr}_{ik} = 1, \quad \sum_{j=1}^p \text{Ctr}_{jk} = 1$$

Ce sont donc des répartitions normalisées de l'inertie.

Une bonne interprétation combine :

- valeurs propres,
- contributions,
- $\cos^2$,
- connaissance du contexte.

10 Exercices conceptuels Contributions et $\cos^2$

Exercice 1 Contribution vs qualité de représentation

On considère une ACP sur trois variables X_1, X_2, X_3 . Pour l'axe 1, on obtient les charges suivantes :

$$Z_1 = 0.8X_1 + 0.5X_2 + 0.3X_3$$

1. Calculer les contributions des variables à l'axe 1.
2. Quelle variable structure principalement l'axe ?
3. Peut-on affirmer que X_3 est bien représentée sur l'axe 1 ?
4. Quelle information supplémentaire faut-il examiner ?

Exercice 2 Interprétation géométrique du $\cos^2$

On considère un individu i dont les coordonnées sur les deux premières composantes sont :

$$z_{i1} = 3, \quad z_{i2} = 4$$

1. Calculer le $\cos^2$ de l'individu sur l'axe 1.
2. Calculer le $\cos^2$ sur le plan (1,2).
3. L'individu est-il bien représenté sur l'axe 1 ?
4. Interpréter géométriquement le résultat.

Exercice 3 Influence d'un individu extrême

On observe qu'un individu possède :

$$z_{i1} = 10$$

alors que la majorité des individus ont des coordonnées comprises entre -2 et 2.

1. Comment évolue sa contribution à l'axe 1 ?
2. Pourquoi cela peut-il être problématique ?
3. Que faut-il vérifier avant d'interpréter l'axe ?
4. Proposer une solution méthodologique.

Exercice 4 Variable fortement contributive mais mal représentée

Supposons qu'une variable ait :

$$\text{Ctr}_{j1} = 0.45$$

mais

$$\cos^2_{j1} = 0.15$$

1. Comment interpréter cette situation ?

2. Pourquoi ces deux mesures peuvent-elles diverger ?
3. Peut-on interpréter l'axe à partir de cette variable ?
4. Quelle vérification supplémentaire est nécessaire ?

Exercice 5 Sommes des contributions

1. Montrer que la somme des contributions des variables à un axe vaut 1.
2. Montrer que la somme des contributions des individus à un axe vaut 1.
3. Interpréter ces résultats en termes d'inertie.

11 Corrigé magistral détaillé

Exercice 1

Contributions :

$$\text{Ctr}_{11} = 0.8^2 = 0.64$$

$$\text{Ctr}_{21} = 0.5^2 = 0.25$$

$$\text{Ctr}_{31} = 0.3^2 = 0.09$$

La variable X_1 structure principalement laxe.

On ne peut pas conclure sur la qualité de représentation de X_3 sans examiner son $\cos^2$.

Il faut calculer :

$$\cos_{31}^2 = \text{Corr}(X_3, Z_1)^2$$

Exercice 2

Norme totale :

$$z_{i1}^2 + z_{i2}^2 = 9 + 16 = 25$$

$$\cos_{i1}^2 = \frac{9}{25} = 0.36$$

$$\cos_{i2}^2 = \frac{16}{25} = 0.64$$

Sur le plan (1,2), le $\cos^2$ vaut 1.

L'individu est mal représenté sur l'axe 1 seul.

Géométriquement : l'angle avec l'axe 1 est important.

Exercice 3

Contribution proportionnelle à :

$$\frac{z_{i1}^2}{n\lambda_1}$$

Comme $z_{i1}^2 = 100$, contribution très élevée.

Problème : un individu extrême peut orienter l'axe.

Il faut vérifier :

- validité de la donnée,
- robustesse de l'ACP.

Solution : ACP robuste ou suppression justifiée.

Exercice 4

La variable participe à la construction de laxe mais laxe ne la représente pas bien.

Cela peut se produire si :

- elle est corrélée à plusieurs axes,
- son inertie totale est répartie.

On ne doit pas interpréter laxe uniquement à partir de cette variable.

Il faut examiner le $\cos^2$ sur plusieurs axes.

Exercice 5

Pour les variables :

$$\sum_{j=1}^p a_{jk}^2 = 1$$

donc :

$$\sum_{j=1}^p \text{Ctr}_{jk} = 1$$

Pour les individus :

$$\sum_{i=1}^n \frac{z_{ik}^2}{n\lambda_k} = 1$$

Ces sommes traduisent une décomposition de linertie totale sur laxe considéré.