

Master 1 Informatique

Analyse de Données

Module 1 — Introduction à l'analyse de données

Département d'Informatique

Table des matières

1	Modélisation prédictive	4
1.1	Introduction : de la description à la prédiction	4
1.1.1	Analyse descriptive vs analyse prédictive	4
1.1.2	Apprentissage supervisé	4
1.1.3	Exemples de problèmes prédictifs	5
1.1.4	Types de problèmes prédictifs	5
1.1.5	Analyse descriptive vs analyse prédictive	6
1.1.6	Apprentissage supervisé	6
1.1.7	Exemples de problèmes prédictifs	6
1.2	Formulation mathématique du problème	6
1.2.1	Relation entre variables	6
1.2.2	Fonction de prédiction	6
1.2.3	Erreur de prédiction	6
1.2.4	Risque empirique	6
1.2.5	Problème d'optimisation	7
1.2.6	Remarque	7
1.2.7	Variables explicatives et variable cible	7
1.2.8	Fonction de prédiction	7
1.2.9	Erreur de prédiction	7
1.3	Régression linéaire	7
1.3.1	Intuition du modèle	7
1.3.2	Modèle de régression linéaire	7
1.3.3	Interprétation des coefficients	8
1.3.4	Exemple	8
1.3.5	Interprétation géométrique	8
1.3.6	Modèle linéaire	8
1.3.7	Interprétation géométrique	8
1.3.8	Hypothèses du modèle	8
1.4	Estimation par moindres carrés	8
1.4.1	Principe des moindres carrés	8
1.4.2	Problème d'optimisation	9
1.4.3	Formulation matricielle	9
1.4.4	Solution analytique	9
1.4.5	Interprétation géométrique	9
1.4.6	Remarque	9
1.5	Interprétation et propriétés du modèle	9
1.5.1	Interprétation des coefficients	10
1.5.2	Valeurs prédites	10
1.5.3	Résidus	10
1.5.4	Propriétés des résidus	10
1.5.5	Hypothèses du modèle	11
1.5.6	Remarque	11
1.6	Évaluation du modèle	11
1.6.1	Erreur quadratique moyenne (MSE)	11

1.6.2	Erreur quadratique moyenne racine (RMSE)	11
1.6.3	Décomposition de la variance	12
1.6.4	Coefficient de détermination	12
1.6.5	Interprétation	12
1.7	Validation des modèles	12
1.7.1	Erreur d'apprentissage et erreur de généralisation	12
1.7.2	Séparation train / test	13
1.7.3	Validation croisée	13
1.7.4	Choix du nombre de blocs	13
1.7.5	Objectif de la validation	13
1.8	Surapprentissage	14
1.8.1	Intuition	14
1.8.2	Sous-apprentissage	14
1.8.3	Surapprentissage	14
1.8.4	Exemple	14
1.8.5	Compromis biais-variance	14
1.8.6	Compromis	14
1.8.7	Rôle de la validation	15
1.9	Introduction à la régression logistique	15
1.9.1	Variable binaire	15
1.9.2	Limites de la régression linéaire	15
1.9.3	Fonction logistique	15
1.9.4	Transformation logit	16
1.9.5	Interprétation des coefficients	16
1.9.6	Décision de classification	16
1.9.7	Remarque	16
1.10	Messages méthodologiques	16
1.10.1	Un modèle est une approximation	16
1.10.2	Corrélation et causalité	16
1.10.3	Importance de la qualité des données	17
1.10.4	Risque de surapprentissage	17
1.10.5	Interprétation des résultats	17
1.10.6	Validation des modèles	17
1.10.7	Modèle simple vs modèle complexe	17
1.11	Exercices conceptuels	17
1.12	Correction des exercices	19
1.13	Travaux pratiques	20
2	TP – Modélisation prédictive	20
2.1	Partie 1 : Exploration des données	21
2.2	Partie 2 : Régression linéaire	21
2.3	Partie 3 : Évaluation du modèle	21
2.4	Partie 4 : Séparation train/test	21
2.5	Partie 5 : Validation croisée	21
2.6	Partie 6 : Régression logistique	21

1 Modélisation prédictive

1.1 Introduction : de la description à la prédiction

Les modules précédents ont été consacrés à l'exploration et à la compréhension des données :

- préparation et qualité des données,
- analyse exploratoire (EDA),
- réduction de dimension,
- clustering.

Ces approches permettent de **décrire** et de **comprendre** la structure d'un jeu de données.

Cependant, dans de nombreuses applications, l'objectif principal n'est pas seulement de comprendre les données existantes, mais de **prédire des valeurs futures ou inconnues**.

C'est l'objet de la **modélisation prédictive**.

1.1.1 Analyse descriptive vs analyse prédictive

On distingue généralement deux grandes approches en analyse de données.

Analyse descriptive L'analyse descriptive vise à résumer et explorer les données.

Exemples :

- calcul de statistiques descriptives,
- visualisation des distributions,
- analyse de corrélations,
- identification de groupes par clustering.

L'objectif est de répondre à la question :

Que disent les données ?

Analyse prédictive L'analyse prédictive vise à construire un modèle capable de prédire une variable d'intérêt à partir d'autres variables.

L'objectif devient alors :

Que peut-on prédire à partir des données ?

Cette approche repose sur l'idée qu'il existe une relation entre une variable cible et un ensemble de variables explicatives.

1.1.2 Apprentissage supervisé

La modélisation prédictive s'inscrit dans le cadre de l'**apprentissage supervisé**.

On observe un ensemble de données de la forme :

$$(X_i, Y_i), \quad i = 1, \dots, n$$

où :

- $X_i = (X_{i1}, \dots, X_{ip})$ représente les variables explicatives,
- Y_i est la variable cible à prédire.

Le but est d'apprendre une fonction de prédiction :

$$f(X) \rightarrow Y$$

qui permettra de prédire la valeur de Y pour une nouvelle observation.

1.1.3 Exemples de problèmes prédictifs

La modélisation prédictive intervient dans de nombreux domaines.

Prévision de prix Prédire le prix d'un logement à partir de :

- surface,
- localisation,
- nombre de pièces,
- année de construction.

Diagnostic médical Prédire la probabilité d'une maladie à partir de :

- âge,
- symptômes,
- résultats d'analyses biologiques.

Risque de crédit Prédire la probabilité de défaut d'un emprunteur à partir de :

- revenu,
- historique de crédit,
- situation professionnelle.

1.1.4 Types de problèmes prédictifs

On distingue deux grands types de problèmes.

Régression La variable cible est quantitative.

Exemple :

$$Y = \text{prix d'une maison}$$

Classification La variable cible est qualitative.

Exemple :

$$Y = \begin{cases} 1 & \text{malade} \\ 0 & \text{sain} \end{cases}$$

Dans ce module, nous introduirons deux modèles fondamentaux :

- la **régression linéaire**,
- la **régression logistique**.

Ces modèles constituent la base de nombreuses méthodes d'apprentissage statistique.

1.1.5 Analyse descriptive vs analyse prédictive

1.1.6 Apprentissage supervisé

1.1.7 Exemples de problèmes prédictifs

1.2 Formulation mathématique du problème

Afin de formaliser la modélisation prédictive, il est nécessaire d'introduire un cadre mathématique général.

Considérons un ensemble de données composé de n observations :

$$(X_i, Y_i), \quad i = 1, \dots, n$$

où :

- $X_i = (X_{i1}, \dots, X_{ip}) \in \mathbb{R}^p$ représente le vecteur de variables explicatives,
- Y_i représente la variable cible.

Le problème consiste à apprendre une relation entre les variables explicatives et la variable cible.

1.2.1 Relation entre variables

On suppose qu'il existe une relation fonctionnelle :

$$Y = f(X) + \varepsilon$$

où :

- f est une fonction inconnue,
- ε représente un terme d'erreur aléatoire.

Le rôle de la modélisation prédictive est d'estimer une approximation de la fonction f à partir des données observées.

1.2.2 Fonction de prédiction

On construit un modèle :

$$\hat{Y} = \hat{f}(X)$$

qui permet de prédire la valeur de Y pour une nouvelle observation.

L'objectif est que la prédiction soit la plus proche possible de la valeur réelle.

1.2.3 Erreur de prédiction

Pour mesurer la qualité d'un modèle, on introduit une fonction de perte qui quantifie l'erreur de prédiction.

Dans le cas d'une variable quantitative, la perte la plus courante est l'erreur quadratique :

$$L(Y, \hat{Y}) = (Y - \hat{Y})^2$$

Cette fonction pénalise fortement les grandes erreurs.

1.2.4 Risque empirique

La performance du modèle est mesurée sur l'ensemble des données d'apprentissage.

On définit le risque empirique :

$$R(\hat{f}) = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{f}(X_i))^2$$

L'objectif de l'apprentissage consiste à trouver la fonction $\hat{f}$ qui minimise ce risque.

1.2.5 Problème d'optimisation

La modélisation prédictive peut donc être formulée comme un problème d'optimisation :

$$\hat{f} = \arg \min_f \frac{1}{n} \sum_{i=1}^n L(Y_i, f(X_i))$$

Autrement dit, on cherche la fonction qui minimise l'erreur moyenne sur les données observées.

1.2.6 Remarque

Ce cadre général englobe la plupart des méthodes d'apprentissage statistique :

- régression linéaire,
- régression logistique,
- arbres de décision,
- réseaux de neurones.

Chaque méthode correspond simplement à un choix particulier de la fonction f et de la manière de l'estimer.

1.2.7 Variables explicatives et variable cible

1.2.8 Fonction de prédiction

1.2.9 Erreur de prédiction

1.3 Régression linéaire

La régression linéaire est l'un des modèles les plus simples et les plus utilisés en modélisation prédictive. Elle consiste à approximer la relation entre une variable cible et un ensemble de variables explicatives par une fonction linéaire.

1.3.1 Intuition du modèle

Supposons que l'on souhaite prédire le prix d'un logement à partir de sa surface.

On peut observer empiriquement que le prix augmente généralement avec la surface.

Une première approximation consiste alors à modéliser cette relation par une droite :

$$prix = \beta_0 + \beta_1 \times surface$$

où :

- β_0 est l'ordonnée à l'origine,
- β_1 représente l'effet de la surface sur le prix.

Dans ce cadre, la régression linéaire consiste à déterminer la droite qui décrit le mieux la relation entre les variables.

1.3.2 Modèle de régression linéaire

Dans le cas général avec p variables explicatives, le modèle s'écrit :

$$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p + \varepsilon$$

où :

- Y est la variable cible,
- $X_1, \dots, X_p$ sont les variables explicatives,
- $\beta_0, \dots, \beta_p$ sont les coefficients du modèle,
- ε est un terme d'erreur aléatoire.

Le modèle suppose donc que la variable cible est une combinaison linéaire des variables explicatives.

1.3.3 Interprétation des coefficients

Chaque coefficient β_j mesure l'effet marginal de la variable X_j sur la variable cible.

Plus précisément :

$$\beta_j = \frac{\partial Y}{\partial X_j}$$

Il représente la variation moyenne de Y lorsque X_j augmente d'une unité, toutes les autres variables étant maintenues constantes.

1.3.4 Exemple

Considérons le modèle suivant :

$$prix = 50\,000 + 2000 \times surface$$

Cela signifie que :

- un logement de surface nulle vaut théoriquement 50 000,
- chaque mètre carré supplémentaire augmente le prix de 2000 unités monétaires.

1.3.5 Interprétation géométrique

Dans l'espace des observations, la régression linéaire peut être interprétée comme la recherche d'un hyperplan qui approxime au mieux les données.

Dans le cas d'une seule variable explicative, cet hyperplan est simplement une droite.

Dans le cas de deux variables explicatives, il s'agit d'un plan.

Dans le cas général avec p variables explicatives, il s'agit d'un hyperplan de dimension p .

Le problème consiste donc à trouver l'hyperplan qui minimise l'erreur de prédiction.

1.3.6 Modèle linéaire

1.3.7 Interprétation géométrique

1.3.8 Hypothèses du modèle

1.4 Estimation par moindres carrés

Le modèle de régression linéaire introduit précédemment contient des coefficients inconnus :

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \varepsilon$$

L'objectif est d'estimer les paramètres :

$$\beta_0, \beta_1, \dots, \beta_p$$

à partir des données observées.

1.4.1 Principe des moindres carrés

L'idée fondamentale consiste à choisir les coefficients du modèle de manière à minimiser l'erreur entre les valeurs observées et les valeurs prédites.

Pour chaque observation i , la prédiction du modèle est :

$$\hat{Y}_i = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip}$$

L'erreur de prédiction est appelée **résidu** :

$$e_i = Y_i - \hat{Y}_i$$

La méthode des moindres carrés consiste à minimiser la somme des carrés des résidus :

$$S(\beta) = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Cette quantité est appelée **erreur quadratique totale**.

1.4.2 Problème d'optimisation

On cherche les coefficients qui minimisent cette fonction :

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_{i1} - \cdots - \beta_p X_{ip})^2$$

Ce problème possède une solution analytique qui peut être obtenue à l'aide de l'algèbre linéaire.

1.4.3 Formulation matricielle

On introduit la matrice des variables explicatives :

$$X = \begin{pmatrix} 1 & X_{11} & \cdots & X_{1p} \\ 1 & X_{21} & \cdots & X_{2p} \\ \vdots & \vdots & & \vdots \\ 1 & X_{n1} & \cdots & X_{np} \end{pmatrix}$$

et le vecteur des observations :

$$Y = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}$$

Le modèle peut alors s'écrire :

$$Y = X\beta + \varepsilon$$

où :

$$\beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}$$

1.4.4 Solution analytique

La solution du problème des moindres carrés est donnée par :

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

Cette expression fournit directement l'estimateur des coefficients du modèle.

1.4.5 Interprétation géométrique

Du point de vue géométrique, la régression linéaire correspond à la projection orthogonale du vecteur Y sur l'espace engendré par les colonnes de la matrice X .

Autrement dit, la prédiction $\hat{Y}$ est la projection de Y dans le sous-espace des combinaisons linéaires des variables explicatives.

Cette interprétation explique pourquoi la solution minimise la distance entre Y et l'espace des modèles linéaires.

1.4.6 Remarque

La solution précédente existe si la matrice $X^T X$ est inversible, ce qui nécessite que les variables explicatives ne soient pas parfaitement colinéaires.

1.5 Interprétation et propriétés du modèle

Une fois les coefficients du modèle estimés, il est nécessaire d'interpréter les résultats et d'analyser les propriétés du modèle obtenu.

1.5.1 Interprétation des coefficients

Considérons le modèle de régression linéaire :

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \varepsilon$$

Chaque coefficient β_j possède une interprétation précise.

Ordonnée à l'origine Le coefficient β_0 représente la valeur moyenne de la variable cible lorsque toutes les variables explicatives sont nulles.

Dans certains contextes, cette interprétation peut être peu réaliste si la valeur zéro n'a pas de sens pour les variables.

Effet marginal Le coefficient β_j mesure l'effet marginal de la variable X_j sur la variable cible.
Plus précisément :

$$\beta_j = \frac{\partial Y}{\partial X_j}$$

Il correspond à la variation moyenne de Y lorsque X_j augmente d'une unité, toutes les autres variables étant maintenues constantes.

1.5.2 Valeurs prédites

Les valeurs prédites par le modèle sont données par :

$$\hat{Y} = X\hat{\beta}$$

Elles représentent l'estimation de la variable cible produite par le modèle.

1.5.3 Résidus

Les résidus mesurent l'erreur de prédiction du modèle.
Pour chaque observation :

$$e_i = Y_i - \hat{Y}_i$$

Un bon modèle doit produire des résidus :

- de moyenne proche de zéro,
- sans structure particulière,
- de variance relativement constante.

L'analyse des résidus constitue un outil important pour diagnostiquer la qualité du modèle.

1.5.4 Propriétés des résidus

Dans le modèle de régression linéaire estimé par moindres carrés, les résidus possèdent plusieurs propriétés importantes :

- la somme des résidus est nulle :

$$\sum_{i=1}^n e_i = 0$$

- les résidus sont orthogonaux aux variables explicatives :

$$X^T e = 0$$

Ces propriétés découlent directement de la minimisation de la somme des carrés des résidus.

1.5.5 Hypothèses du modèle

Le modèle de régression linéaire repose sur plusieurs hypothèses :

- **Linéarité**
La relation entre la variable cible et les variables explicatives est supposée linéaire.
- **Indépendance**
Les observations sont supposées indépendantes.
- **Homoscédasticité**
La variance des erreurs est constante :

$$\text{Var}(\varepsilon_i) = \sigma^2$$

— **Normalité des erreurs**

Dans certains contextes, on suppose que :

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

Ces hypothèses sont importantes pour l'interprétation statistique du modèle et pour la validité de certaines méthodes d'inférence.

1.5.6 Remarque

Dans la pratique, ces hypothèses ne sont pas toujours strictement vérifiées.

Il est donc essentiel de vérifier empiriquement le comportement des résidus afin de détecter d'éventuelles violations du modèle.

1.6 Évaluation du modèle

Une fois le modèle estimé, il est nécessaire d'évaluer sa capacité à prédire correctement la variable cible.

Plusieurs mesures permettent de quantifier la qualité d'un modèle de régression.

1.6.1 Erreur quadratique moyenne (MSE)

Une première mesure consiste à calculer l'erreur quadratique moyenne.

Elle est définie par :

$$MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Cette mesure correspond à la moyenne des carrés des résidus.

Plus la valeur du MSE est faible, plus le modèle est précis.

1.6.2 Erreur quadratique moyenne racine (RMSE)

Le RMSE est la racine carrée du MSE :

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2}$$

L'avantage du RMSE est qu'il s'exprime dans la même unité que la variable cible.

Il est donc plus facile à interpréter.

1.6.3 Décomposition de la variance

Afin d'évaluer la qualité du modèle, on introduit la décomposition suivante :

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Cette relation décompose la variance totale de la variable cible en deux parties :

— variance expliquée par le modèle

$$\sum (\hat{Y}_i - \bar{Y})^2$$

— variance non expliquée

$$\sum (Y_i - \hat{Y}_i)^2$$

1.6.4 Coefficient de détermination

Le coefficient de détermination R^2 mesure la proportion de variance expliquée par le modèle. Il est défini par :

$$R^2 = 1 - \frac{\sum (Y_i - \hat{Y}_i)^2}{\sum (Y_i - \bar{Y})^2}$$

Ses valeurs sont comprises entre 0 et 1.

- $R^2 = 0$: le modèle n'explique pas la variabilité des données
- $R^2 = 1$: le modèle explique parfaitement les données

1.6.5 Interprétation

Un coefficient $R^2 = 0.75$ signifie que :

75% de la variabilité de la variable cible est expliquée par le modèle.

Cependant, un R^2 élevé ne garantit pas nécessairement un bon modèle prédictif.

Il est possible qu'un modèle s'ajuste très bien aux données d'apprentissage mais généralise mal à de nouvelles données.

Cette situation est appelée **surapprentissage**.

1.7 Validation des modèles

Les mesures présentées précédemment permettent d'évaluer la qualité d'un modèle sur les données utilisées pour l'estimation.

Cependant, l'objectif d'un modèle prédictif est de produire de bonnes prédictions sur de nouvelles observations.

Il est donc nécessaire d'évaluer la capacité du modèle à **généraliser**.

1.7.1 Erreur d'apprentissage et erreur de généralisation

On distingue deux types d'erreurs :

Erreur d'apprentissage Elle correspond à l'erreur calculée sur les données utilisées pour estimer le modèle.

$$MSE_{train}$$

Cette erreur est souvent optimiste.

Erreur de généralisation Elle correspond à l'erreur de prédiction sur de nouvelles observations non utilisées pour l'estimation.

$$MSE_{test}$$

Cette erreur reflète mieux la performance réelle du modèle.

1.7.2 Séparation train / test

Une méthode simple consiste à diviser le jeu de données en deux parties :

- **ensemble d'entraînement (train)**
utilisé pour estimer le modèle
- **ensemble de test**
utilisé pour évaluer la performance prédictive

Typiquement, on utilise :

- 70% ou 80% des données pour l'entraînement
- 20% ou 30% pour le test

Le modèle est estimé sur l'ensemble d'entraînement, puis évalué sur l'ensemble de test.

1.7.3 Validation croisée

La séparation train / test dépend fortement du choix des observations.

Pour obtenir une estimation plus stable, on utilise la **validation croisée**.

La méthode la plus courante est la validation croisée en K blocs.

Le principe est le suivant :

1. les données sont divisées en K sous-ensembles
 2. le modèle est entraîné sur $K - 1$ blocs
 3. le bloc restant est utilisé pour le test
 4. l'opération est répétée K fois
- L'erreur finale correspond à la moyenne des erreurs obtenues.

1.7.4 Choix du nombre de blocs

En pratique, on utilise souvent :

- $K = 5$
- $K = 10$

Ces valeurs offrent un bon compromis entre biais et variance de l'estimation.

1.7.5 Objectif de la validation

La validation des modèles permet :

- d'estimer la performance prédictive réelle
- de comparer plusieurs modèles
- de détecter le surapprentissage

1.8 Surapprentissage

Dans de nombreux cas, un modèle peut s'ajuster très précisément aux données d'apprentissage tout en produisant de mauvaises prédictions sur de nouvelles données.

Ce phénomène est appelé **surapprentissage** (*overfitting*).

1.8.1 Intuition

Considérons un ensemble de points observés. Un modèle trop simple peut être incapable de capturer la structure réelle des données.

À l'inverse, un modèle trop complexe peut s'ajuster parfaitement aux données observées, mais également capturer le bruit aléatoire.

Dans ce cas, le modèle ne reflète plus la relation réelle entre les variables.

1.8.2 Sous-apprentissage

Le **sous-apprentissage** (*underfitting*) se produit lorsque le modèle est trop simple pour représenter correctement la relation entre les variables.

Dans ce cas :

- l'erreur d'apprentissage est élevée
- l'erreur de test est également élevée

Le modèle ne parvient pas à capturer la structure des données.

1.8.3 Surapprentissage

Le surapprentissage apparaît lorsque le modèle est trop complexe.

Dans ce cas :

- l'erreur d'apprentissage est très faible
- l'erreur de test est élevée

Le modèle s'ajuste non seulement à la structure des données mais également au bruit aléatoire.

1.8.4 Exemple

Supposons que l'on ajuste un polynôme de degré élevé à un ensemble de points.

Un polynôme de degré élevé peut passer exactement par tous les points observés.

Cependant, la fonction obtenue peut présenter de fortes oscillations et produire des prédictions instables.

1.8.5 Compromis biais-variance

Le phénomène de surapprentissage est souvent interprété à travers le compromis **biais-variance**.

Biais Le biais mesure l'erreur introduite par une hypothèse trop simplificatrice sur la structure du modèle.

Un modèle simple possède généralement un biais élevé.

Variance La variance mesure la sensibilité du modèle aux fluctuations des données.

Un modèle très complexe possède souvent une variance élevée.

1.8.6 Compromis

Un bon modèle doit trouver un équilibre entre biais et variance.

— modèle trop simple → biais élevé

— modèle trop complexe → variance élevée

L'objectif est donc de choisir un niveau de complexité qui minimise l'erreur de prédiction sur de nouvelles données.

1.8.7 Rôle de la validation

Les techniques de validation, comme la séparation train/test ou la validation croisée, permettent de détecter le surapprentissage et d'évaluer la capacité de généralisation du modèle.

1.9 Introduction à la régression logistique

Dans de nombreux problèmes prédictifs, la variable cible n'est pas quantitative mais qualitative.

Par exemple :

— un patient est malade ou non

— un client rembourse ou ne rembourse pas un crédit

— un email est spam ou non

Ces problèmes correspondent à des tâches de **classification**.

1.9.1 Variable binaire

Dans le cas le plus simple, la variable cible prend deux valeurs :

$$Y \in \{0, 1\}$$

Par exemple :

$$Y = \begin{cases} 1 & \text{événement présent} \\ 0 & \text{événement absent} \end{cases}$$

L'objectif du modèle est alors de prédire la probabilité de l'événement :

$$P(Y = 1 \mid X)$$

1.9.2 Limites de la régression linéaire

On pourrait être tenté d'utiliser une régression linéaire pour prédire la variable binaire. Cependant, cette approche présente plusieurs problèmes :

- les prédictions peuvent être inférieures à 0 ou supérieures à 1
- la relation entre les variables n'est généralement pas linéaire

Il est donc nécessaire d'utiliser un modèle adapté aux probabilités.

1.9.3 Fonction logistique

La régression logistique modélise la probabilité conditionnelle :

$$p(X) = P(Y = 1 | X)$$

à l'aide de la fonction logistique :

$$p(X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p)}}$$

Cette fonction possède deux propriétés importantes :

- les valeurs sont comprises entre 0 et 1
- la relation entre les variables peut être non linéaire

1.9.4 Transformation logit

La régression logistique peut également s'écrire sous la forme :

$$\log\left(\frac{p(X)}{1 - p(X)}\right) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$$

Le terme :

$$\frac{p}{1 - p}$$

est appelé **odds** (rapport de chances).

La transformation logarithmique est appelée **logit**.

1.9.5 Interprétation des coefficients

Dans un modèle logistique, le coefficient β_j représente l'effet de la variable X_j sur le logarithme du rapport de chances.

Une augmentation de X_j d'une unité modifie les odds d'un facteur :

$$e^{\beta_j}$$

Cette interprétation est très utilisée en épidémiologie et en analyse de risques.

1.9.6 Décision de classification

Une fois la probabilité estimée, on peut effectuer une classification.

Par exemple :

$$\hat{Y} = \begin{cases} 1 & \text{si } p(X) > 0.5 \\ 0 & \text{sinon} \end{cases}$$

Le seuil peut être ajusté en fonction du problème étudié.

1.9.7 Remarque

La régression logistique constitue l'un des modèles de classification les plus simples et les plus utilisés. Elle sert souvent de modèle de référence avant l'utilisation de méthodes plus complexes.

1.10 Messages méthodologiques

La modélisation prédictive constitue un outil puissant pour analyser et prévoir des phénomènes à partir de données.

Cependant, plusieurs points méthodologiques doivent être soigneusement pris en compte lors de l'utilisation de ces modèles.

1.10.1 Un modèle est une approximation

Tout modèle statistique est une simplification de la réalité.

La relation réelle entre les variables peut être beaucoup plus complexe que celle décrite par le modèle.

Un bon modèle n'est donc pas nécessairement un modèle "vrai", mais un modèle **utile** pour la prédiction ou l'interprétation.

1.10.2 Corrélation et causalité

La présence d'une relation statistique entre deux variables ne signifie pas nécessairement qu'il existe une relation causale.

Par exemple, deux variables peuvent être corrélées en raison de l'influence d'une troisième variable non observée.

Il est donc essentiel d'interpréter les résultats avec prudence.

1.10.3 Importance de la qualité des données

La performance d'un modèle dépend fortement de la qualité des données utilisées.

Des données bruitées, incomplètes ou biaisées peuvent conduire à des modèles peu fiables.

En pratique, une grande partie du travail en analyse de données consiste à :

- nettoyer les données
- détecter les valeurs aberrantes
- traiter les données manquantes
- vérifier la cohérence des variables

1.10.4 Risque de surapprentissage

Un modèle trop complexe peut s'ajuster parfaitement aux données d'entraînement mais produire de mauvaises prédictions sur de nouvelles données.

Il est donc essentiel de toujours évaluer la performance du modèle sur des données indépendantes.

1.10.5 Interprétation des résultats

Les coefficients d'un modèle doivent être interprétés dans le contexte du problème étudié.

Une relation statistique peut avoir des significations différentes selon le domaine d'application.

L'expertise métier reste donc indispensable pour interpréter correctement les résultats.

1.10.6 Validation des modèles

La validation constitue une étape fondamentale de toute analyse prédictive.

Les techniques comme la séparation train/test ou la validation croisée permettent d'évaluer la capacité du modèle à généraliser à de nouvelles observations.

Un modèle doit toujours être évalué au-delà des données ayant servi à son estimation.

1.10.7 Modèle simple vs modèle complexe

Dans de nombreuses situations, un modèle simple peut être préférable à un modèle très complexe.

Les modèles simples sont :

- plus interprétables
- plus robustes
- plus faciles à communiquer

Le principe de **parcimonie** (consistant à privilégier les modèles les plus simples possibles) constitue une règle importante en modélisation statistique.

1.11 Exercices conceptuels

Exercice 1 : Analyse descriptive vs prédictive

On dispose d'un jeu de données contenant les variables suivantes :

- surface d'un logement
- nombre de pièces
- localisation
- prix de vente

1. Donner un exemple d'analyse descriptive que l'on pourrait réaliser avec ces données.
2. Donner un exemple de problème de modélisation prédictive.
3. Quelle serait la variable cible dans ce cas ?

Exercice 2 : Modèle de régression linéaire

Considérons le modèle :

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

où :

- Y est le prix d'un logement
- X est la surface du logement

Après estimation, on obtient :

$$\hat{Y} = 50\,000 + 2000X$$

1. Interpréter le coefficient β_1 .
2. Interpréter le coefficient β_0 .
3. Calculer le prix prédit pour un logement de 80 m².

Exercice 3 : Résidus

On observe les valeurs suivantes :

$$Y_i = 120, \quad \hat{Y}_i = 110$$

1. Calculer le résidu.
2. Que signifie un résidu positif ?
3. Que signifie un résidu négatif ?

Exercice 4 : Interprétation de R^2

Un modèle de régression possède un coefficient :

$$R^2 = 0.82$$

1. Comment interpréter cette valeur ?
2. Un R^2 élevé garantit-il un bon modèle prédictif ?

Exercice 5 : Surapprentissage

On entraîne deux modèles :

- modèle A : erreur train faible, erreur test élevée
- modèle B : erreur train modérée, erreur test faible

1. Quel modèle présente un surapprentissage ?
2. Quel modèle est préférable ?
3. Expliquer pourquoi.

Exercice 6 : Régression vs classification

Pour chacun des problèmes suivants, indiquer s'il s'agit d'un problème de régression ou de classification.

1. prédire le prix d'une voiture
2. prédire si un email est spam
3. prédire la consommation d'électricité d'un ménage
4. prédire si un patient est atteint d'une maladie

Exercice 7 : Régression logistique

Dans un modèle logistique, on estime :

$$\beta_1 = 0.7$$

1. Calculer l'effet multiplicatif sur les odds.
2. Interpréter ce résultat.

1.12 Correction des exercices

Exercice 1

1. Analyse descriptive On pourrait par exemple :

- calculer le prix moyen par quartier
- analyser la distribution des surfaces
- étudier la corrélation entre surface et prix

2. Problème prédictif Prédire le prix d'un logement à partir :

- de sa surface
- du nombre de pièces
- de la localisation

3. Variable cible La variable cible est le **prix du logement**.

Exercice 2

1. Interprétation de β_1 Le coefficient $\beta_1 = 2000$ signifie que :

une augmentation de la surface de 1 m² augmente le prix moyen de 2000 unités monétaires.

2. Interprétation de β_0 $\beta_0 = 50\,000$ correspond au prix théorique d'un logement de surface nulle. Cette valeur sert principalement d'interception mathématique.

3. Prédiction

$$\hat{Y} = 50\,000 + 2000 \times 80$$

$$\hat{Y} = 210\,000$$

Le prix prédit est donc de 210 000.

Exercice 3

1. Résidu

$$e_i = Y_i - \hat{Y}_i$$

$$e_i = 120 - 110 = 10$$

2. Résidu positif Le modèle sous-estime la valeur réelle.

3. Résidu négatif Le modèle surestime la valeur réelle.

Exercice 4

1. Interprétation Un $R^2 = 0.82$ signifie que :

82% de la variabilité de la variable cible est expliquée par le modèle.

2. Limite Un R^2 élevé ne garantit pas nécessairement une bonne capacité de prédiction.
Le modèle peut être surajusté aux données d'entraînement.

Exercice 5

1. Surapprentissage Le modèle A présente un surapprentissage.

2. Modèle préférable Le modèle B est préférable.

3. Explication Un bon modèle doit généraliser correctement à de nouvelles données.

Exercice 6

- prix d'une voiture : **régression**
- email spam : **classification**
- consommation électrique : **régression**
- diagnostic médical : **classification**

Exercice 7

1. Effet sur les odds

$$e^{0.7} \approx 2.01$$

2. Interprétation Une augmentation d'une unité de la variable multiplie les odds par environ 2.

1.13 Travaux pratiques

2 TP – Modélisation prédictive

Objectifs

Ce TP a pour objectif de mettre en pratique les notions introduites dans le module :

- régression linéaire
- évaluation des modèles
- séparation train/test
- validation croisée
- régression logistique

Nous utiliserons le jeu de données **Boston Housing** qui contient des informations sur des logements.

Variables

Le jeu de données contient notamment :

- **lstat** : pourcentage de population défavorisée
- **rm** : nombre moyen de pièces
- **medv** : valeur médiane des logements

La variable cible sera :

$$Y = medv$$

2.1 Partie 1 : Exploration des données

1. Charger le jeu de données.
2. Afficher les premières observations.
3. Examiner les statistiques descriptives.
4. Visualiser la relation entre `lstat` et `medv`.

2.2 Partie 2 : Régression linéaire

On souhaite prédire le prix des logements.

1. Ajuster un modèle :

$$medv \sim lstat$$

2. Interpréter les coefficients du modèle.
3. Visualiser la droite de régression.

2.3 Partie 3 : Évaluation du modèle

1. Calculer les valeurs prédites.
2. Calculer le MSE.
3. Calculer le RMSE.
4. Interpréter la valeur du coefficient R^2 .

2.4 Partie 4 : Séparation train/test

1. Diviser les données :
 - 80% pour l'entraînement
 - 20% pour le test
2. Estimer le modèle sur l'ensemble d'entraînement.
3. Évaluer l'erreur sur l'ensemble de test.

2.5 Partie 5 : Validation croisée

Utiliser une validation croisée à 10 blocs pour évaluer le modèle.
Comparer les résultats avec l'erreur de test.

2.6 Partie 6 : Régression logistique

Créer une variable binaire :

$$Y = \begin{cases} 1 & \text{si } medv > 25 \\ 0 & \text{sinon} \end{cases}$$

1. Ajuster un modèle de régression logistique.
2. Calculer les probabilités prédites.
3. Construire une règle de classification.

Travail demandé

Rédiger un rapport contenant :

- description du jeu de données
- interprétation du modèle
- analyse de l'erreur de prédiction
- discussion sur le surapprentissage