

1. Distributions statistiques à un caractère

Le savant doit ordonner ; on fait la science avec des faits
comme une maison avec des pierres ;
mais une accumulation de faits n'est pas plus une science
qu'un tas de pierres n'est une maison.

La Science et l'hypothèse, Henri Poincaré (1854-1912)

La statistique descriptive est un ensemble de méthodes permettant de décrire, présenter, résumer des données souvent très nombreuses. Ces méthodes peuvent être numériques (tris, élaboration de tableaux, calcul de moyennes...) et/ou mener à des représentations graphiques.

I. Définitions

A. Population, individu, échantillon

Une *population* est l'ensemble des éléments auxquels se rapportent les *données* étudiées. En statistique, le terme « population » s'applique à des ensembles de toute nature : étudiants d'une académie, production d'une usine, poissons d'une rivière, entreprises d'un secteur donné...

Des enquêtes de l'Office statistique des communautés européennes donnent la durée hebdomadaire moyenne du travail des salariés à temps complet pour 15 pays membres. Les résultats de ces enquêtes ne donnent pas d'information « atomisée » à un niveau plus bas que le pays ; la population de référence n'est donc pas ici l'ensemble (plusieurs millions) de tous les salariés des 15 pays. L'étude de ces 15 observations concerne un ensemble

de 15 unités (statistiques), les 15 pays sélectionnés qui constituent la *population* de l'étude.

Dans une population donnée, chaque élément est appelé « individu » ou « unité statistique ».

La collecte d'informations sur une population peut être effectuée sur la totalité des individus ; on parle alors d'enquêtes *exhaustives*. Lorsque la taille de la population étudiée est élevée, de telles enquêtes sont fort coûteuses ou impossibles, et le cas échéant, leurs résultats souvent très longs à rassembler peuvent être dépassés avant même la fin de l'enquête. C'est la raison pour laquelle on a souvent recours aux enquêtes par *sondage* qui portent sur une partie de la population appelée *échantillon*. Les observations obtenues sur une population ou sur un échantillon constituent un ensemble de données auxquelles s'appliquent les méthodes de la statistique descriptive dont le but est de décrire le plus complètement et le plus simplement l'ensemble des observations qu'elles soient relatives à toute la population ou seulement à un sous-ensemble.

B. Variables

Chaque individu d'une population peut être décrit selon une ou plusieurs *variables* qui peuvent être des caractéristiques qualitatives ou prendre des valeurs numériques.

Une variable est dite *qualitative* si ses différentes réalisations (modalités) ne sont pas numériques. Ainsi : le sexe, la situation matrimoniale, la catégorie socioprofessionnelle... sont des variables qualitatives. On peut toujours rendre numérique une telle variable en associant un nombre à chaque modalité ; on dit alors que les modalités sont codées. Bien entendu, les valeurs numériques n'ont dans ce cas aucune signification particulière, et effectuer des opérations algébriques sur ces valeurs numériques n'a pas de sens.

Une variable est dite *quantitative* lorsqu'elle est intrinsèquement numérique : effectuer des opérations algébriques (addition, multiplication...) sur une telle variable a alors un sens. Une variable quantitative peut être une variable statistique discrète ou continue.

Les *variables statistiques discrètes* sont des variables qui ne peuvent prendre que des valeurs isolées, discrètes. Le nombre d'enfants d'une famille, le nombre de pétales d'une fleur, le nombre de buts marqués lors d'une rencontre de football... sont des variables quantitatives discrètes. Le plus fréquemment, les valeurs possibles sont des nombres entiers.

Les *variables statistiques continues* peuvent prendre toutes les valeurs numériques possibles d'un ensemble inclus dans $\mathbb{R}$: le revenu, la taille, le taux de natalité sont des variables continues.


La distinction entre variables quantitatives discrètes et continues peut paraître factice, car toute mesure est discrète en raison d'une précision toujours limitée ; et inversement, lorsqu'une variable discrète peut prendre un grand nombre de valeurs et que la taille de la population (ou de l'échantillon) étudiée est élevée, on regroupera des valeurs voisines et la variable sera, par extension, traitée comme une variable continue. En pratique, lorsque les valeurs d'une variable sont regroupées en k classes, la variable est traitée comme une variable quantitative continue, mais elle peut aussi être envisagée comme une variable qualitative à k modalités.

Les données dont on dispose sont les modalités ou valeurs prises par plusieurs variables qualitatives ou quantitatives sur les individus d'une population ou d'un échantillon ; pour une population d'entreprises, on peut disposer, par exemple, de données sur le chiffre d'affaire, le bénéfice net, le nombre d'employés, la masse salariale annuelle, le secteur d'activité principale...

On peut, dans un premier temps, décrire chaque variable séparément, puis ensuite, étudier les relations ou liaisons existantes entre elles. Ainsi, dans ce livre, nous envisagerons d'abord les populations statistiques décrites selon une seule variable, puis selon deux variables. L'étude des populations caractérisées par plus de deux variables n'est pas abordée dans cet ouvrage.

II. Représentations graphiques

Deux méthodes de représentation des données vont être exposées. On commencera par celles adaptées aux données nombreuses et/ou anonymes, c'est-à-dire pour lesquelles l'identité des individus n'a pas été relevée ou ne présente pas d'intérêt à être conservée pour l'interprétation. Ceci n'est pas le cas lorsque les individus sont peu nombreux (régions, pays...), où on définira un nouveau mode de représentation graphique dû à J.W. Tukey (§ II.B.). L'étude d'une population selon une variable sera restreinte au cas des variables quantitatives, car la description d'une population selon une variable qualitative est totalement résumée dans un tableau de pourcentages ou dans un diagramme circulaire, appelé aussi diagramme en « camembert » (*cf.* figure 1.1).



Extrait de Agreste, *GraphAgri 2006*,
Ministère de l'Agriculture et de la Pêche.

Figure 1.1 – Surface du verger français en 2005

A. Distributions statistiques et représentations graphiques

Considérons une variable observée sur une population $\mathbb{P}$ de n individus. Si la variable X prend k valeurs ou ensembles de valeurs (appelés dans ce qui suit, modalités), le premier traitement des données brutes consiste à compter le nombre n_i d'individus qui présentent la i^{e} modalité ($i = 1, 2, \dots, k$).

1) Variables statistiques discrètes

Les résultats concernant les observations de la variable X dont l'ensemble des valeurs est $\{x_i, i = 1, \dots, k\}$, sont présentés dans le tableau des effectifs (x_i, n_i) ou dans le tableau des fréquences (x_i, f_i) avec $f_i = n_i/n$ (on utilise souvent le pourcentage $100 \cdot f_i$). Il est préférable de calculer les fréquences à partir des effectifs cumulés (§ II.A.3) afin que des erreurs successives d'arrondis ne donnent pas une somme totale de fréquences différente de 1.

Tableau des effectifs

Modalité	Effectif
x_1	n_1
$\vdots$	$\vdots$
x_i	n_i
$\vdots$	$\vdots$
x_k	n_k
	$\sum_{i=1}^k n_i = n$

Tableau des fréquences

Modalité	Fréquence
x_1	$f_1 = n_1/n$
$\vdots$	$\vdots$
x_i	$f_i = n_i/n$
$\vdots$	$\vdots$
x_k	$f_k = n_k/n$
	$\sum_{i=1}^k f_i = 1$

On présente logiquement les modalités numériques en ordre croissant. On peut associer à ces tableaux une représentation graphique appelée « diagramme en bâtons ».

Un *diagramme en bâtons* (cf. figure 1.2) est construit dans un système d’axes rectangulaires ; les valeurs de la variable statistique X sont portées en abscisse ; à partir de chaque valeur x_i , on trace un segment de droite vertical et dont la hauteur est proportionnelle à l’effectif correspondant. On peut retenir indifféremment une échelle qui explicite les effectifs n_i , ou une échelle qui explicite les fréquences f_i . Pour les distributions du tableau 1.1, on pourrait représenter sur le même graphique les diagrammes en bâtons de plusieurs pays avec des couleurs différentes, chaque couleur correspondant à un pays, ce qui permettrait de comparer les distributions du nombre de personnes par ménage.

Tableau 1.1 – Ménages suivant le nombre de personnes du ménage dans quelques pays en 1995 (%)

	Allemagne	Espagne	Finlande	France	Grèce	Irlande	Italie	Pays-Bas	Portugal
Ménages de :									
– 1 personne	34,4	12,7	37,4	29,2	20,7	22,8	22,7	30,6	13,7
– 2 personnes	32,3	24,5	31,0	31,8	28,9	23,1	23,1	34,0	26,4
– 3 personnes	16,0	21,8	14,4	16,8	19,8	15,6	15,6	13,4	24,7
– 4 personnes	12,6	24,0	11,9	14,2	21,7	17,1	17,1	15,9	22,8
– 5 personnes et plus	4,7	17,0	5,3	8,0	8,9	21,4	21,4	6,2	12,4
Ensemble (en milliers)	34 413	12 112	2 222	23 126	3 756	1 146	1 146	6 425	3 275

Source : Tableaux de l’Économie Française 1999-2000, INSEE.

Nombre de personnes	f_i (%)
1	29,2
2	31,8
3	16,8
4	14,2
5 ou plus	8,0
	100 %




Figure 1.2 – Diagramme en bâtons – Nombre de personnes par ménage en France en 1995

2) Variables statistiques continues

L'infinité des valeurs observables ne rend pas possible la généralisation du diagramme en bâtons. Le domaine de variation d'une variable statistique continue X est partagé en k parties. L'intervalle $[x_{i-1}, x_i[$ fermé à gauche, ouvert à droite, est appelé i^{e} classe ($i = 1, 2, \dots, k$) ; son amplitude est égale à :

$$a_i = x_i - x_{i-1}$$

Il arrive que l'amplitude des classes extrêmes soit indéterminée : la première classe étant définie par « moins de... », et la dernière par « plus de... » (cf. tableau 1.2).

Le choix des extrémités des classes se fait à partir des données brutes ; le nombre k de classes doit être modéré (usuellement entre 4 et 10). Le découpage en classes est assez souvent choisi tel que l'amplitude des classes soit constante, ou tel que les effectifs des classes soient constants (par exemple, 10 % de la population dans chaque classe, cf. tableau 1.6).

Le classement d'une série statistique correspond à une perte d'information par rapport aux données initiales puisque seuls les effectifs des classes sont retenus. Le travail sur une telle série impose alors l'hypothèse que les données sont réparties uniformément à l'intérieur de chacune des classes. On parle aussi d'équirépartition des individus ou encore d'homogénéité dans chacune des classes. Chaque partie de la classe correspond alors à un effectif proportionnel à sa longueur. L'idée est, bien sûr, que chaque classe représente une entité qui doit se distinguer par rapport aux autres classes. Comme précédemment, les résultats sont présentés dans un tableau d'effectifs ou de fréquences. On associe à un tel tableau un histogramme qui est une représentation graphique très répandue. L'histogramme est constitué de la juxtaposition de rectangles (pour respecter l'hypothèse d'équirépartition) dont les bases représentent les différentes classes et dont les surfaces sont proportionnelles aux effectifs des classes (cf. figure 1.3).

On verra par la suite qu’une difficulté du travail avec des séries classées est le choix des limites pour les classes extrêmes, indispensable aussi pour le tracé de l’histogramme.

À la i^e classe, correspond un rectangle dont la base est l’intervalle $[x_{i-1}, x_i[$ et dont la surface est proportionnelle à la fréquence f_i (ou à l’effectif n_i). Si les classes ont toutes la même amplitude, les hauteurs des rectangles sont proportionnelles aux fréquences. Dans le cas où les classes sont d’amplitudes inégales, la hauteur du rectangle correspondant à la i^e classe d’amplitude a_i sera $h_i = f_i/a_i$. La surface du rectangle représentant la i^e classe sera ainsi égale à f_i

Pour une série d’observations relatives à une variable statistique X discrète ou continue classée, la donnée des modalités et de leurs fréquences est appelée « *distribution statistique* » de la variable X .

Tableau 1.2 – Chômeurs BIT selon le sexe et l’ancienneté de chômage en septembre 2006

Ancienneté d’inscription	Distribution en milliers		Distribution en pourcentage	
	Hommes	Femmes	Hommes	Femmes
Moins d’un mois	180,3	181,0	16,5	16,8
D’un à moins de trois mois	203,9	204,9	18,6	19,0
De trois à moins de six mois	169,3	163,1	15,5	15,1
De six mois à moins d’un an	202,1	191,1	18,5	17,7
D’un à moins de deux ans	197,3	199,3	18,0	18,5
De deux à moins de trois ans	74,5	75,4	6,8	7,0
Trois ans ou plus	67,1	62,9	6,1	5,8
Ensemble	1 094,5	1 077,7	100	100
Ancienneté moyenne en jours	341	334		

Source : Bulletin Mensuel des Statistiques du Travail, www.travail.gouv.fr, octobre 2006.




Figure 1.3 – Histogramme de la distribution des chômeurs « Femmes » selon l'ancienneté (voir tableau 1.2)

La classe « Trois ans ou plus » est supposée bornée supérieurement par 5 ans (60 mois).

3) Fréquences cumulées et courbe cumulative

a) Tableau des fréquences cumulées

Les tableaux de fréquences (ou d'effectifs) qui viennent d'être définis peuvent être modifiés de façon à présenter un résumé des données sous une forme différente.

On appelle *effectif cumulé* de la i^e classe, le nombre d'individus N_i pour lesquels la variable prend une valeur inférieure à x_i :

$$N_i = \sum_{j \leq i} n_j \text{ pour } i = 1, 2, \dots, k$$

On définit de même F_i , la *fréquence cumulée* de la i^e classe : $F_i = N_i/n$

Les tableaux d'effectifs cumulés ou de fréquences cumulées se déduisent des tableaux d'effectifs ou de fréquences (non cumulés) en substituant aux effectifs ou fréquences non cumulés les effectifs ou fréquences cumulés. Les deux types de tableaux sont donc équivalents (cf. figures 1.2 et 1.4).

b) Fonction cumulative et courbe cumulative

La *courbe cumulative* ou courbe des fréquences cumulées est la représentation graphique des fréquences cumulées. Plus précisément, la courbe cumulative est la représentation graphique de la proportion $F(t)$ des individus de la population dont le caractère prend une valeur inférieure à t . Cette fonction, appelée *fonction cumulative* ou *fonction de répartition*, est :

1. définie pour tout $t \in \mathbb{R}$
2. croissante (mais non strictement croissante)
3. nulle pour t inférieur à $\min_{1 \leq i \leq n} x_i$
4. égale à 1 pour t au moins égal à $\max_{1 \leq i \leq n} x_i$

Pour une variable statistique *discrète*, cette fonction est une *fonction en escalier*, présentant en chacune des valeurs possibles x_i , un saut égal à la fréquence correspondante f_i (cf. figure 1.4).

Dans le cas d'une variable statistique *continue*, la fonction cumulative n'est connue que pour les valeurs de X égales aux extrémités des classes. L'hypothèse d'équirépartition (§ II.A.2) implique que la fonction F est linéaire entre ces valeurs (cf. figure 1.5). Cette fonction est donc continue et linéaire par morceaux. Ici encore, il est nécessaire de choisir des limites pour les classes extrêmes.

t	$F(t) (\%)$
< 1	0
$[1 ; 2[$	29,2
$[2 ; 3[$	61,0
$[3 ; 4[$	77,8
$[4 ; 5[$	92,0
≥ 5	100




Figure 1.4 – Graphe des fréquences cumulées de la distribution représentée à la figure 1.2

Ces fréquences cumulées sont des fréquences cumulées *ascendantes*, car elles ont été obtenues en calculant les fréquences F_i d'individus pour lesquelles le caractère étudié X est *au plus* égal à x_i ; on peut aussi définir les fré-

t	$F(t) (\%)$
0	0
1	16,8
3	35,8
6	50,9
12	68,7
24	87,2
36	94,2
60	100




Figure 1.5 – Courbe cumulative de la distribution représentée à la figure 1.3

quences cumulées *descendantes*, c'est-à-dire les fréquences pour lesquelles le caractère étudié X est supérieur à x_i . Quand on ne spécifie pas le type de fréquences cumulées, on sous-entend qu'il s'agit des fréquences cumulées ascendantes.

B. Le diagramme « branche et feuille »

Lorsque la taille de la population étudiée n'est pas trop élevée (inférieure à la centaine), il est intéressant d'utiliser la représentation en **diagramme « branche et feuille »** due à J. W. Tukey¹. Ce diagramme tient à la fois du *tableau* et de la *représentation graphique* et donne une vision d'ensemble des données *sans perdre* l'information numérique valeur par valeur.

1) Profondeur d'une observation

Selon qu'on range les valeurs observées de la variable statistique X de la plus faible à la plus élevée ou de la plus élevée à la plus faible, on associe à chaque observation x_i deux rangs, croissant et décroissant. On dit alors que la distribution est ordonnée.

On appelle **profondeur** de x_i le nombre égal au *plus petit des deux rangs*.

Les durées hebdomadaires du travail des salariés à temps complet dans les pays de l'Union européenne (cf. tableau 1.3) peuvent être ordonnées, et on en déduit la profondeur de chaque valeur de chacune des séries.

1. J. W. Tukey, *Exploratory Data Analysis* (EDA), Addison-Wesley, 1977.

Tableau 1.3 – Durée hebdomadaire du travail des salariés à temps complet dans l'Union européenne (heures)

	1990	1995	2000
Allemagne	39,9	39,7	40,1
Autriche	40,1	39,3	40,1
Belgique	38	38,4	38,5
Danemark	39	39	39,3
Espagne	40,7	40,7	40,6
Finlande	38,4	38,6	39,3
France	39,6	39,9	38,9
Grèce	40,2	40,3	40,9
Irlande	40,4	40,2	39,9
Italie	38,6	38,4	38,6
Luxembourg	39,9	39,5	39,8
Pays-Bas	39	39,5	39
Portugal	41,9	41,2	40,3
Royaume-Uni	43,7	43,9	43,6
Suède	40,7	40	40

Source : Tableaux de l'Économie Française, INSEE.

Le nombre de pays étant impair et égal à 15, il y a deux valeurs de profondeur 1, 2, 3, 4, 5, 6, 7 et une seule valeur de profondeur 8 (cf. tableau 1.4).

Tableau 1.4 – Pays ordonnés selon la durée hebdomadaire du travail des salariés à temps complet en 2000

Rang croissant	Rang décroissant	Profondeur	Durée (heures)	Pays
1	15	1	38,5	Belgique
2	14	2	38,6	Italie
3	13	3	38,9	France
4	12	4	39,0	Pays-Bas
5	11	5	39,3	Danemark
6	10	6	39,3	Finlande
7	9	7	39,8	Luxembourg
8	8	8	39,9	Irlande
9	7	7	40,0	Suède
10	6	6	40,1	Allemagne
11	5	5	40,1	Autriche
12	4	4	40,3	Portugal
13	3	3	40,6	Espagne
14	2	2	40,9	Grèce
15	1	1	43,6	Royaume-Uni

2) La représentation en diagramme « branche et feuille »

Son principe consiste à distinguer deux parties pour tout nombre : les chiffres de plus « faible poids », la *feuille*, et les chiffres de plus « haut poids », la *branche*.

La figure 1.6 reproduit les *diagrammes* « Branche et feuille » donnés par le logiciel SPSS pour les séries du tableau 1.3.

1990 Frequency Stem & Leaf	1995 Frequency Stem & Leaf	2000 Frequency Stem & Leaf
3,00 38 . 046	3,00 38 . 446	0,00 38 .
5,00 39 . 00699	6,00 39 . 035579	3,00 38 . 569
5,00 40 . 12477	4,00 40 . 0237	3,00 39 . 033
1,00 41 . 9	1,00 41 . 2	2,00 39 . 89
1,00 Extrêmes (>=43,7)	1,00 Extrêmes (>=43,9)	4,00 40 . 0113
		2,00 40 . 69
		1,00 Extrêmes (>=43,6)
Stem width : 1,0	Stem width : 1,0	Stem width : 1,0
Each leaf : 1 case(s)	Each leaf : 1 case(s)	Each leaf : 1 case(s)

Figure 1.6 – « Branche et feuille » (logiciel SPSS) pour les séries du tableau 1.3

Par exemple, pour le diagramme de l’année 1995 de la figure 1.6, en se référant aux valeurs ordonnées :

- la valeur 38,4 est représentée par la branche 38 et la feuille 4 (pour les deux observations) ;
- la valeur 38,6 est représentée par la branche 38 et la feuille 6.

Ces trois observations conduisent à l’écriture : 3,00 38. 446

La valeur 43,9 est beaucoup plus élevée que les autres ; elle est mentionnée comme valeur « *extrême* ». On verra comment une valeur est ainsi classée (§ IV.B). Le nombre de feuilles de chaque branche donnant l’effectif, un histogramme à classes égales d’amplitude 1 donne une représentation similaire, mais l’avantage du diagramme branche et feuille est de conserver ici l’information donnée par le premier chiffre décimal, donc de garder l’information de la répartition à l’intérieur des classes.

Les logiciels choisissent, selon la structure des données, des « amplitudes » égales à 1, 0,5 ou 0,25. La plage des valeurs étant plus restreinte en 2000 qu’en 1990 et 1995, le logiciel SPSS a choisi des amplitudes égales à 1 pour les années 1990 et 1995, et des amplitudes égales à 0,5 pour l’année 2000.

On peut compléter ce type de diagramme pour garder l’identité des individus en indiquant symétriquement l’identité de chaque feuille (cf. figure 1.7). On pourrait aussi représenter *dos à dos* les distributions correspondant à deux années différentes pour suivre l’évolution de la durée hebdomadaire du travail.

Frequency		Stem & Leaf
	3,00	Fin It Bel 38 . 446
	6,00	Fr All P.Bas Lux Aut Dk 39 . 035579
	4,00	Esp Gr Irl Suèd 40 . 0237
	1,00	Por 41. 2
	1,00	R-U Extremes (> = 43,9)
Stem width : 1,0		
Each leaf : 1 case(s)		

Figure 1.7 – Diagramme « Branche et feuille » complété par l'identité des pays (1995)

III. Les indicateurs statistiques

Le tableau de distribution d'une variable statistique présente l'information recueillie sur cette variable. Une représentation graphique en fournit un portrait pour appréhender plus facilement la globalité de l'information. On peut désirer aller plus loin en cherchant à caractériser la représentation visuelle par des éléments synthétiques sur :

- la valeur de la variable située au « centre » de la distribution : la *tendance centrale* et, plus généralement, un *indicateur de position* non nécessairement centrale, liée à un rang donné ;
- la variation des valeurs : la *dispersion* ;
- la *forme* de la distribution ;
- les aspects particuliers : valeurs *extrêmes*, *groupes* de valeurs...

Ces indicateurs étant exprimés dans les unités de la variable étudiée, on verra qu'il peut être intéressant pour comparer plusieurs distributions entre elles de calculer des *caractéristiques de dispersion relative*.

A. Conditions de Yule

Le statisticien britannique Yule ¹ a énoncé un certain nombre de *propriétés* souhaitées pour les indicateurs des séries statistiques ; ceux-ci doivent être d'une part, des résumés « maniables » et d'autre part, les plus exhaustifs possibles relativement à l'information contenue dans les données.

1. G. Udny Yule et M. G. Kendall, *An Introduction to the Theory of Statistics*, Charles Griffin & Co, 14^e édition, 1950.

Dans son schéma, une caractéristique statistique doit être une valeur-type :

1. définie de façon objective et donc indépendante de l'observateur ;
2. dépendante de toutes les observations ;
3. de signification concrète pour être comprise par des non-spécialistes ;
4. simple à calculer ;
5. peu sensible aux fluctuations d'échantillonnage ;
6. se prêtant aisément aux opérateurs mathématiques classiques.

En réalité, on ne dispose pas de caractéristiques répondant simultanément à ces six conditions. Le choix d'un indicateur sera l'objet d'un compromis guidé par la spécificité de l'étude en cours.

B. Les indicateurs de tendance centrale et de position

Selon l'usage courant, toutes les mesures de tendance centrale méritent le nom de « moyenne ». Lorsqu'on parle de moyenne, on pense à la moyenne arithmétique ; mais il existe d'autres types de moyennes, chacune d'entre elles ayant la propriété de *conserver une caractéristique* de l'ensemble quand on remplace chaque élément de l'ensemble par cette valeur unique ; chaque moyenne n'a donc d'intérêt que pour autant que cette propriété soit utile ¹.

Les « moyennes » sont des valeurs abstraites qui, sauf par hasard, ne correspondent à aucune réalisation concrète.

1) La moyenne arithmétique

On appelle *moyenne arithmétique* la somme de toutes les données statistiques divisée par le nombre de ces données. La moyenne arithmétique *conserve la somme totale des valeurs* observées : si on modifie les valeurs de deux observations d'une série statistique tout en conservant leur somme, la moyenne de la série sera inchangée.

Soit la série statistique de données brutes : $x_1, \dots, x_i, \dots, x_n$, sa moyenne arithmétique a pour expression :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Bien entendu, si une valeur x_i de X est observée n_i fois, comme $\underbrace{x_i + x_i + \dots + x_i}_{n_i \text{ fois}} = n_i x_i$, la formule précédente devient :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k n_i x_i = \sum_{i=1}^k f_i x_i$$

1. Ch. Antoine, « Les moyennes au quotidien », dans *Les Moyennes*, Que Sais-je, PUF, n° 3383, 1998, p. 107.

où k désigne le nombre de valeurs *distinctes* de X et $f_i = \frac{n_i}{n}$

Lorsqu'on a une variable statistique continue, on ne connaît pas les valeurs exactes prises par la variable, mais seulement le nombre d'observations à l'intérieur de chaque classe. Pour calculer la moyenne arithmétique d'une telle variable, on ramène *chaque observation au centre de sa classe*, ceci en raison de l'hypothèse d'équirépartition à l'intérieur des classes, et cela revient à considérer la moyenne des individus de la i^e classe égale à $(x_{i-1} + x_i)/2$.

Dans le cas des classes extrêmes non limitées, le choix des limites de ces classes influe évidemment sur la valeur de la moyenne arithmétique. Ces limites devront être choisies en fonction des connaissances sur les données et en n'oubliant pas l'hypothèse de base : l'homogénéité à l'intérieur des classes. Pour une classe extrême dans laquelle on sait qu'il n'y a pas équirépartition, les observations étant vraisemblablement en majorité regroupées sur une partie de la classe, il conviendra de choisir la borne extrême :

- moins faible que la borne réelle (supposée) s'il s'agit de la première classe ;
- plus faible que la borne réelle (supposée) s'il s'agit de la dernière classe.

C'est ce qui a été fait pour la série présentée au tableau 1.2 et à la figure 1.3, l'ancienneté moyenne du chômage a été considérée égale à 48 mois pour ceux dont l'ancienneté était au moins égale à 36 mois et la borne supérieure de la dernière classe a été de ce fait fixée à 60 mois (l'hypothèse d'équirépartition amène à considérer que la moyenne des observations d'une classe est égale au centre de la classe).

Propriétés

1. La moyenne est une caractéristique qui satisfait à toutes les conditions de Yule, sauf à la conditions 5 : une observation « extrême » (exceptionnellement élevée ou faible) peut avoir une forte incidence sur sa valeur.

2. La somme algébrique des écarts des valeurs d'une variable statistique à sa moyenne arithmétique est nulle :

$$\sum_{i=1}^k f_i (x_i - \bar{x}) = 0$$

3. Lorsqu'on fait subir à une variable statistique X une transformation affine, c'est-à-dire un changement d'origine et d'unité $\{ Y = aX + x_0 \}$, sa moyenne arithmétique subit la même transformation : $\bar{y} = a\bar{x} + x_0$

4. Soit une population $\mathbb{P}$ de taille n partagée en deux sous-populations $\mathbb{P}_1$ de taille n_1 et $\mathbb{P}_2$ de taille n_2 .

Soit X , une variable statistique observée sur la population $\mathbb{P}$, on peut exprimer sa moyenne $\bar{x}$ en fonction de ses moyennes $\bar{x}_1$ sur $\mathbb{P}_1$ et $\bar{x}_2$ sur

$\mathbb{P}_2$ en remarquant que la somme totale $n\bar{x}$ s'obtient en additionnant $n_1\bar{x}_1$ et $n_2\bar{x}_2$:

$$\bar{x} = \frac{1}{n}(n_1\bar{x}_1 + n_2\bar{x}_2)$$

Ce résultat se généralise à une partition en k sous-populations ($k \geq 2$) :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k n_i \bar{x}_i$$

► Exemple

L'ancienneté moyenne d'inscription au chômage pour hommes et femmes réunis en septembre 2006 est égale à (cf. tableau 1.2 pour les données) :

$$\bar{x} = \frac{1}{2\,172,2} (1\,094,5 \cdot 341 + 1\,077,7 \cdot 334) \approx 338 \text{ jours}$$

2) D'autres moyennes

a) La moyenne géométrique

C'est la moyenne applicable à des mesures de grandeurs dont la croissance est géométrique ou exponentielle.

La *moyenne géométrique conserve le produit des x_i* : si on modifie les valeurs de deux observations tout en conservant leur produit, la moyenne géométrique sera inchangée.

La moyenne géométrique G de la série de valeurs $x_1, \dots, x_i, \dots, x_n$ supposées toutes positives (strictement), est définie ainsi :

$$G = \sqrt[n]{\prod_{i=1}^n x_i} \Rightarrow \ln(G) = \frac{1}{n} \sum_{i=1}^n \ln(x_i)$$

Lorsque la distribution de la variable statistique est donnée par les k couples (x_i, n_i) , les x_i étant tous positifs ; la moyenne géométrique a pour expression :

$$G = \sqrt[n]{\prod_{i=1}^k x_i^{n_i}} = \prod_{i=1}^k x_i^{f_i} \Rightarrow \ln(G) = \sum_{i=1}^k f_i \ln(x_i)$$

► Exemple

Supposons que pendant une décennie, les salaires aient été multipliés par 2 et que pendant la décennie suivante, ils aient été multipliés par 4 ; le coefficient multiplicateur moyen par décennie est égal à :

$$\sqrt{2 \cdot 4} = \sqrt{8} \approx 2,83$$

La moyenne arithmétique (= 3) n'est pas égale au coefficient demandé.

Prenons, par exemple, un salaire de 300 € au début de la première décennie, il sera de $300 \cdot 2 \cdot 4 = 2\,400$ € au bout des vingt ans, ce qui équivaut à $300 \cdot (2,83)^2$, soit un coefficient multiplicateur moyen de 2,83 par décennie.

b) La moyenne harmonique

La *moyenne harmonique* est l'inverse de la moyenne arithmétique des inverses des valeurs. L'*inverse de la moyenne harmonique conserve ainsi la somme des inverses des x_i* : si on modifie les valeurs de deux observations tout en conservant la somme de leurs inverses, la moyenne harmonique sera inchangée.

$$H = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}} \quad \text{ou} \quad H = \frac{1}{\sum_{i=1}^k \frac{f_i}{x_i}}$$

La moyenne harmonique peut être utilisée lorsqu'il est possible d'attribuer un sens réel aux inverses des données en particulier pour les taux de change, les taux d'équipement, le pouvoir d'achat, les vitesses. Elle est notamment utilisée dans les calculs d'*indices*.

► Exemple

On achète des dollars une première fois pour 100€ au cours de 1,23 € le dollar, une seconde fois pour 100 € au cours de 0,97 € le dollar.

Le cours moyen du dollar pour l'ensemble de ces deux opérations est égal à :

$$\frac{200}{\frac{100}{1,23} + \frac{100}{0,97}} \approx 1,085 \text{ €}$$

La moyenne arithmétique (= 1,1) ne représente pas le cours moyen du dollar.

Comparaison des 3 moyennes étudiées

On montre que si les x_i sont tous positifs :

$$\min_{1 \leq i \leq n} x_i \leq H \leq G \leq \bar{x} \leq \max_{1 \leq i \leq n} x_i$$

L'égalité de deux de ces moyennes entre elles entraîne leur égalité dans leur ensemble, et dans ce cas, toutes les valeurs x_i sont égales.

3) Le mode

Pour obtenir une mesure de la tendance centrale non influencée par les valeurs extrêmes de la distribution, on peut prendre la valeur – ou la classe de valeurs – du caractère pour laquelle le diagramme en bâtons – respectivement l'histogramme – présente son *maximum* : c'est le *mode* – respectivement l'*intervalle modal* – de la distribution ; dans le cas où le diagramme en bâtons – ou l'histogramme – présente aussi un maximum local, il y a deux modes – respectivement deux classes modales.

Lorsque la variable statistique est discrète, le mode se définit donc à l'aide du tableau de distribution ou du diagramme en bâtons. Pour la distribution présentée à la figure 1.2, le mode est égal à 2. Si la fréquence maximum correspond à deux valeurs successives de la variable, il y a un *intervalle modal*.

Lorsqu'une distribution présente plusieurs modes auxquels correspondent (généralement) des fréquences différentes, c'est souvent l'indice du mélange de deux ou plusieurs populations ayant chacune leur mode propre (cf. figure 1.8). Un exemple peut en être la distribution des pointures de chaussures des hommes et femmes réunies.

Lorsque la variable statistique est continue, la *classe modale* est la classe dont la fréquence par unité d'amplitude est la plus élevée. Pour la distribution présentée à la figure 1.3, la classe modale est la classe $[1, 3[$. Mais cette détermination n'est absolument pas précise, car elle dépend du découpage en classes retenu ; son intérêt est limité par cette imprécision.

Dans le cas d'une distribution discrète, le mode satisfait aux conditions 1, 3, 4 et 5 de Yule. Dans le cas de la distribution du nombre d'enfants par famille, le mode est réellement une valeur typique et paraît mieux correspondre à la réalité que la moyenne arithmétique qui est rarement un nombre entier et qui est sensiblement influencée par un nombre relativement petit de familles très nombreuses. À l'inverse de la moyenne arithmétique, le mode néglige délibérément la précision numérique au profit de la représentativité. Dans un tel cas, il est souvent souhaitable de disposer de ces deux mesures de la tendance centrale.

Le mode, historiquement l'un des premiers paramètres de position utilisés, est un peu moins employé aujourd'hui.




Figure 1.8 – Exemple de distribution bimodale d'une variable discrète

4) La médiane et les quantiles

Bien qu'homogènes dans leur composition, de nombreuses distributions présentent de très grands écarts entre les valeurs extrêmes de leurs éléments.

De plus, elles ont souvent un manque de symétrie prononcé, les éléments ayant tendance à s'agglomérer plus près d'un extrême que de l'autre. Les

distributions de salaires ou de revenus en donnent des exemples typiques . Il est évident que, dans de tels cas, nous avons besoin d'une mesure de la tendance centrale qui ne soit pas influencée par un nombre relativement petit de valeurs extrêmes se situant en « queue » de la distribution.

a) La médiane

La *médiane* est la valeur de la variable statistique telle qu'il y ait autant d'observations supérieures et d'observations inférieures à cette valeur. Elle partage la série statistique en deux parties d'égal effectif. Elle se détermine soit à partir de la série des valeurs ordonnées, soit à partir de la fonction cumulative (§ II.A.3).

Pour les *variables statistiques discrètes* , la médiane est déterminée à l'aide de la « profondeur ».

Dans le cas où la série comporte un nombre impair n d'observations, la médiane est égale à la valeur de profondeur maximum $(n + 1)/2$: pour la série des 15 valeurs du tableau 4, la médiane est égale à la valeur de profondeur 8, soit 39,9 h .

Dans le cas où la série comporte un nombre pair n d'observations, la médiane est la moyenne arithmétique des deux valeurs de profondeur $n/2$ et est ainsi définie comme la valeur de profondeur $(n + 1)/2$.

La *médiane* est ainsi dans tous les cas la valeur de **profondeur** $(n + 1)/2$.

Lorsque les données d'une variable statistique discrète sont classées, il n'existe généralement pas une valeur médiane Me pour laquelle la fonction cumulative vaut 50 %. Il faut dans ce cas utiliser d'autres valeurs typiques pour caractériser la tendance centrale de la série : ceci est le cas pour la distribution du nombre de personnes par ménage dont la fonction cumulative est représentée à la figure 1.4.

Pour les *variables statistiques continues* , la valeur médiane Me est telle que $F(Me) = 50\%$. On commence par chercher la *classe médiane* à l'aide des fréquences cumulées, la classe médiane $[x_{i-1}, x_i]$ étant telle que $F_{i-1} < 50\%$ et $F_i > 50\%$. La valeur de la médiane s'obtient ensuite par *interpolation linéaire* en raison de l'hypothèse d'équirépartition à l'intérieur des classes. Cette détermination peut se faire par le calcul ou graphiquement (cf. figure 1.9) :

$$\frac{Me - x_{i-1}}{x_i - x_{i-1}} = \frac{0,5 - F_{i-1}}{f_i} \Rightarrow Me = x_{i-1} + (x_i - x_{i-1}) \cdot \frac{0,5 - F_{i-1}}{f_i}$$

Pour la distribution de l'ancienneté du chômage des femmes (tableau 1.2 et figure 1.5), la médiane appartient à la classe $[3 ; 6]$:

$$Me = 3 + 3 \cdot \frac{50 - 35,8}{15,1} \approx 5,8 \text{ mois}$$




Figure 1.9 – Détermination graphique de la médiane pour une variable continue

La médiane peut aussi être déterminée à partir de la courbe des fréquences cumulées comme l'abscisse du point d'ordonnée 50 %.

Une *seule* observation très élevée (ou très faible) peut influencer fortement la moyenne, alors que la médiane peut supporter sans être modifiée qu'une moitié des observations soit très élevée (ou très faible) : on dit que la médiane est *résistante*. La médiane satisfait aux conditions 1, 3, 4 et 5 de Yule.

Dans le cas de distribution unimodale, la médiane est fréquemment comprise entre la moyenne arithmétique et le mode, et plus près de la moyenne que du mode. Si la distribution est symétrique, ces *trois caractéristiques* de tendance centrale sont *confondues* (cf. figure 1.10).




Figure 1.10 – Positions respectives du mode, de la médiane et de la moyenne

b) Les quantiles

Les *quantiles* sont des *indicateurs de position*.

Le *quantile d'ordre* α ($0 \leq \alpha \leq 1$), noté x_α , est tel qu'une proportion α des individus ait une valeur du caractère X inférieure ou égale à x_α .

Le quantile $x_{0,5}$ est égal à la médiane.

On utilise couramment les quantiles d'ordre 1/4, 1/2 et 3/4. Ils sont ainsi notés et nommés :

$$Q_1 = \text{premier quartile} = x_{0,25}$$

$$Q_2 = \text{deuxième quartile} = \text{médiane} = x_{0,5}$$

$$Q_3 = \text{troisième quartile} = x_{0,75}$$

Les quartiles se déterminent, comme la médiane, à l'aide de la profondeur (variable discrète), ou à l'aide des fréquences cumulées (variable continue).

Dans le cas d'une variable statistique *discrète*, le premier quartile Q_1 et le troisième quartile Q_3 sont des éléments de *même profondeur égale à* $(m + 1)/2$ où m désigne la *partie entière* de la profondeur de la médiane. On peut aussi considérer Q_1 comme la médiane des m premières valeurs de la série et Q_3 comme la médiane des m dernières valeurs. Ainsi par exemple, pour une série de 39 observations, la médiane a une profondeur égale à 20, et les quartiles Q_1 et Q_3 sont de profondeur 10,5 ; pour une série de 50 observations, la médiane a une profondeur de 25,5 et la partie entière de cette profondeur étant 25, les quartiles Q_1 et Q_3 sont de profondeur 13.

La pratique de la détermination des quartiles ne respecte pas toujours la définition précédente due à Tukey. Ainsi les calculatrices de poche (TI, Casio,...) déterminent le 1^{er} quartile (resp. le 3^e quartile) comme la médiane des valeurs de profondeur inférieure (resp. supérieure) à la profondeur de la médiane. Le résultat diffère de celui calculé avec la définition de Tukey dans le cas d'un nombre impair d'observations. Le logiciel SPSS détermine deux types de quartiles : « Valeurs charnières » selon la définition de Tukey, et « Moyenne pondérée » à l'aide d'une formule d'interpolation linéaire [Dodge, 1993]. La détermination des premier et troisième quartiles n'est pas standardisée.

Pour la distribution de la durée hebdomadaire du travail dans les 15 pays de l'Union européenne en 2000 (cf. tableau 1.4), les premier et troisième quartiles sont les valeurs de profondeur 4,5 :

$$Q_1 = 39,15 \text{ h} \quad \text{et} \quad Q_3 = 40,2 \text{ h}$$

Dans le cas d'une variable statistique *continue*, on a $F(Q_1) = 0,25$ et $F(Q_3) = 0,75$ et on calcule les quartiles par *interpolation linéaire*, en raison de l'hypothèse d'équirépartition. Pour la distribution de l'ancienneté du chômage des femmes (cf. figure 1.5) :

$$Q_1 = 1 + 2 \cdot \frac{25 - 16,8}{19} \approx 1,9 \text{ mois}$$

$$Q_3 = 12 + 12 \cdot \frac{75 - 68,7}{18,5} \approx 16,1 \text{ mois}$$

On peut définir à partir des quartiles Q_1 et Q_3 le paramètre de tendance centrale $(Q_1 + Q_3)/2$, égal à la médiane dans le cas d'une distribution symétrique, ainsi que l'intervalle interquartile $[Q_1, Q_3]$ qui contient 50 % des observations.

Plus généralement, deux quantiles d'ordres complémentaires x_α et $x_{1-\alpha}$ définissent un intervalle dont le milieu peut être considéré comme un paramètre de tendance centrale.

De la même façon, on définit les *déciles* $D_1, D_2, \dots, D_9$ qui sont les quantiles $x_{i/10}$ ($i = 1$ à 9), les *vingtiles*, quantiles $x_{i/20}$ ($i = 1$ à 19), les *centiles*, etc.

Les classes d'une variable statistique continue sont souvent définies à l'aide des déciles. Dans ce cas, on a 10 classes contenant chacune 10 % de l'effectif total (cf. tableau 1.5 et figure 1.11).

Tableau 1.5 – Distribution des salaires annuels nets de tous prélèvements pour les salariés à temps complet du secteur privé et semi-public

Déciles* (en euros courants)	Ensemble		Hommes		Femmes	
	2000	2006	2000	2006	2000	2006
D_1	10 790	12 718	11 230	13 181	10 190	12 075
D_2	12 220	14 219	12 760	14 776	11 420	13 431
D_3	13 520	15 545	14 140	16 209	12 500	14 531
D_4	14 910	16 977	15 580	17 729	13 710	15 715
Médiane	16 500	18 631	17 270	19 466	15 130	17 141
D_6	18 410	20 685	19 330	21 657	16 810	18 924
D_7	20 890	23 430	22 170	24 734	18 850	21 300
D_8	24 780	27 826	26 660	29 787	21 620	24 590
D_9	32 810	36 941	35 020	40 305	26 950	30 962
D_9/D_1	3	2,9	3,2	3,1	2,6	2,6
<i>Salaire moyen</i>	20 400	23 292	21 890	24 912	17 510	20 232

* En 2006, 10 % des salariés à temps complet du secteur privé et semi-public gagnent un salaire annuel net inférieur à 12 718 euros, 20 % inférieur à 14 219 euros...

Source : INSEE.




Figure 1.11 – Histogramme de la distribution des salaires « Ensemble » en 2000 (voir tableau 1.5)

C. Les indicateurs de dispersion

1) L'étendue

L'*étendue* est la différence entre la plus grande et la plus petite des valeurs observées :

$$\text{Étendue} = \max_{1 \leq i \leq n} x_i - \min_{1 \leq i \leq n} x_i$$

Cette mesure de la dispersion ne dépend que des *valeurs extrêmes* souvent exceptionnelles ; elle ne satisfait pas aux conditions 2 et 5 de Yule. Il faut remarquer aussi que la forme de la distribution entre les valeurs extrêmes n'influe pas sur l'étendue. Cependant, cette caractéristique, étant facile à calculer et ayant une signification concrète facile à comprendre, est fréquemment utilisée en contrôle industriel de fabrication.

2) L'étendue interquartile

De par la définition des quartiles, l'intervalle interquartile $[Q_1, Q_3]$ contient 50 % des observations. Sa longueur, notée *EIQ* (Étendue InterQuartile), est un indicateur de dispersion :

$$EIQ = Q_3 - Q_1$$

Le calcul de l'étendue interquartile a l'avantage par rapport à celui de l'étendue d'écarter les valeurs extrêmes, souvent sans signification.

Plus généralement, les longueurs des fourchettes définies par les déciles extrêmes, les centiles extrêmes constituent des indicateurs de dispersion contenant respectivement 80 % et 98 % des observations.

3) L'écart absolu moyen

On peut définir une caractéristique de dispersion d'une distribution statistique en calculant les écarts des observations à une tendance centrale C . La tendance centrale de la série ($x_i - C$) ne peut pas être une mesure de dispersion puisque les écarts positifs sont compensables par les écarts négatifs.

Par contre, la série $|x_i - C|$ définit une variable statistique positive dont les valeurs centrales constituent une mesure de dispersion.

L'écart absolu moyen à la médiane est la moyenne arithmétique des valeurs absolues des écarts à la médiane ; on démontre que c'est le plus petit écart absolu moyen :

$$e_{Me} = \frac{1}{n} \sum_{i=1}^n |x_i - Me| \quad \text{ou} \quad e_{Me} = \sum_{i=1}^k f_i |x_i - Me|$$

L'écart absolu moyen à la moyenne est la moyenne arithmétique des valeurs absolues des écarts à la moyenne arithmétique :

$$e_{\bar{x}} = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}| \quad \text{ou} \quad e_{\bar{x}} = \sum_{i=1}^k f_i |x_i - \bar{x}|$$

Dans le cas d'une variable continue classée, on considère, comme pour le calcul de la moyenne, que chaque individu a sa valeur égale au milieu de sa classe d'affectation.

4) L'écart-type

L'écart-type s_X d'une variable statistique X est la mesure de dispersion la plus couramment utilisée.

Algébriquement, il se définit comme la racine carrée de la variance, et la variance est la moyenne arithmétique des carrés des écarts à la moyenne arithmétique :

$$\text{var}(X) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \quad \text{ou} \quad \text{var}(X) = \sum_{i=1}^k f_i (x_i - \bar{x})^2 \Rightarrow s_X = \sqrt{\text{var}(X)}$$

Il est possible de développer la formule de la variance pour obtenir une expression mieux adaptée au calcul (mais cette formule devient inusitée de par la diffusion des calculatrices munies des fonctions statistiques ¹⁾ :

1. Les calculatrices munies des fonctions statistiques donnent les valeurs de la moyenne et de l'écart-type d'une variable statistique dont on a saisi la distribution. Certaines calculatrices (dont les calculatrices de marque CASIO®) proposent deux écarts-types : σ_n et σ_{n-1} . La valeur de σ_n correspond à celle de l'écart-type s_X défini ici et utilisé en statistique descriptive ; quant à celle de σ_{n-1} , elle est utilisée en inférence statistique et se déduit de σ_n par la formule

$$\text{suivante : } \sigma_{n-1}^2 = \frac{n}{n-1} \sigma_n^2$$

$$\text{var}(X) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - (\bar{x})^2$$

$$\text{ou } \text{var}(X) = \sum_{i=1}^k f_i (x_i - \bar{x})^2 = \sum_{i=1}^k f_i x_i^2 - (\bar{x})^2$$

Dans le cas d'une variable statistique continue, on ramène la valeur de chaque individu au milieu de sa classe d'affectation. Là encore, le choix des bornes des classes extrêmes non limitées doit être fait avec précaution.

Mais, alors que pour le calcul de la moyenne, l'erreur liée à ce choix était faible dans le cas de distributions approximativement symétriques autour de la moyenne, il n'en est pas de même pour le calcul de la variance où les erreurs s'ajoutent et ne peuvent pas se compenser.

L'écart-type est exprimé dans la *même unité* que les observations, alors que la variance s'exprime dans le carré de cette unité.

On démontre que l'écart-type, donnant plus de poids aux observations extrêmes que l'écart absolu moyen à la moyenne, lui est toujours supérieur : $s_X \geq e_{\bar{x}}$

Propriétés

1. L'écart-type satisfait aux conditions 1, 2 et 6 de Yule ; l'écart-type est plus *sensible* aux fluctuations d'échantillonnage et aux valeurs extrêmes que la moyenne, en raison des élévations au carré.

2. On montre que la variance est le plus petit écart quadratique moyen, c'est-à-dire :

$$\text{var}(X) \leq \frac{1}{n} \sum_{i=1}^n (x_i - C)^2 \text{ pour tout } C$$

3. Lorsque deux variables X et Y sont en correspondance par le changement d'origine x_0 et le changement d'échelle a , les écart-types se correspondent par le seul changement d'échelle a pris en valeur absolue :

$$Y = aX + x_0 \Rightarrow s_Y = |a|s_X$$

4. Soit une population $\mathbb{P}$ de taille n composée de deux sous-populations $\mathbb{P}_1$ de taille n_1 et $\mathbb{P}_2$ de taille n_2 . Soit X , une variable statistique observée sur la population $\mathbb{P}$, on peut exprimer sa variance $\text{var}(X)$ en fonction de $\bar{x}$, $\bar{x}_1$, $\bar{x}_2$, $\text{var}(X_1)$ et $\text{var}(X_2)$:

$$\text{var}(X) = \frac{1}{n} \left(n_1 \text{var}(X_1) + n_2 \text{var}(X_2) + n_1 (\bar{x}_1 - \bar{x})^2 + n_2 (\bar{x}_2 - \bar{x})^2 \right)$$

Il faut bien remarquer que la variance de X sur $\mathbb{P}$ est la somme pondérée des variances de X sur $\mathbb{P}_1$ et $\mathbb{P}_2$ augmentée de la somme pondérée des carrés des différences entre la moyenne de X sur $\mathbb{P}$ et les moyennes sur $\mathbb{P}_1$ et $\mathbb{P}_2$. Ce résultat se généralise à une partition en k sous-populations ($k \geq 2$).

5. Les distributions statistiques symétriques telles qu'environ :

- 2/3 de la distribution se situent à moins d'un écart-type de $\bar{x}$;
- 95 % de la distribution se situent à moins de deux écarts-types de $\bar{x}$ sont dites normales (chapitre 7, § II).

Le *triplet* $(n, \bar{x}, s_x)$ est un *résumé exhaustif* des distributions de ce type. Dans de nombreux cas, la normalité étant approximative, $(n, \bar{x}, s_x)$ est alors un résumé (quasi-exhaustif) qui présente un intérêt primordial.

D'autres mesures de la dispersion peuvent être envisagées. On peut calculer un *écart médian*, égal à la médiane de la série des valeurs absolues des écarts à une valeur centrale choisie. On peut aussi calculer la *différence moyenne* égale à la moyenne arithmétique des valeurs absolues des différences entre les observations prises deux à deux. C'est cet indicateur de dispersion qui est utilisé pour le calcul de l'indice de concentration de Gini (§ III.E) et qui, ne mesurant pas la dispersion par rapport à la moyenne, est adapté aux distributions non symétriques.

D. Les caractéristiques de forme

La plupart des distributions statistiques sont unimodales. En complément de l'étude de la tendance centrale et de la dispersion, il est intéressant de repérer la forme (déjà mise en évidence par une représentation graphique) par des mesures de son *asymétrie* (en anglais, *skewness*) et de son *aplatissement* (*kurtosis*).

La symétrie est un concept important pour plusieurs raisons. Tout d'abord, la définition de la tendance centrale est sans ambiguïté pour une distribution symétrique puisque pour une telle distribution, la médiane est égale à la moyenne et à $(x_\alpha + x_{1-\alpha})/2$ pour tout α compris entre 0 et 0,5, et la dispersion des observations est symétrique par rapport à la moyenne. D'autre part, de nombreuses méthodes statistiques reposent sur une hypothèse de distribution(s) normale(s) ou s'en approchant (chapitre 7). Le caractère de symétrie d'une distribution apparaît donc particulièrement important.

Les mesures de la forme sont indépendantes des unités de mesure de la variable étudiée.

1) Définition des moments centrés

Le *moment centré* d'ordre r d'une distribution est égal à la moyenne arithmétique des puissances d'ordre r des écarts $(x_i - \bar{x})$:

$$\mu_r = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^r \quad \text{ou} \quad \mu_r = \sum_{i=1}^k f_i (x_i - \bar{x})^r$$

→ Remarque

Le moment centré μ_1 est nul, et le moment centré μ_2 n'est autre que la variance et ne peut être nul, comme tous les moments centrés d'ordre pair, que si toutes les observations ont la même valeur.

2) L'asymétrie

Pour une distribution symétrique, la moyenne arithmétique est égale à la médiane et à $(x_\alpha + x_{1-\alpha})/2$ pour α compris entre 0 et 0,5. D'autre part, les moments centrés d'ordre impair sont nuls pour une distribution symétrique, négatifs pour une distribution unimodale étalée à gauche, positifs pour une distribution unimodale étalée à droite. Ces propriétés sont utilisées pour diagnostiquer et mesurer l'asymétrie.

a) Diagnostic et mesure de l'asymétrie à l'aide des quantiles

Dans un cas d'asymétrie, la *comparaison des quantités* $(x_\alpha + x_{1-\alpha})/2$, milieux des intervalles $[x_\alpha, x_{1-\alpha}]$, pour différentes valeurs de α ($0 \leq \alpha \leq 0,5$) donne une indication rapide sur le type de l'asymétrie. Certains logiciels donnent la représentation graphique de ces quantités en fonction des amplitudes $(x_{1-\alpha} - x_\alpha)$. Pour une distribution symétrique, on obtient une droite parallèle à l'axe des abscisses puisque les termes $(x_\alpha + x_{1-\alpha})/2$ sont tous égaux à la médiane (et à la moyenne !).

Pour la distribution des salariés masculins en 2000 (cf. tableau 1.5), la comparaison des milieux des intervalles des déciles symétriques par rapport à la médiane montre qu'il s'agit d'une distribution étalée vers la droite :

$$D_5 = 17270 < \frac{D_6 + D_4}{2} = 17455 < \frac{D_7 + D_3}{2} = 18155 < \frac{D_8 + D_2}{2} = 19710 < \frac{D_9 + D_1}{2} = 23125$$

Le quotient suivant définit un coefficient d'asymétrie, appelé coefficient de Yule et Kendall :

$$\frac{(Q_3 - Q_2) - (Q_2 - Q_1)}{(Q_3 - Q_2) + (Q_2 - Q_1)} = \frac{Q_3 + Q_1 - 2Q_2}{Q_3 - Q_1}$$

Ce coefficient, compris entre -1 et $+1$, est nul pour une distribution symétrique, positif pour une distribution unimodale étalée vers la droite et négatif dans le cas contraire, et il est, de plus invariant par changement d'origine et d'échelle.

On obtient des variantes de ce coefficient en remplaçant les quartiles par les déciles. Pour les distributions des salaires présentées dans le tableau 1.5, on peut calculer le coefficient d'asymétrie suivant :

$$\frac{D_9 + D_1 - 2D_5}{D_9 - D_1}$$

qui vaut respectivement 0,49 et 0,41 pour les distributions des salaires masculins et féminins en 2000 ; ces valeurs indiquent des distributions asymétriques, étalées vers la droite.

b) Le coefficient d'asymétrie de Fisher

Le coefficient d'asymétrie de Fisher, noté γ_1 , est ainsi défini :

$$\gamma_1 = \frac{\mu_3}{\mu_2^{3/2}} \quad \text{pour} \quad \mu_2 \neq 0$$

Comme tout coefficient d'asymétrie, il est *nul* pour une distribution *symétrique*, négatif pour une distribution unimodale étalée vers la gauche, positif pour une distribution unimodale étalée vers la droite (figure 1.12).




Figure 1.12 – Signe du coefficient d'asymétrie

Les coefficients calculés par les logiciels statistiques sont soit celui de Fisher, soit des variantes de même l'interprétation. Par exemple, le logiciel SPSS donne un coefficient d'asymétrie légèrement modifié :

$$\frac{n}{(n-1) \cdot (n-2)} \gamma_1 \quad \text{pour} \quad n \geq 3$$

3) L'aplatissement

Les coefficients d'aplatissement mesurent l'aplatissement d'une distribution ou l'importance des « queues » d'une distribution. Le coefficient d'aplatissement de Fisher, noté γ_2 , est ainsi défini :

$$\gamma_2 = \frac{\mu_4}{\mu_2^2} - 3 \quad \text{pour} \quad \mu_2 \neq 0$$

Ce coefficient est *nul* pour une *distribution normale* (chapitre 7), positif ou négatif selon que la distribution est plus ou moins aplatie que la distribution normale de même moyenne et de même écart-type.

Les coefficients calculés par les logiciels sont celui de Fisher ou des variantes de même interprétation.

Ces coefficients d'asymétrie et d'aplatissement sont invariants par changement d'origine et d'échelle, mais ils sont sensibles aux fluctuations d'échantillonnage puisqu'ils font intervenir des moments d'ordre élevé.

E. Les caractéristiques de dispersion relative

Ces caractéristiques permettent de *comparer* les distributions statistiques de plusieurs sous-ensembles d'une même population, ou de faire des comparaisons dans le temps ou dans l'espace.

1) Le coefficient de variation et l'interquartile relatif

Supposons que nous sachions que l'écart-type de poids d'une certaine population est de 8 kg, l'importance du degré de variabilité que cela suggère dépend de la valeur du poids moyen : 10 kg, 50 kg ou plusieurs centaines de kg...

Pour remédier à cette difficulté d'interprétation, il est naturel d'examiner le rapport $s_x/\bar{x}$ appelé *coefficient de variation* et défini en général pour des variables *positives*.

C'est un nombre *sans dimension*, invariant si on effectue un changement d'unité de mesure.

Plus le coefficient de variation est élevé, plus la dispersion autour de la moyenne est élevée.

Ce coefficient permet de comparer les dispersions de distributions qui ne sont pas exprimées dans la même unité (comme des distributions de salaires de pays différents) ou de distributions dont les moyennes sont différentes (comme des distributions de salaires pour différentes qualifications).

On peut construire d'autres coefficients de ce type en utilisant les statistiques d'ordre comme les quartiles et les déciles ; citons l' *interquartile*

relatif : $\frac{Q_3 - Q_1}{Q_2}$ et l' *interdécile relatif* : $\frac{D_9 - D_1}{D_5}$

Pour les distributions des salaires « Hommes » et « Femmes » en 2001 (cf. tableau 1.5), les interdéciles relatifs valent respectivement 1,45 et 1,12.

2) Les caractéristiques de concentration

La notion de *concentration* a été introduite à propos des distributions de salaires et de revenus. Cette notion est apparentée à celle de dispersion puisqu'elle concerne l'intensité du groupement des données.

Elle ne s'applique qu'à des variables *continues* à valeurs *positives*, et pour des ensembles statistiques dont chaque élément est affecté d'un caractère susceptible d'addition :

- un ensemble de ménages classés selon le revenu, l'épargne, le patrimoine... ;
- un ensemble d'entreprises classées selon le chiffre d'affaire, le nombre de salariés, les montants des factures... ;
- un ensemble d'exploitations agricoles classées selon la surface agricole utilisée.

Il est clair que la notion de concentration ne peut pas s'appliquer, par exemple, à des ensembles d'individus classés selon l'âge, la taille ou le poids, puisque la somme des âges, des tailles ou des poids d'une population est sans signification.

La concentration peut se caractériser, soit par un *procédé graphique*, soit par le *calcul*.

a) Construction de la courbe de concentration

Considérons la distribution des exploitations agricoles par classes de grandeurs des régions Provence-Alpes-Côte d'Azur (PACA) et Midi-Pyrénées en 2005 (cf. tableau 1.6). L'intervalle de variation de la SAU (superficie agricole utilisée) est partagé en k classes (ici, $k = 9$) dont les bornes supérieures sont notées dans l'ordre : $x_1, \dots, x_i, \dots, x_k$

On calcule pour chaque classe ($i = 1$ à k) :

- la *proportion cumulée* p_i des exploitations de SAU inférieure à x_i
- la *proportion cumulée* q_i de la SAU totale des exploitations de SAU inférieure à x_i

Sur un diagramme cartésien, on représente les k points de coordonnées (p_i, q_i) . Ces points s'inscrivent dans un carré OABC dont la longueur des côtés est égale à 1 (ou 100 si les proportions sont exprimées en pourcentage).

La courbe qui joint les points successifs est la *courbe de concentration* ou *courbe de Lorenz* (cf. figure 1.13). La courbe, toujours en-dessous de la bissectrice, permet de lire que les α % des exploitations les moins bien loties cultivent β % de la SAU totale. Si toutes les exploitations ont une part égale de SAU, la courbe se confond avec la bissectrice OB. La courbe s'éloigne lorsque l'inégalité s'accroît.

Tableau 1.6 – Distribution des exploitations agricoles par classes de grandeurs en régions PACA et Midi-Pyrénées

	Midi-Pyrénées		PACA		Midi-Pyrénées		PACA	
	f_i	Proportion SAU	f_i	Proportion SAU	p_i	q_i	p_i	q_i
Moins de 5 ha	15,5	0,8	44,9	2,6	15,5	0,8	44,9	2,6
5 à moins de 10 ha	9,0	1,4	12,5	3,1	24,6	2,2	57,4	5,7
10 à moins de 20 ha	13,2	4,2	14,8	7,6	37,7	6,4	72,2	13,2
20 à moins de 35 ha	15,7	9,2	9,3	8,6	53,4	15,7	81,5	21,9
35 à moins de 50 ha	12,2	11,1	5,1	7,4	65,6	26,8	86,6	29,3
50 à moins de 100 ha	23,1	35,1	7,2	17,6	88,7	61,9	93,8	46,9
100 à moins de 200 ha	9,6	27,5	3,7	18,1	98,2	89,4	97,5	65,0
200 à moins de 300 ha	1,3	6,6	1,4	11,5	99,5	96,0	98,9	76,5
300 ha ou plus	0,5	4,0	1,1	23,5	100	100	100	100
	100	100	100	100				

Source : agreste.agriculture.gouv.fr

Ceci suggère d'utiliser l'aire, dite *aire de concentration*, comprise entre la courbe et la bissectrice OB comme indicateur d'inégalité.




Figure 1.13 – Courbe de Lorenz





Figure 1.14 – Courbes de concentration des SAU dans les régions PACA et Midi-Pyrénées

On peut *comparer* la concentration de deux ou plusieurs populations selon un même caractère en représentant sur un même graphique leurs courbes de Lorenz. Les terres agricoles sont plus concentrées dans la région PACA que dans la région Midi-Pyrénées puisque la courbe de Lorenz de la SAU de la région Midi-Pyrénées est incluse dans celle de la région PACA (cf. figure 1.14).

On peut aussi comparer la concentration de deux caractères sur une même population : sur la figure 1.15, on constate que la concentration du patrimoine financier des ménages est plus forte que celle des revenus.

Dans les cas où les courbes se coupent, on ne peut pas comparer les degrés d'inégalité.



Lecture : plus la courbe s'éloigne de la diagonale, plus la distribution de la variable considérée est concentrée. La moitié des ménages les moins riches possède 27 % de la masse des revenus disponibles tandis que la moitié des ménages les moins bien dotés possède environ 4 % de la masse totale de patrimoine financier. Les 10 % les mieux dotés en patrimoine financier en possèdent environ 63 %.

Champ : ménages dont la personne de référence n'est pas étudiante et dont le revenu déclaré est positif ou nul.
Sources : enquête Revenus fiscaux 2003, Insee-DGI pour le revenu disponible et enquête Patrimoine 2004, Insee, montants de patrimoine financier recalés sur les données de la Comptabilité nationale.

Source : INSEE, Économie et Statistique, n° 414, 2008.

Figure 1.15 – Courbes de concentration

b) Détermination de l'indice de concentration ou indice de Gini

L'indice I_G de Gini est égal au double de l'aire de concentration (cf. figure 1.13). Cet indice, compris entre 0 et 1, a une valeur d'autant plus élevée que la répartition est plus inégalitaire, et peut être évalué selon la formule ¹ :

$$I_G = \frac{\sum_{i=1}^n \sum_{j=i+1}^n |x_i - x_j|}{n(n-1) \cdot \bar{x}}$$

les x_i ($i = 1, \dots, n$) désignant ici les valeurs prises (supposées toutes distinctes) par la variable sur chacun des n individus de la population étudiée.

1. Le statisticien italien Corrado Gini a proposé cette mesure de la concentration en 1912 et a montré deux années plus tard que son indice était égal au double de l'aire comprise entre la droite d'équirépartition et la courbe proposée par Max Otto Lorenz en 1905.

Cet indice s'apparente donc bien à la notion de dispersion relative des éléments d'une série. C'est un *nombre sans dimension*. Cette caractéristique de dispersion ne fait pas appel au calcul d'écarts à la moyenne. Elle est ainsi particulièrement *bien adaptée à l'étude de distributions très dissymétriques pour lesquelles la notion d'écart à la moyenne est sans grande signification*.

IV. La boîte de distribution

La **boîte de distribution** (*box-plot* en anglais, ou encore « *boîte-à-pattes* », « *boîte à moustaches* », « *boîte de dispersion* » en français) est un outil privilégié de l' *analyse exploratoire des données* . Elle fournit en un seul coup d'oeil des informations sur sa tendance centrale, sa dispersion, son asymétrie, l'importance des valeurs extrêmes. Elle est aussi particulièrement intéressante pour la comparaison de distributions sur plusieurs de ces critères.

A. Résumé d'une distribution par des quantiles

Les *trois quartiles* Q_1 , Q_2 et Q_3 et les *deux valeurs extrêmes* fournissent pour une distribution des informations sur sa *tendance centrale* par les quantités Q_2 , $\frac{1}{2}(Q_1 + Q_3)$ et $\frac{1}{2} \left(\min_{1 \leq i \leq n} x_i + \max_{1 \leq i \leq n} x_i \right)$, sur sa *dispersion* par l'étendue et

l'étendue interquartile, et sur sa *forme* par la comparaison des trois indicateurs de tendance centrale.

En analyse exploratoire des données, ces cinq valeurs sont présentés avec leur profondeur dans un tableau. Pour la distribution de la durée hebdomadaire du travail en 2000 (cf. tableau 1.4) :

$n = 15$	Durée hebdomadaire	
8	$Me = 39,9 \text{ h}$	
4,5	$Q_1 = 39,15$	$Q_3 = 40,2$
1	$\min_{1 \leq i \leq n} x_i = 38,5$	$\max_{1 \leq i \leq n} x_i = 43,6$

On peut compléter ce tableau en indiquant l'étendue interquartile, le milieu de l'intervalle interquartile, l'étendue et le milieu de l'intervalle déterminé par les deux valeurs extrêmes. On obtient ainsi un résumé des informations sur la dispersion et l'asymétrie :

$n = 15$	Durée hebdomadaire		Dispersion	Position
8	39,9 h			
4,5	39,15	40,2	$EIQ = 1,05$	$\frac{1}{2}(Q_1 + Q_3) = 39,615$
1	38,5	43,6	$\acute{E}tendue = 5,1$	$\frac{1}{2} \left(\min_{1 \leq i \leq n} x_i + \max_{1 \leq i \leq n} x_i \right) = 41,05$

B. Représentation d'une boîte de distribution

Dans une *boîte de distribution*, la boîte représente l'intervalle interquartile, et à l'intérieur, la médiane la sépare en deux parties. Les lignes qui partent du bord de la boîte s'étendent jusqu'aux valeurs les plus extrêmes qui ne sont pas considérées comme éloignées. Le logiciel SPSS note « valeur éloignée » (o), les points situés à plus de 1,5 fois l'étendue interquartile par rapport aux bords de la boîte, et « valeur extrême » (*), les points situés à plus de 3 fois l'étendue interquartile (cf. figure 1.17).

Ainsi, la taille de la boîte représente l'étendue interquartile, la position de la médiane est un bon indicateur de la symétrie de la distribution, la taille des lignes de part et d'autre de la boîte traduit la dispersion, et les valeurs éloignées ou extrêmes sont immédiatement repérées.

On représente une *boîte de distribution* de la façon suivante (cf. figure 1.16) :

a) on trace un rectangle de largeur fixée à priori et de longueur $EIQ = (Q_3 - Q_1)$, et on y situe la médiane par un segment positionné à la valeur Q_2 , par rapport à Q_3 et Q_1 ; on a alors la *boîte*,

b) on calcule $(Q_3 + 1,5 \cdot EIQ)$ et $(Q_1 - 1,5 \cdot EIQ)$ et on cherche :

- la dernière observation x_h en deçà de la limite $(Q_3 + 1,5 \cdot EIQ)$ soit

$$x_h = \max \{ x_i \mid x_i \leq Q_3 + 1,5 \cdot EIQ \}$$

- la première observation x_b au delà de la limite $(Q_1 - 1,5 \cdot EIQ)$ soit

$$x_b = \min \{ x_i \mid x_i \geq Q_1 - 1,5 \cdot EIQ \}$$

c) on trace deux lignes allant des milieux des largeurs du rectangle aux valeurs x_b et x_h

Ainsi, pour la distribution représentée à la figure 1.16, la valeur « éloignée » associée au Royaume-Uni et mise en évidence sur le diagramme *Branche et feuille* de la figure 1.6, est à l'extérieur de la boîte de distribution.




Figure 1.16 – Construction de la boîte de distribution de la durée du travail en 2000 (tableau 1.4)

Ce type de diagramme permet aussi de *comparer* facilement plusieurs distributions en terme de médiane, quartiles et valeurs éloignées ou extrêmes.

On peut représenter en parallèle les boîtes de distribution de la durée hebdomadaire du travail des salariés à temps complet de l'Union européenne en 1990, 1995 et 2000, et comparer les trois distributions (cf. figure 1.17).




Figure 1.17 – Représentation SPSS des boîtes de distribution du tableau 1.3

La médiane n'évolue pas de façon monotone, la dispersion diminue, le Royaume-Uni passe de « valeur éloignée » en 1990 à « valeur extrême » en 1995 et 2000.

Pour les distributions présentées par leurs déciles (cf. tableau 1.5), on ne connaît pas les valeurs individuelles. Dans ce cas, on peut convenir de considérer *valeurs éloignées* les valeurs inférieures au premier décile ou supérieures au neuvième décile.

La représentation des boîtes de distribution des distributions de salaires en 2000 permet de comparer les salaires selon le sexe (cf. figure 1.18). La représentation par des histogrammes (cf. figure 1.11) ne permettrait pas de comparer aussi aisément les distributions, les histogrammes ne pouvant pas être superposés si on veut conserver la lisibilité, mais seulement juxtaposés.




Figure 1.18 – Représentation des boîtes de distribution des salaires en 2000

C. Interprétation d'une boîte de distribution

Une boîte de distribution rend compte de la tendance centrale, de la dispersion, des valeurs éloignées ou extrêmes et de la forme de la distribution (cf. figure 1.19), même si d'autres modes de représentation (histogramme, branche et feuille) peuvent apporter un complément d'information sur la forme.




Figure 1.19 – Quelques types de boîtes de distribution :

1. Distribution symétrique
2. Distribution peu dispersée
3. Distribution étalée vers les valeurs élevées
4. Distribution étalée vers les valeurs faibles

En statistique descriptive, on a vu l'importance du *triplet* (n , $\bar{x}$, s_x). Pour la distribution de la durée hebdomadaire du travail du tableau 1.4, ce triplet prend les valeurs (15 ; 39,93 ; 1,2) pour l'année 2000. La *boîte de distribution* (cf. figures 1.15 et 1.16) est un complément qui se révèle intéressant puisqu'elle permet de détecter l'asymétrie, les valeurs extrêmes, et de repérer la médiane et l'intervalle interquartile qui contient la moitié des observations.

Dans le cas d'une asymétrie, l'écart-type qui mesure la dispersion *symétriquement* par rapport à la moyenne n'est pas la mesure de dispersion la mieux adaptée, et peut être complété par l'étendue interquartile. D'autre part, si la boîte de distribution indique des valeurs éloignées ou extrêmes, on sait que la moyenne et l'écart-type sont particulièrement influencés par ces valeurs.

V. Bilan

Avant toute étude formelle, il est nécessaire de procéder à une évaluation descriptive des données. Cette approche descriptive présente deux difficultés, l'une liée aux calculs, l'autre à la diversité des indicateurs. Si les calculatrices de poche ont permis depuis longtemps déjà de rendre aisés les calculs de moyenne et écart-type, il a fallu attendre la généralisation des moyens de calcul

automatique (en particulier, des logiciels statistiques sur micro-ordinateurs) pour que tous les indicateurs basés sur la notion de profondeur, et en particulier la médiane, soient facilement accessibles. C'est aussi l'environnement récent des micro-ordinateurs qui a permis de développer les modes de représentation graphique par lesquels on peut appréhender des indicateurs très divers. L'approche descriptive des données trouve dans la représentation graphique un enrichissement et une aide à l'interprétation. Simplicité et interactivité de cette démarche en font une première étape maintenant indispensable à toute étude statistique.