

Probabilités et statistique

La statistique descriptive

Module 7

Plan

- Introduction
- Description numérique (mesures de tendance centrale et de dispersion)
- Mesures de position
- Diagramme en boîte
- Histogramme

1. Introduction

La statistique descriptive fournit des méthodes pour résumer l'information contenue dans un ensemble ou jeu de données.

Un échantillon est un sous-ensemble (de taille n) de la population.


Un échantillon aléatoire est un échantillon pigé au hasard dans la population, de telle sorte que tous les éléments ont la même chance d'être pigés.

Exemple : Voici un extrait d'un jeu de données

Numéro	Dossier	Nom	Âge	Poids	Taille	Couleur des yeux
1	05927	Demba	17	80	1.80	brun
2	13465	Julie	25	75	1.64	bleu
3	24790	Nadia	35	65	1.78	gris
⋮	⋮	⋮	⋮	⋮	⋮	⋮
n	00341	Salif	29	70	1.73	noir

Chaque ligne définit une observation et chaque colonne définit une variable.

Types de variables



2. Description numérique

A. Moyenne et variance

Données brutes :

Soit X , une variable quantitative et soient n observations de la variable X , notées $x_1, x_2, \dots, x_n$ avec x_i la valeur de X pour la $i^{\text{ème}}$ observation.

- Moyenne échantillonnale (mesure de position) :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- Variance échantillonnale (mesure de dispersion) :

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n \bar{x}^2 \right)$$

- Écart-type échantillonnal (mesure de dispersion) :

$$s = \sqrt{s^2}$$

Exemple :

Soient les observations suivantes :

x_1	x_2	x_3	x_4	x_5	x_6	x_7
3	7	5	12	9	7	4

Ainsi, nous avons :

$$\bar{x} = \frac{1}{7} \sum_{i=1}^7 x_i = \frac{1}{7} (3 + 7 + 5 + 12 + 9 + 7 + 4) = 6.71$$

$$\begin{aligned} s^2 &= \frac{1}{7-1} \left(\sum_{i=1}^7 x_i^2 - 7 \times \bar{x}^2 \right) = \frac{1}{6} \left((3^2 + 7^2 + 5^2 + 12^2 + 9^2 + 7^2 + 4^2) - 7 \times (6.71)^2 \right) \\ &= \frac{1}{6} (373 - 315.17) = 9.638 \end{aligned}$$

$$s = \sqrt{s^2} = \sqrt{9.638} = 3.105$$

Données groupées en valeurs réelles isolées :

Tableau de fréquences :

Observation	Fréquence
x_1	n_1
x_2	n_2
x_3	n_3
$\dots$	$\dots$
x_k	n_k

$$n_1 + n_2 + n_3 + \dots + n_k = \sum_{j=1}^k n_j = n$$

Moyenne échantillonnale :

$$\bar{x} = \frac{1}{n} \sum_{j=1}^k n_j x_j$$

Variance échantillonnale :

$$s^2 = \frac{1}{n-1} \sum_{j=1}^k n_j (x_j - \bar{x})^2 = \frac{1}{n-1} \left(\sum_{j=1}^k n_j x_j^2 - n \bar{x}^2 \right)$$

Exemple :

$X : \{2, 3, 3, 6, 8, 2, 3, 8, 6, 2, 3, 6, 6, 2, 3, 3, 2, 8, 6, 3, 3, 3, 2, 2, 3\}$

$$n = 25$$

$$k = 4$$

$$n_1 + n_2 + n_3 + n_4 = 7 + 10 + 5 + 3 = 25$$

Observation	Fréquence
2	7
3	10
6	5
8	3

Ainsi, nous pouvons obtenir facilement les statistiques descriptives suivantes :

$$\bar{x} = \frac{1}{25} \sum_{j=1}^4 n_j x_j = \frac{1}{25} (7 \times 2 + 10 \times 3 + 5 \times 6 + 3 \times 8) = \frac{1}{25} \times 98 = 3.92$$

$$\begin{aligned} s^2 &= \frac{1}{24} \left(\sum_{j=1}^4 n_j x_j^2 - n \bar{x}^2 \right) = \frac{1}{24} \left((7 \times 2^2 + 10 \times 3^2 + 5 \times 6^2 + 3 \times 8^2) - 25 \times (3.92)^2 \right) \\ &= \frac{1}{24} (490 - 384.16) = 4.41 \end{aligned}$$

$$s = \sqrt{4.41} = 2.1$$

Données groupées en intervalle :

Soit X , une variable quantitative. On considère les observations de X réparties sur les intervalles $[x_0, x_1[$, $[x_1, x_2[$, $[x_2, x_3[$, ..., $[x_{k-1}, x_k[$ et respectivement de fréquence : $n_1, n_2, n_3, \dots, n_k$.

Intervalle I_i	Milieu Y_i	Fréquence n_i
$[x_0, x_1[$	y_1	n_1
$[x_1, x_2[$	y_2	n_2
$[x_2, x_3[$	y_3	n_3
...	...	...
$[x_{k-1}, x_k[$	y_k	n_k

$$n_1 + n_2 + n_3 + \dots + n_k = \sum_{j=1}^k n_j = n$$

$$\bar{x} \cong \frac{1}{n} \sum_{j=1}^k n_j y_j$$

$$s^2 \cong \frac{1}{n-1} \sum_{j=1}^k n_j (y_j - \bar{x})^2 = \frac{1}{n-1} \left(\sum_{j=1}^k n_j y_j^2 - n \bar{x}^2 \right)$$

On désigne $y_i = \frac{x_{i-1} + x_i}{2}$ le milieu de l'intervalle $[x_{i-1}, x_i[$ pour $i = 1, \dots, k$.

Exemple :

Soit la variable X , définie par l'âge :

$X = \{10.5, 23.0, 36.3, 12.3, 25.0, 23.2, 30.1, 17.5, 22.1, 32.2, 37.0, 27.0, 34.2, 20.0, 28.3, 29.1, 16.9, 24.6, 18.1, 31.5\}$

I_i	y_i	n_i
[10, 20[	15	5
[20, 30[	25	9
[30, 40[	35	6

$$n = 5 + 9 + 6 = 20$$

$$\bar{x} \cong \frac{1}{20} \sum_{j=1}^3 n_j y_j = \frac{1}{20} (5 \times 15 + 9 \times 25 + 6 \times 35) = \frac{1}{20} \times 510 = 25.5$$

$$\begin{aligned} s^2 &\cong \frac{1}{19} \left(\sum_{j=1}^3 n_j y_j^2 - n \bar{x}^2 \right) = \frac{1}{19} \left((5 \times 15^2 + 9 \times 25^2 + 6 \times 35^2) - 20 \times (25.5)^2 \right) \\ &= \frac{1}{19} (14100 - 13005) = 57.63 \end{aligned}$$

$$s = \sqrt{57.63} = 7.59$$

B. Mesures de position

On considère la variable X et des observations de cette variable :

observations : $x_1, x_2, x_3, \dots, x_n$

statistique d'ordre : $x_{(1)}, x_{(2)}, x_{(3)}, \dots, x_{(n)}$ avec $x_{(1)} \leq x_{(2)} \leq x_{(3)} \leq \dots \leq x_{(n)}$ (échantillon ordonné en ordre croissant). La plus petite observation a le rang 1 et la plus grande le rang n .

Exemple :

Pour les observations suivantes : 4, 3, 9, 8, 11, nous avons les statistiques d'ordre suivantes :

Statistiques d'ordre	$x_{(i)}$
$x_{(1)}$	3
$x_{(2)}$	4
$x_{(3)}$	8
$x_{(4)}$	9
$x_{(5)}$	11

Les quartiles :

Soit les statistiques d'ordre suivantes : $x_{(1)}, x_{(2)}, x_{(3)}, \dots, x_{(n)}$

Il y a trois quartiles qui divisent l'échantillon en quatre parties de même fréquence: Q_1 , Q_2 et Q_3 . Ils donnent une idée de la position des données sur l'axe réel. Ce sont des fonctions des statistiques d'ordre.

La **médiane** (Q_2) divise l'échantillon en deux parties égales. Le rang de la médiane est $(n+1)/2$.

Quand n est impair, $(n+1)/2$ est un entier. On pose alors $Q_2 = x_{((n+1)/2)}$.

Quand n est pair, $(n+1)/2$ n'est pas un entier. On fait alors la moyenne des deux observations dont le rang est le plus près de celui de la médiane: $Q_2 = (x_{(n/2)} + x_{((n+2)/2}))/2$.
Il se peut alors que Q_2 ne soit pas une valeur observée dans l'échantillon.

Exemple:

Si $n = 11$, $Q_2 = x_{(6)}$. Si $n = 6$, le rang de la médiane est 3.5; alors, $Q_2 = (x_{(3)} + x_{(4)})/2$.

Le **premier quartile** (Q_1) divise la première moitié de l'échantillon en deux parties égales. C'est donc la médiane de la première moitié de l'échantillon. Il y a $m = [(n+1)/2]$ observations dans cette partie, où $[v]$ est la partie entière de v . On calcule le rang du premier quartile comme on a calculé celui de la médiane.

Exemple:

Si $n = 11$, $m = [6] = 6$. Le rang de Q_1 est 3.5. Alors, $Q_1 = (x_{(3)} + x_{(4)})/2$.

Si $n = 6$, $m = [3.5] = 3$. Le rang de Q_1 est 2. Alors, $Q_1 = x_{(2)}$.


Le **troisième quartile** (Q_3) divise la seconde moitié de l'échantillon en deux parties égales. Le rang du troisième quartile est $(n + 1 - \text{rang de } Q_1)$.

Exemple:

Si $n = 11$, le rang de Q_3 est $(12 - 3.5) = 8.5$. Alors, $Q_3 = (x_{(8)} + x_{(9)})/2$.

Si $n = 6$, le rang de Q_3 est $(7 - 3) = 4$. Alors, $Q_3 = x_{(4)}$.

Illustration du rôle des quartiles:



Exemple:

Soit les statistiques d'ordre suivantes:

2	5	6	9	13	14	16	21	27	31
$x_{(1)}$	$x_{(2)}$	$x_{(3)}$	$x_{(4)}$	$x_{(5)}$	$x_{(6)}$	$x_{(7)}$	$x_{(8)}$	$x_{(9)}$	$x_{(10)}$

a) Quelle est la médiane ?

Le rang de la médiane est $(10 + 1)/2 = 5.5$. Donc, la médiane est $(x_{(5)} + x_{(6)})/2 = 13.5$. Cinq observations sont plus petites que 13.5 et cinq observations sont plus grandes.

b) Quel est le premier quartile?

Il y a $[5.5] = 5$ observations dans la première moitié de l'échantillon. Le rang du premier quartile est 3. Donc, $Q_1 = x_{(3)} = 6$.

c) Quel est le troisième quartile?

Le rang du troisième quartile est $11 - 3 = 8$. Donc $Q_3 = x_{(8)} = 21$.

L'écart interquartile : $EIQ = Q_3 - Q_1$ est une mesure alternative de dispersion.

Dans l'exemple précédent, l'écart interquartile vaut $21 - 6 = 15$.

3. Représentation graphique

A. Diagramme en boîte (pour des variables continues)

Cette représentation concerne surtout les données réelles non groupées.

Exemple :

Statistique d'ordre : 4, 18, 29, 31, 35, 36, 42, 51, 68

On calcule Q_1 , Q_2 et Q_3 :

$$Q_1 = 29 \quad , \quad Q_2 = 35 \quad , \quad Q_3 = 42$$

On calcule EIQ :

$$EIQ = Q_3 - Q_1 = 42 - 29 = 13$$

On calcule la *borne inférieure* b_i et la *borne supérieure* b_s :


$$b_i = Q_1 - 1.5 \times EIQ \quad \text{et} \quad b_s = Q_3 + 1.5 \times EIQ$$

Les valeurs qui se retrouvent en dehors de l'intervalle $[b_i, b_s]$ sont des données dites **aberrantes**. Les bornes n'apparaissent pas dans le diagramme en boîte. On voit plutôt les données non aberrantes les plus proches.

Dans l'exemple, nous obtenons :

$$b_i = 29 - 1.5 \times 13 = 9.5 \quad \text{et} \quad b_s = 42 + 1.5 \times 13 = 61.5$$

Interprétation du diagramme en boîte :



Distribution des données symétrique




Distribution des données asymétrique à droite



Distribution des données asymétrique à gauche

Dans l'exemple précédent, nous avons $[b_i, b_s] = [9.5, 61.5]$. Alors, les données 4 et 68 sont des données aberrantes (représentées par des étoiles). De plus, nous avons une distribution symétrique des données (le dessin n'est pas tout à fait à l'échelle):



B. Histogramme (variable continue)


Cette représentation concerne surtout les données groupées en intervalle.

Exemple :

a) Les intervalles ont la même longueur :

Intervalle $[x_{i-1}, x_i[$	Fréquence n_i	Amplitude $a_i = x_i - x_{i-1}$	Fréquence relative $f_i = n_i / n$	Hauteur $h_i = f_i / a_i$	Hauteur* $h_i * 10^3$
[10, 26[	5	16	0.04	0.0025	2.5
[26, 42[	10	16	0.08	0.005	5.0
[42, 58[	15	16	0.12	0.0075	7.5
[58, 74[	25	16	0.20	0.0125	12.5
[74, 90[	35	16	0.28	0.0175	17.5
[90, 106[	20	16	0.16	0.01	10.0
[106, 122[	15	16	0.12	0.0075	7.5

Intervalle $[x_{i-1}, x_i[$	Hauteur $h_i * 10^3$
[10, 26[	2.5
[26, 42[	5.0
[42, 58[	7.5
[58, 74[	12.5
[74, 90[	17.5
[90, 106[	10.0
[106, 122[	7.5




Exemple

b) Les intervalles n'ont pas toutes la même longueur :

Intervalle $[x_{i-1}, x_i[$	Fréquence n_i	Amplitude $a_i = x_i - x_{i-1}$	Fréquence relative $f_i = n_i / n$	Hauteur $h_i = f_i / a_i$	Hauteur* $h_i * 10^2$
[2, 3[	15	1	0.15	0.15	15
[3, 4.5[	30	1.5	0.30	0.20	20
[4.5, 7[	45	2.5	0.45	0.18	18
[7, 9[	10	2	0.10	0.05	5

Note : La somme des fréquences relatives donne toujours 1.

Intervalle $[x_{i-1}, x_i[$	Hauteur $h_i * 10^2$
$[2, 3[$	15
$[3, 4.5[$	20
$[4.5, 7[$	18
$[7, 9[$	5



Notes :

L'aire totale de tous les rectangles vaut 1.

Le polygone de fréquence est la version empirique d'une densité.

On ne laisse pas d'espace entre deux colonnes adjacentes.