

Bornes pour l'estimation ponctuelle

KONANE Victorien

Université Joseph

KI-ZERBO MATHS



Plan

- 1 Quantité d'information
- 2 Exhaustivité
- 3 Borne de Cramer-Rao
- 4 Comportement asymptotique des EMV

Plan

- 1 Quantité d'information
- 2 Exhaustivité
- 3 Borne de Cramer-Rao
- 4 Comportement asymptotique des EMV

Cadre de l'étude

Modèle continu:

On considérera par la suite un modèle statistique avec

$$\mu_{\theta}(dx) = f_{\theta}(x) dx.$$

On pose

$$E_{\theta} = \{x \in E; f_{\theta}(x) > 0\}$$

Généralisation: Tous nos résultats s'étendront facilement au cas de variables aléatoires discrètes (i.e. à valeurs dans $\mathbb{N}$).

Inégalité de la théorie de l'information

Lemme

Soit $(\Omega, \mathcal{A}, X, E, (\mu_\theta)_{\theta \in \Theta})$ un modèle avec $\mu_\theta(dx) = f_\theta(x) dx$.
On suppose $f_\theta > 0$ pour tout $\theta \in \Theta$. Soit $\theta_0 \in \Theta$. Alors:

$$\mathbf{E}_{\theta_0}[\ln(f_\theta(X))] < \mathbf{E}_{\theta_0}[\ln(f_{\theta_0}(X))], \quad \text{pour tout } \theta \in \Theta \setminus \{\theta_0\}.$$

Hypothèse supplémentaire:

La fonction $\theta \mapsto \mathbf{E}_{\theta_0}[\ln(f_\theta(X))]$ est deux fois dérivable sous le signe $\mathbf{E}$.

On pose

$$J(\theta, \theta_0) = \mathbf{E}_{\theta_0}[\partial_\theta \ln(f_\theta(X))].$$

Alors il existe un voisinage de θ_0
sur lequel $\theta \mapsto J(\theta, \theta_0)$ est décroissante.

Démonstration

Inégalité de Jensen: par concavité stricte de $\ln$, pour $\theta \neq \theta_0$,

$$\mathbf{E}_{\theta_0} \left[\ln \left(\frac{f_{\theta}(X)}{f_{\theta_0}(X)} \right) \right] < \ln \left(\mathbf{E}_{\theta_0} \left[\frac{f_{\theta}(X)}{f_{\theta_0}(X)} \right] \right) = 0$$

On en déduit

$$\mathbf{E}_{\theta_0}[\ln(f_{\theta}(X))] < \mathbf{E}_{\theta_0}[\ln(f_{\theta_0}(X))].$$

Démonstration (2)

On a trouvé:

$\theta \mapsto \mathbf{E}_{\theta_0}[\ln(f_\theta(X))]$ admet un minimum strict en θ_0

Rappel:

$$J(\theta, \theta_0) = \mathbf{E}_{\theta_0} [\partial_\theta \ln(f_\theta(X))] = \partial_\theta \mathbf{E}_{\theta_0} [\ln(f_\theta(X))] .$$

Donc $J(\theta_0, \theta_0) = 0$.

De plus:

$$\partial_\theta J(\theta, \theta_0) = \mathbf{E}_{\theta_0} [\partial_{\theta\theta}^2 \ln(f_\theta(X))] \implies \partial_\theta J(\theta, \theta_0)|_{\theta=\theta_0} = -I_X(\theta_0),$$

où $I_X(\theta_0)$ se nomme **quantité d'information** de X par rapport à θ_0 .

On verra que $I_X(\theta_0) > 0$.

$\hookrightarrow$ Décroissance de J dans un voisinage de θ_0 .

Exemple

Lois de Bernoulli: si $E = \{0, 1\}$, $\Theta =]0, 1[$ et $\mu_p = \mathcal{B}(p)$

On a vu $f_\theta(x) = \theta^x(1 - \theta)^{1-x}$ et

$$\begin{aligned}\mathbf{E}_{\theta_0}[\ln(f_\theta(X))] &= (1 - \theta_0) \ln(1 - \theta) + \theta_0 \ln(\theta) \\ J(\theta, \theta_0) = \partial_\theta \mathbf{E}_{\theta_0}[\ln(f_\theta(X))] &= \frac{\theta_0 - \theta}{\theta(1 - \theta)}\end{aligned}$$

On observe bien les phénomènes annoncés par la proposition.

Quantité d'information

Définition

Soit $(\Omega, \mathcal{A}, X, E, (\mu_\theta)_{\theta \in \Theta})$ un modèle avec $\mu_\theta(dx) = f_\theta(x) dx$.

On pose

$$I_X(\theta) = \mathbf{E}_\theta \left[(\partial_\theta \ln(f_\theta(X)))^2 \right],$$

lorsque cette quantité est bien définie.

Proposition

Lorsque E_θ est indépendant de θ , on a aussi

$$I_X(\theta) = -\mathbf{E}_\theta \left[\partial_{\theta\theta}^2 \ln(f_\theta(X)) \right] = \mathbf{Var}[\partial_\theta \ln(f_\theta(X))],$$

Interprétations et remarques

(i) Sur l'expression $-\mathbf{E}_\theta[\partial_{\theta\theta}^2 \ln(f_\theta(X))]$:

$I_X(\theta_0) \equiv$ largeur du pic de $\mathbf{E}_{\theta_0}[\ln(f_{\theta_0}(X))]$ autour de θ_0

$\hookrightarrow$ Quantifie l'apport de X à l'estimation de θ_0

(ii) Sur l'expression $\mathbf{Var}[\partial_\theta \ln(f_\theta(X))]$:

On a vu que $\mathbf{E}_\theta[\partial_\theta \ln(f_\theta(X))] = 0$ (à redémontrer)

$\hookrightarrow$ La variance est le premier moment intéressant de $\partial_\theta \ln(f_\theta(X))$.

(ii) Rôle de l'hypothèse sur E_θ :

Afin de pouvoir dériver tranquillement sous le signe somme.

Démonstration

(i) Montrons directement $\mathbf{E}_\theta [\partial_\theta \ln(f_\theta(X))] = 0$:

$$\begin{aligned}\mathbf{E}_\theta [\partial_\theta \ln(f_\theta(X))] &= \mathbf{E}_\theta \left[\frac{\partial_\theta f_\theta(X)}{f_\theta(X)} \right] = \int_{\mathbb{R}} \partial_\theta f_\theta(x) dx \\ &= \partial_\theta \left(\int_{\mathbb{R}} f_\theta(x) dx \right) = 0.\end{aligned}$$

Donc

$$I_X(\theta) = \mathbf{E}_\theta \left[(\partial_\theta \ln(f_\theta(X)))^2 \right] = \mathbf{Var} [\partial_\theta \ln(f_\theta(X))].$$

Démonstration (2)

(ii) Dérivons la relation $\mathbf{E} [\partial_\theta \ln(f_\theta(X))] = 0$:

$$\begin{aligned}\partial_\theta \mathbf{E} [\partial_\theta \ln(f_\theta(X))] &= \partial_\theta \left(\int_{\mathbb{R}} \partial_\theta (\ln(f_\theta(x))) f_\theta(x) dx \right) \\ &= \int_{\mathbb{R}} \partial_{\theta\theta}^2 (\ln(f_\theta(x))) f_\theta(x) dx + \int_{\mathbb{R}} [\partial_\theta (\ln(f_\theta(x)))]^2 f_\theta(x) dx \\ &= \mathbf{E}_\theta [\partial_{\theta\theta}^2 \ln(f_\theta(X))] + \mathbf{E}_\theta [(\partial_\theta \ln(f_\theta(X)))^2] = 0.\end{aligned}$$

Donc

$$I_X(\theta) = \mathbf{E}_\theta [(\partial_\theta \ln(f_\theta(X)))^2] = -\mathbf{E}_\theta [\partial_{\theta\theta}^2 \ln(f_\theta(X))].$$

Exemples (1)

Cas gaussien: on prend $\mathbf{P}_\mu = \mathcal{N}(\mu, \sigma^2)$ avec σ^2 connue.
Les hypothèses de la proposition sont vérifiées et

$$I_X(\mu) = \frac{1}{\sigma^2}$$

Donc plus σ est petit, plus X apporte de l'information sur μ .

Exemples (2)

Cas uniforme: on prend $\mu_a = \mathcal{U}([0, a])$.

Alors sur $[0, a]$, on a $f_a(x) = 1/a$ et

$$I_X(a) = \mathbf{E}_a \left[(\partial_a \ln(f_a(X)))^2 \right] = \int_0^a a^{-2} \frac{dx}{a} = a^{-2} > 0$$

Mais $\partial_a \ln(f_a(X)) = -1/a$ car $X \in E_a$. Donc

$$\mathbf{Var} [\partial_a \ln(f_a(X))] = 0$$

Conclusion: La proposition n'est donc pas vérifiée ici

$\hookrightarrow$ dû au fait que $E_a = [0, a]$ dépend de a .

Rappel: modèle d'échantillonnage

Définition

On appelle **modèle d'échantillonnage** basé sur le modèle statistique précédent une famille $(\tilde{\Omega}, \tilde{\mathcal{A}}, \mathbf{X}_n, E^n, \tilde{\mathbf{P}}_\theta)$, où

- $\mathbf{X}_n, E^n$: réalisation de la v.a. $\mathbf{X}_n := (X_1, \dots, X_n)$ définie sur $(\tilde{\Omega}, \tilde{\mathcal{A}})$
- $\Theta \equiv$ ensemble des paramètres
- $\tilde{\mathbf{P}}_\theta$ est une loi de proba sur E^n pour tout $\theta \in \Theta$
 $\hookrightarrow$ correspond à un n -échantillon $(X_1, \dots, X_n)$ de loi $\mathbf{P}_\theta$

Quantité d'information d'un échantillon

Proposition

*Soit un modèle d'échantillonnage de loi $\{\mu_\theta; \theta \in \Theta\}$.
On suppose $\mu_\theta(dx) = f_\theta(x) dx$ et E_θ indépendant de θ .
Alors*

$$I_{(X_1, \dots, X_n)}(\theta) = n I_{X_1}(\theta).$$

Interprétation: un n -échantillon apporte n fois plus d'information que l'observation de X_1 seule.

Démonstration

Retour de la log-vraisemblance: pour un n -échantillon, on a

$$\ln(f_{\theta}(X_1, \dots, X_n)) = \ell_{\theta}(X_1, \dots, X_n) = \sum_{i=1}^n \ell_{\theta}(X_i).$$

On en déduit:

$$\begin{aligned} I_{(X_1, \dots, X_n)}(\theta) &= \mathbf{Var} [\partial_{\theta} \ell_{\theta}(X_1, \dots, X_n)] = \mathbf{Var} \left[\sum_{i=1}^n \partial_{\theta} \ell_{\theta}(X_i) \right] \\ &= \sum_{i=1}^n \mathbf{Var} [\partial_{\theta} \ell_{\theta}(X_i)] = n I_{X_1}(\theta). \end{aligned}$$

Plan

- 1 Quantité d'information
- 2 Exhaustivité**
- 3 Borne de Cramer-Rao
- 4 Comportement asymptotique des EMV

Exhaustivité

Définition

Soit un modèle d'éch. de loi $\{\mu_\theta; \theta \in \Theta\}$, avec $\mu_\theta(dx) = f_\theta(x) dx$.

Soit T un estimateur.

On dit que T est exhaustif si la vraisemblance L_θ se factorise en

$$L_\theta(x_1, \dots, x_n) = g_\theta(t) h(x_1, \dots, x_n),$$

où g_θ est la densité de T .

Remarque: En fait, la définition d'estimateur exhaustif est

$$\mathcal{L}_\theta((X_1, \dots, X_n) | T) \text{ ne dépend pas de } \theta.$$

Exemples (1)

Cas gaussien: on prend $\mathbf{P}_\mu = \mathcal{N}(\mu, \sigma^2)$ avec σ^2 connue.

Alors

$$\begin{aligned} L_\mu(x_1, \dots, x_n) &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}\right) \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{n(\bar{x}_n - \mu)^2}{2\sigma^2}\right) \exp\left(-\frac{\sum_{i=1}^n (x_i - \bar{x}_n)^2}{2\sigma^2}\right) \end{aligned}$$

De plus, $\bar{X}_n \sim \mathcal{N}(\mu, \sigma^2/n)$.

$\Rightarrow \bar{X}_n$ est un estimateur exhaustif.

Exemples (2)

Cas uniforme: on prend $\mu_a = \mathcal{U}([0, a])$.

Sur $[0, a]$, on a $f_a(x) = 1/a$.

Soit $R = \max_{i \leq n} X_i$. Alors R est un estimateur, de densité

$$g(r) = \frac{n r^{n-1}}{a^n} \mathbf{1}_{[0,a]}(r).$$

De plus, pour $x_1, \dots, x_n \in [0, a]$, on a

$$L_a(x_1, \dots, x_n) = \frac{1}{a^n} = \frac{n r^{n-1}}{a^n} \cdot \frac{1}{n r^{n-1}}.$$

$\Rightarrow R$ est un estimateur exhaustif.

Information des estimateurs exhaustifs

Théorème

On suppose que E_θ est indépendant de θ

Hypothèse: $I_X(\theta) = -\mathbf{E}_\theta[\partial_{\theta\theta}^2 \ln(f_\theta(X))]$

Alors

- 1 *L'information concernant θ fournie par un estimateur T est majorée par celle du n -échantillon:*

$$I_T(\theta) \leq I_{(X_1, \dots, X_n)}(\theta).$$

- 2 *On a **égalité** si et seulement si T est **exhaustif***

Interprétation: toute l'information d'un n -échantillon est contenue dans un estimateur exhaustif.

Exemple

Cas gaussien: on prend $\mathbf{P}_\mu = \mathcal{N}(\mu, \sigma^2)$ avec σ^2 connue.
Les hypothèses de la proposition sont vérifiées et

$$I_X(\mu) = \frac{1}{\sigma^2} \implies I_{(X_1, \dots, X_n)}(\theta) = \frac{n}{\sigma^2}$$

On a aussi vu que $\bar{X}_n$ est un estimateur exhaustif et

$$\bar{X}_n \sim \mathcal{N}(\mu, \sigma^2/n) \implies I_{\bar{X}_n}(\theta) = \frac{n}{\sigma^2}$$

Famille exponentielle

Définition

Soit un modèle d'éch. de loi $\{\mu_\theta; \theta \in \Theta\}$, avec $\mu_\theta(dx) = f_\theta(x) dx$.

On suppose que E_θ est indépendant de θ .

On dit que $\{\mu_\theta; \theta \in \Theta\}$ est une **famille exponentielle** si on peut décomposer f_θ comme:

$$\ln(f_\theta(x)) = a(x) \alpha(\theta) + b(x) + \beta(\theta),$$

avec

$$a, b : \mathbb{R} \rightarrow \mathbb{R}, \quad \alpha, \beta : \Theta \rightarrow \mathbb{R}.$$

Familles exponentielles et exhaustivité

Théorème

Soit un modèle d'éch. de loi $\{\mu_\theta; \theta \in \Theta\}$, avec $\mu_\theta(dx) = f_\theta(x) dx$.
On suppose que E_θ est indépendant de θ .

(i) S'il existe $n > 1$ tel que $(X_1, \dots, X_n)$ admette un est. exhaustif
 $\implies \{\mu_\theta; \theta \in \Theta\}$ est une famille exponentielle.

(ii) Si $\{\mu_\theta; \theta \in \Theta\}$ est une famille exponentielle, et si l'application

$$x \mapsto a(x), \quad x \in \mathbb{R}$$

est une bijection de C^1

$\implies (X_1, \dots, X_n)$ admet un estimateur exhaustif.

Cet estimateur est donné par

$$T = \sum_{i=1}^n a(X_i).$$

Exemples (1)

Cas gaussien: on prend $\mathbf{P}_\mu = \mathcal{N}(\mu, \sigma^2)$ avec σ^2 connue.

Alors

$$\ln(f_\mu(x)) = x\mu - \frac{x^2}{2} - \frac{\mu^2}{2} - \frac{1}{2}\ln(2\pi),$$

soit

$$a(x) = x, \quad \alpha(\mu) = \mu, \quad b(x) = -\frac{x^2}{2}, \quad \beta(\mu) = -\frac{\mu^2}{2}.$$

La fonction a est C^1 et bijective.

Conclusion: $\sum_{i=1}^n X_i$ ou $\bar{X}_n$ est un estimateur exhaustif.

Exemples (2)

Cas uniforme: on prend $\mu_a = \mathcal{U}([0, a])$.

Sur $[0, a]$, on a $f_a(x) = 1/a$.

Soit $R = \max_{i \leq n} X_i$. On a vu que R est un estimateur exhaustif.

Application du théorème:

$$\ln(f_a(x)) = -\ln(a), \quad x \in E_a.$$

Donc

$$a(x) = 1, \quad T = \sum_{i=1}^n a(X_i) = n$$

Donc T n'est pas exhaustif.

Plan

- 1 Quantité d'information
- 2 Exhaustivité
- 3 Borne de Cramer-Rao**
- 4 Comportement asymptotique des EMV

Risque quadratique

Définition

Soit un modèle d'éch. de loi $\{\mu_\theta; \theta \in \Theta\}$

Soit T estimateur de θ

Le *risque quadratique* associé à T est la fonction

$$R_T(\theta) = \mathbf{E}_\theta \left[(T - \theta)^2 \right].$$

Remarques:

- (i) $R_T(\theta)$ quantifie les fluctuations de T autour de θ .
- (ii) Si T est sans biais, $R_T(\theta) = \mathbf{Var}(T)$.
- (iii) Situation idéale: $R_T(\theta) = O(\frac{1}{n})$.

Borne de Cramer-Rao

Théorème

Soit un modèle d'éch. de loi $\{\mu_\theta; \theta \in \Theta\}$, avec $\mu_\theta(dx) = f_\theta(x) dx$.
On suppose que $E = E_\theta$ est indépendant de θ , et $\Theta \subset \mathbb{R}$.

Soit $T = \varphi(X_1, \dots, X_n)$ estimateur de θ tel que

- $T \in L^2(\mu_\theta)$ pour tout $\theta \in \Theta$.
- f_θ est telle que $I_{X_1}(\theta) < \infty$ pour tout $\theta \in \Theta$.
- $\partial_\theta L_\theta$ et $\varphi \partial_\theta L_\theta$ intégrables dans E^n , et permettent de dériver sous $\int$.

Alors on a

$$\text{Var}(T) \geq \frac{(\partial_\theta \mathbf{E}_\theta[T])^2}{n I_{X_1}(\theta)}.$$

Interprétation:

La convergence des estimateurs ne peut se faire à vitesse $> n^{1/2}$.

Démonstration

Comme on peut dériver sous $\int$, on a

$$\partial_{\theta} \mathbf{E}_{\theta}[T] = \int_{E^n} \varphi \frac{\partial_{\theta} L_{\theta}}{L_{\theta}} L_{\theta} dx = \int_{E^n} \varphi \partial_{\theta} \ell_{\theta} L_{\theta} dx.$$

En particulier, si $T \equiv 1$, on a

$$0 = \int_{E^n} \partial_{\theta} \ell_{\theta} L_{\theta} dx.$$

Par conséquent,

$$\partial_{\theta} \mathbf{E}_{\theta}[T] = \mathbf{E} [(T - \mathbf{E}_{\theta}[T]) \partial_{\theta} \ell_{\theta}(X)].$$

Cauchy-Schwarz:

$$\begin{aligned} (\partial_{\theta} \mathbf{E}_{\theta}[T])^2 &\leq \mathbf{E}_{\theta} [(T - \mathbf{E}_{\theta}[T])^2] \mathbf{E}_{\theta} [(\partial_{\theta} \ell_{\theta}(X))^2] \\ &= \mathbf{Var}_{\theta}(T) I_{(X_1, \dots, X_n)}(\theta). \end{aligned}$$

Cas d'un estimateur sans biais

Hypothèse: l'estimateur T est non biaisé, i.e. $\mathbf{E}_\theta[T] = \theta$.

Alors l'inégalité de Cramer-Rao se lit

$$\mathbf{Var}(T) \geq \frac{1}{n I_{X_1}(\theta)}.$$

Cas gaussien $\mathcal{N}(\mu, \sigma^2)$, σ connu: on a vu que $I_{X_1}(\theta) = 1/\sigma^2$.

Donc, pour T non biaisé,

$$\mathbf{Var}(T) \geq \frac{\sigma^2}{n}.$$

On remarque que la borne est atteinte pour $T = \bar{X}_n$.

Efficacité

Définition

*Soit un modèle d'éch. de loi $\{\mu_\theta; \theta \in \Theta\}$, avec $\mu_\theta(dx) = f_\theta(x) dx$.
On suppose que $E = E_\theta$ est indépendant de θ ,
ainsi que les autres hypothèses de Cramer-Rao.*

Soit T un estimateur sans biais de θ .

L'efficacité de T est la quantité

$$e_n(T) = \frac{1}{n I_{X_1}(\theta) \text{Var}(T)}.$$

On a toujours $e_n(T) \in [0, 1]$.

Si $e_n(T) = 1$, on dit que T est efficace.

Interprétation: l'efficacité quantifie la précision d'un estimateur.

Familles exponentielles et efficacité

Théorème

Soit un modèle d'éch. de loi $\{\mu_\theta; \theta \in \Theta\}$, avec $\mu_\theta(dx) = f_\theta(x) dx$.
On suppose que μ_θ est une famille exponentielle:

$$\ln(f_\theta(x)) = a(x) \alpha(\theta) + b(x) + \beta(\theta),$$

et que l'application $x \mapsto a(x)$ est une bijection de C^1 .

Alors

(i) $T = \frac{1}{n} \sum_{i=1}^n a(X_i)$ est un estimateur
sans biais efficace de $h(\theta) = -\frac{\beta'(\theta)}{\alpha'(\theta)}$.

(ii) La variance minimale est donnée par

$$\text{Var}(T) = -\frac{1}{n\alpha'(\theta)} \frac{d}{d\theta} \left(\frac{\beta'(\theta)}{\alpha'(\theta)} \right).$$

Exemple

Cas gaussien: on prend $\mathbf{P}_\mu = \mathcal{N}(\mu, \sigma^2)$ avec σ^2 connue.

Alors

$$\ln(f_\mu(x)) = x\mu - \frac{x^2}{2} - \frac{\mu^2}{2} - \frac{1}{2}\ln(2\pi),$$

soit

$$a(x) = x, \quad \alpha(\mu) = \mu, \quad b(x) = -\frac{x^2}{2}, \quad \beta(\mu) = -\frac{\mu^2}{2}.$$

La fonction a est C^1 et bijective.

Conclusion:

$\bar{X}_n$ est un estimateur sans biais efficace de $h(\mu) = -\frac{\beta'(\mu)}{\alpha'(\mu)} = \mu$.

Variance minimale:

$$\mathbf{Var}(\bar{X}_n) = -\frac{1}{n\alpha'(\theta)} \frac{d}{d\theta} \left(\frac{\beta'(\theta)}{\alpha'(\theta)} \right) = \frac{\sigma^2}{n}.$$

Plan

- 1 Quantité d'information
- 2 Exhaustivité
- 3 Borne de Cramer-Rao
- 4 Comportement asymptotique des EMV**

Forte consistance

Théorème

*Soit un modèle d'éch. de loi $\{\mu_\theta; \theta \in \Theta\}$, avec $\mu_\theta(dx) = f_\theta(x) dx$.
On suppose que $\Theta \subset \mathbb{R}$ et pour tout $\theta_1, \theta_2 \in \Theta$,*

$$\mathbf{E}_{\theta_1} [|\partial_\theta \ln(f(X, \theta_2))|] < \infty, \quad \mathbf{E}_{\theta_1} \left[\left| \partial_{\theta\theta}^2 \ln(f(X, \theta_2)) \right| \right] < \infty.$$

Alors il existe une suite $(\hat{\theta}_n)_{n \geq 1}$ de racines de l'équation

$$\partial_\theta \ell_\theta(X_1, \dots, X_n) := \sum_{i=1}^n \partial_\theta \ln(f(X_i, \theta)) = 0$$

telle que $\hat{\theta}_n$ est un estimateur fortement consistant de θ .

Démonstration

Hypothèse: On va supposer que $\theta = \theta_0$.

Rappel: On pose

$$J(\theta, \theta_0) = \mathbf{E}_{\theta_0} [\partial_{\theta} \ln(f_{\theta}(X_1))] .$$

Alors $J(\theta_0, \theta_0) = 0$ et il existe un voisinage $\mathcal{V}_{\theta_0}$ de θ_0 sur lequel $\theta \mapsto J(\theta, \theta_0)$ est décroissante.

Application de LGN: on pose

$$Z_n(\theta) = \frac{1}{n} \partial_{\theta} \ell_{\theta}(X_1, \dots, X_n) = \frac{1}{n} \sum_{i=1}^n \partial_{\theta} \ln(f(X_i, \theta)) .$$

Alors pour tout θ , $Z_n(\theta) \rightarrow J(\theta, \theta_0)$ P_{θ_0} -p.s.

Démonstration (2)

Construction de la suite: Soit ε tel que $[\theta_0 - \varepsilon, \theta_0 + \varepsilon] \in \mathcal{V}_{\theta_0}$.
Alors P_{θ_0} -p.s, il existe $N = N(\omega)$ tel que pour tout $n \geq N$, on a

$$\frac{1}{n} \partial_{\theta} \ell_{\theta_0 - \varepsilon}(X_1, \dots, X_n) > 0, \quad \frac{1}{n} \partial_{\theta} \ell_{\theta_0 + \varepsilon}(X_1, \dots, X_n) < 0$$

Par continuité de $\theta \mapsto \ell_{\theta}$, il existe $\hat{\theta}_n \in [\theta_0 - \varepsilon, \theta_0 + \varepsilon]$ tel que

$$\frac{1}{n} \partial_{\theta} \ell_{\hat{\theta}_n}(X_1, \dots, X_n) = 0$$

Conclusion: on a

$$\frac{1}{n} \partial_{\theta} \ell_{\hat{\theta}_n}(X_1, \dots, X_n) = 0 \quad \text{et} \quad \hat{\theta}_n \rightarrow \theta_0 \quad \mathbf{P}_{\theta_0} \text{ p.s.}$$

Théorème

Soit un modèle d'éch. de loi $\{\mu_\theta; \theta \in \Theta\}$, avec $\mu_\theta(dx) = f_\theta(x) dx$.
On suppose que $\Theta \subset \mathbb{R}$ et pour tout $\theta_1, \theta_2 \in \Theta$,

$$\mathbf{E}_{\theta_1} [|\partial_\theta \ln(f(X, \theta_2))|] < \infty, \quad \mathbf{E}_{\theta_1} \left[\left| \partial_{\theta\theta}^2 \ln(f(X, \theta_2)) \right| \right] < \infty.$$

Soit $(\hat{\theta}_n)_{n \geq 1}$ une suite de racines de l'équation $\partial_\theta \ell_\theta(X_1, \dots, X_n) = 0$
telle que $\hat{\theta}_n$ est un estimateur fortement consistant de θ .

On pose

$$Y_n = (n I_{X_1}(\theta))^{1/2} [\hat{\theta}_n - \theta].$$

Alors $Y_n \xrightarrow{(\mathcal{L})} \mathcal{N}(0, 1)$.

Remarques

Définition: on dit que θ_n est asymptotiquement normal.

Optimalité de l'EMV:

Les théorèmes précédents montrent que l'EMV est

- Fortement consistant
- Asymptotiquement sans biais
- Asymptotiquement efficace
- Asymptotiquement gaussien