

Probabilités et statistique

Régression linéaire simple

Module 13

Plan

- Introduction
- Principe de modélisation
- Méthodes d'estimation des moindres carrés
- Table d'analyse de la variance pour la régression
- Intervalle de confiance pour les paramètres
- Utilité de la régression
- Coefficient de détermination et de corrélation

1. Introduction

Soient deux variables X et Y :

Y : variable expliquée (dépendante) ou variable réponse

X : variable explicative (indépendante)

On cherche à modéliser (expliquer) la variable Y à l'aide de la variable X .

Exemple :

Y : note d'un étudiant à un examen

X : nombre d'heures passées à étudier pour l'examen



2. Principe de modélisation

On cherche toujours le modèle le plus simple possible.

Soit le modèle suivant dans la population: $Y = \beta_0 + \beta_1 X + \varepsilon$. L'erreur aléatoire ε est supposée $N(0, \sigma^2)$.


$$Y \sim N(\beta_0 + \beta_1 X, \sigma^2)$$

β_0 représente l'ordonnée à l'origine et β_1 représente la pente.

β_0 et β_1 sont des paramètres inconnus qui se rapportent à la population. Ils doivent donc être estimés.

L'échantillon contient n paires d'observations $(x_1, y_1), \dots, (x_n, y_n)$. Plaçons ces paires sur un graphique.

Estimation des paramètres de β_0 et β_1 :



À partir de cette figure, nous pouvons observer que :

$$\hat{y}_2 = \hat{\beta}_0 + \hat{\beta}_1 x_2$$

$$y_2 = \hat{\beta}_0 + \hat{\beta}_1 x_2 + \hat{\varepsilon}_2$$

$$\text{Résidu : } \hat{\varepsilon}_2 = y_2 - \hat{y}_2$$

3. Méthode d'estimation des moindres carrés ordinaires (m.c.o)

On veut estimer β_0 et β_1 de façon à minimiser les erreurs du modèle :

$$\min_{\beta_0, \beta_1} \sum_{i=1}^n \varepsilon_i^2 = \min_{\beta_0, \beta_1} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Étapes de résolution :

- Il faut dériver par rapport à β_0 et β_1
- Égaliser à 0
- Résoudre le système (pour trouver les estimateurs de β_0 et β_1).

$$\frac{\partial}{\partial \beta_0} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0.$$

$$\text{On a donc que } -2 \sum_{i=1}^n y_i + 2n\hat{\beta}_0 + 2\hat{\beta}_1 \sum_{i=1}^n x_i = 0.$$

$$\frac{\partial}{\partial \beta_1} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) x_i = 0.$$

$$\text{On a donc que } -2 \sum_{i=1}^n y_i x_i + 2 \hat{\beta}_0 \sum_{i=1}^n x_i + 2 \hat{\beta}_1 \sum_{i=1}^n x_i^2 = 0.$$

Après résolution du système, nous obtenons :

$$\hat{\beta}_0 = \frac{\sum_{i=1}^n y_i - \hat{\beta}_1 \sum_{i=1}^n x_i}{n} = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\begin{aligned} \hat{\beta}_1 &= \frac{\sum_{i=1}^n x_i y_i - \hat{\beta}_0 \sum_{i=1}^n x_i}{\sum_{i=1}^n x_i^2} = \frac{\sum_{i=1}^n x_i y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) \sum_{i=1}^n x_i}{\sum_{i=1}^n x_i^2} = \frac{\sum_{i=1}^n x_i y_i - \bar{y} \sum_{i=1}^n x_i + \hat{\beta}_1 \bar{x} \sum_{i=1}^n x_i}{\sum_{i=1}^n x_i^2} \\ &= \frac{\sum_{i=1}^n x_i (y_i - \bar{y})}{\sum_{i=1}^n x_i (x_i - \bar{x})} = \frac{S_{XY}}{S_{XX}} \end{aligned}$$

Voici les estimateurs de β_0 et β_1 :

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$$
$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

On pose aussi :

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$$

$$S_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - n\bar{y}^2$$


$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}$$

Exemple :

x_i	y_i	x_i^2	y_i^2	$x_i y_i$
2	3	4	9	6
3	3	9	9	9
4	2	16	4	8
5	4	25	16	20
5	5	25	25	25
6	3	36	9	18
6	4	36	16	24
7	4	49	16	28
8	5	64	25	40
8	6	64	36	48
54	39	328	165	226

X : quantité d'eau sur un lopin de terre

Y : quantité de blé récolté



$$\bar{x} = 5.4$$

$$\bar{y} = 3.9$$

$$S_{xx} = 328 - 10 \times 5.4^2 = 36.4$$

$$S_{yy} = 165 - 10 \times 3.9^2 = 12.9$$

$$S_{xy} = 226 - 10 \times 5.4 \times 3.9 = 15.4$$

$$\Rightarrow \hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{15.4}{36.4} = 0.4231$$

$$\Rightarrow \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 3.9 - 0.4231 \times 5.4 = 1.6153$$

La droite de régression est donc $\hat{y} = 1.6153 + 0.4231x$.

Voici les coordonnées de quelques points sur la droite :

$$x = 0 \Rightarrow \hat{y} = 1.6153$$

$$x = 8 \Rightarrow \hat{y} = 5.0001$$

$$x = 5.4 \Rightarrow \hat{y} = 3.9$$


Note : La droite de régression passe toujours par $(\bar{x}, \bar{y})$ quand elle a un paramètre β_0 .

Question : Y a-t-il une relation linéaire significative entre X et Y ?

Exemple :

X : la quantité de pluie tombée au Canada

Y : le prix du blé au Sénégal



$$\hat{\beta}_1 \cong 0$$

ceci indique qu'il n'y a pas de relation linéaire entre X et Y .

H_0 : Il n'y a pas de relation linéaire entre X et Y ($\beta_1 = 0$).

vs

H_1 : Il y a une relation linéaire entre X et Y (β_1 est différent de 0).

4. Table d'analyse de la variance pour la régression

On décompose la variabilité totale des y_i en 2 parties :

$$\begin{aligned} SCT &= S_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2 \\ &= \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 \\ &= SCE + SCM \end{aligned}$$

SCT : Variabilité totale de y

SCM : Variation de y expliquée par le modèle

SCE : Variation de y inexpliquée par le modèle

Table d'analyse de la variance

Source	Somme des carrés	Degrés de liberté	Carrés moyens	Statistique
Régression	<i>SCM</i>	1	<i>SCM / 1 = MCM</i>	$F_{\text{observé}} = MCM/MCE$
Erreur	<i>SCE</i>	$n - 2$	$SCE / (n - 2) = MCE$	
Total	<i>SCT</i>	$n - 1$		

$$\begin{aligned}
SCM &= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = \sum_{i=1}^n (\hat{\beta}_0 + \hat{\beta}_1 x_i - \hat{\beta}_0 - \hat{\beta}_1 \bar{x})^2 \\
&= \sum_{i=1}^n (\hat{\beta}_1 x_i - \hat{\beta}_1 \bar{x})^2 = \hat{\beta}_1^2 \sum_{i=1}^n (x_i - \bar{x})^2 \\
&= \hat{\beta}_1^2 S_{xx} = \hat{\beta}_1 \left(\frac{S_{xy}}{S_{xx}} \right) S_{xx} = \hat{\beta}_1 S_{xy}
\end{aligned}$$

Ainsi, nous avons :

$$SCT = S_{yy}$$

$$SCM = \hat{\beta}_1^2 S_{xx} = \hat{\beta}_1 S_{xy}$$

$$SCE = SCT - SCM$$

Exemple :

Soit X , la quantité d'eau reçue par le lopin de terre.

Soit Y , la quantité de blé récoltée

$H_0 : \beta_1 = 0$ (il n'y a pas de relation linéaire entre X et Y)

VS

$H_1 : \beta_1$ est différent de 0 (il y a une relation linéaire entre X et Y)

Source de variation	Somme des carrés	Degrés de liberté	Carrés moyens	$F_{\text{observé}}$
Modèle	6.5157	1	6.5157	8.165
Erreur	6.3843	8	0.7980	
Total	12.9			

$$SCT = S_{yy} = 12.9$$

$$SCM = \hat{\beta}_1 S_{xy} = 0.4231 \times 15.4 = 6.5157$$

$$SCE = SCT - SCM = 12.9 - 6.5157 = 6.3843$$

$$E(MCE) = \sigma^2$$

$\Rightarrow \hat{\sigma}^2 = MCE$ est un estimateur de la variance de l'erreur.

$$F_{\text{observé}} = \frac{MCM}{MCE}$$

Plus $F_{\text{observé}}$ est élevé, plus la preuve en faveur de H_1 est forte.

On rejette H_0 au seuil α si $F_{\text{observé}} > F_{\alpha, 1, n-2}$.

Suite de l'exemple :

Sous $H_0 : F_{\text{observé}} = 6.349$; $F_{0.05, 1, 8} = 5.32$.

Puisque $F_{\text{observé}} > F_{0.05, 1, 8}$, on rejette H_0 au seuil $\alpha = 0.05$

Par conséquent, il y a une relation linéaire entre X et Y .

5. Intervalle de confiance pour les paramètres

a) Intervalle de confiance pour β_0 et β_1 au niveau $1 - \alpha$

$$IC(\beta_0) = \hat{\beta}_0 \pm t_{\alpha/2, n-2} \sqrt{MCE \times \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}$$

$$IC(\beta_1) = \hat{\beta}_1 \pm t_{\alpha/2, n-2} \sqrt{\frac{MCE}{S_{xx}}}$$

Exemple : Pour un niveau de confiance de 95%

$$IC(\beta_0) = 1.6153 \pm 2.306 \sqrt{0.798 \times \left(\frac{1}{10} + \frac{(5.4)^2}{36.4} \right)} = 1.6153 \pm 2.306 \times 0.848 = [-0.3402, 3.5708]$$

$$IC(\beta_1) = 0.4231 \pm 2.306 \sqrt{\frac{0.798}{36.4}} = 0.4231 \pm 2.306 \times 0.1481 = [0.0817, 0.7645]$$

Comme $0 \notin IC(\beta_1)$, on rejette H_0 au seuil de 5 %. Ce qui confirme ainsi la conclusion précédente (il existe une relation linéaire entre X et Y).

Interprétation

$\hat{\beta}_0$: ordonnée à l'origine de la droite de régression valeur de $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ lorsque $x = 0$.

Exemple :

$$\hat{\beta}_0 = 1.6154$$

correspond à la quantité moyenne de blé estimée sur un lopin de terre n'ayant pas reçu d'eau.

Dans certains cas le $\hat{\beta}_0$ n'est pas interprétable surtout quand il n'y a pas d'observations proches de $x = 0$.

Exemple :

Soit Y , le poids en kg

Soit X , l'âge en mois d'un individu

$$\hat{y} = -3.15 + 2.17x$$

$\hat{\beta}_0 = -3.15$ ne correspond pas au poids moyen estimé à la naissance de l'individu.

$\hat{\beta}_1$: pente de la droite de régression.

Lorsque x augmente de 1, y augmente en moyenne de $\hat{\beta}_1$.

Exemple :

$$\hat{\beta}_1 = 0.4231$$

Signification : Pour chaque m^3 d'eau reçue, la quantité de blé augmente de 0.4231 kg.

b) Estimation de $E(Y|x_0)$.

Considérons x_0 une valeur particulière de x .

On estime $E(Y | x_0)$ par : $\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$

Exemple :

$E(Y | x = 5)$: valeur moyenne de la quantité de blé y selon le modèle pour les lopins de terre ayant reçu 5 m^3 d'eau.

La valeur moyenne estimée $\hat{E}(Y | x = 5) = 1.6154 + 0.4231 \times 5 = 3.7309$

c) Intervalle de confiance pour la moyenne de x sachant que $x = x_0$.


$$\hat{E}(Y | x_0) = \hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$$

$$IC(y_0) = \hat{y}_0 \pm t_{\alpha/2, n-2} \sqrt{MCE \times \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right)}$$

Exemple :

$$\hat{y}_0 = 1.6153 + (0.4231) \times 5 = 3.7308$$

$$\begin{aligned} IC(y_0) &= 3.7308 \pm 2.306 \times \sqrt{0.798 \times \left(\frac{1}{10} + \frac{(5 - 5.4)^2}{36.4} \right)} \\ &= 3.7308 \pm 2.306 \times 0.2886 = 3.7308 \pm 0.6655 \\ &= [3.0653, 4.3963] \end{aligned}$$



6. Utilité de la régression

- Elle permet de mieux comprendre la relation entre X et Y .
- Elle permet de prédire Y à partir de X dans les cas où Y est difficile à mesurer.

Estimation de la valeur prédite y_0 .

y_0 : valeur prédite de y par le modèle pour un individu particulier x_0 .

$$y_0 = \beta_0 + \beta_1 x_0 + \varepsilon_0 = E(Y | x_0) + \varepsilon_0$$

$$\varepsilon_0 \sim N(0, \sigma^2)$$

Exemple

Un lopin de terre a reçu 5 m³ d'eau.

La valeur prévue de la quantité de blé obtenue est :

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0 = 1.6154 + (0.4231) \times 5 = 3.7308$$

Prévision de nouvelles observations : Intervalle de confiance pour y_0 au niveau $1 - \alpha$:

$$\hat{y}_0 \pm t_{\alpha/2, n-2} \sqrt{MCE \times \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right)}$$

Exemple :

$$\begin{aligned} IC(y_0) &= 3.7308 \pm 2.306 \times \sqrt{0.798 \times \left(1 + \frac{1}{10} + \frac{(5 - 5.4)^2}{36.4} \right)} \\ &= 3.7308 \pm 2.306 \times 0.9335 \\ &= [1.5781, 5.8835] \end{aligned}$$

Remarque :

Plus $(x_0 - \bar{x})^2$ est grand, moins le modèle fait une bonne prédiction.

7. Coefficient de détermination et de corrélation

- Coefficient de détermination :



$$R^2 = \frac{SCM}{SCT} = \frac{\hat{\beta}_1^2 S_{xx}}{S_{yy}} \Rightarrow \text{Proportion de la variabilité totale de } y \text{ expliquée par } X.$$



$$0 \leq R^2 \leq 1$$

- Coefficient de corrélation ρ (théorique) et r (échantillonnal)



$$r = \pm \sqrt{R^2} \text{ où le signe est celui de la pente : } \begin{cases} -1 & \text{si } \hat{\beta}_1 < 0 \\ 1 & \text{si } \hat{\beta}_1 > 0 \end{cases}$$

$R^2 = 1$: Association linéaire parfaite (négative ou positive) entre x et y .





$$R^2 = \frac{\hat{\beta}_1^2 S_{xx}}{S_{yy}} = 0 \Rightarrow \hat{\beta}_1 = 0 \Rightarrow \text{aucune association linéaire}$$



Force de la relation

Si $R^2 > 0.9 \Rightarrow$ une relation forte

Si $R^2 \cong 0.6 \Rightarrow$ une relation moyenne

Si $R^2 < 0.4 \Rightarrow$ une relation faible

Note : r n'est pas une mesure d'association, c'est une mesure d'association **linéaire**.

Note : Plus les points sont éloignés de la droite de régression, plus R^2 est petit.