

Probabilités et statistique

Analyse de la variance

Module 12

Plan

- Introduction
- Comparaison de plusieurs moyennes
- Modèle
- Table d'analyse de la variance
- Validation du modèle

1. Introduction

L'analyse de variance permet de comparer simultanément les moyennes d'une variable dans plusieurs populations, en général normales et de même variance.

Exemples :

Un informaticien a 7 modèles d'ordinateurs qu'il désire comparer du point de vue de la performance.

Un médecin dispose de 3 médicaments servant à guérir une maladie. Il désire savoir s'ils sont équivalents ou si l'un d'entre eux guérit plus rapidement que les autres.

Un directeur de magasin d'appareils électroniques est intéressé à comparer 4 méthodes de publicité. Il veut savoir si ces méthodes sont équivalentes ou si l'une d'elles amène plus de clients que les autres.

2. Comparaison de plusieurs moyennes

a) $Y_i \sim N(\mu_i, \sigma^2)$ avec $i = 1, 2, \dots, a$

On suppose a populations indépendantes.

Prenons a échantillons de même taille (cas balancé), un pour chaque population à l'étude :

Population 1: $(y_{11}, y_{12}, \dots, y_{1n})$

Population 2: $(y_{21}, y_{22}, \dots, y_{2n})$

...

Population a : $(y_{a1}, y_{a2}, \dots, y_{an})$

Voici la moyenne des observations pour le traitement i et la moyenne générale de toutes les observations :

$$y_{i.} = \sum_{j=1}^n y_{ij} \Rightarrow \bar{y}_{i.} = y_{i.} / n$$

$$y_{..} = \sum_{i=1}^a \sum_{j=1}^n y_{ij} \Rightarrow \bar{y}_{..} = y_{..} / N$$

b) Hypothèses

Soit $H_0 : \mu_1 = \mu_2 = \dots = \mu_a$ vs $H_1 : \text{Au moins deux des moyennes } \mu_i \text{ ne sont pas égales.}$

Exemple :

On veut comparer 5 modèles de voitures par rapport à leur consommation d'essence.

Sont-elles équivalentes ? Laquelle est meilleure ?

	Marque	1	2	3	4
A	Chrysler	22	23	22	21
B	Volkswagen	23	26	25	22
C	Toyota	26	28	27	31
D	Honda	25	23	20	24
E	BMW	23	27	22	20

c) Vocabulaire :

Soit Y , la variable réponse

Exemple : la consommation d'essence

Facteur : Ce qui différencie les populations ou les traitements

Exemple : le modèle ou la marque

Unité expérimentale : Individu ou objet sur lequel la variable réponse est mesurée.

Exemple : automobile

Plan d'expérience : Procédure permettant d'attribuer les traitements aux unités expérimentales.

d) Notation

Soit y_{ij} : j^{e} observation du i^{e} traitement

Exemple (à partir de la diapositive 5) : $y_{21} = 23$, $y_{34} = 31$ etc ...

Exemple :

$$y_{3\bullet} = 26 + 28 + 27 + 31 = 112 \quad \Rightarrow \quad \bar{y}_3 = \frac{y_{3\bullet}}{4} = \frac{112}{4} = 28$$

Nombre total d'observations : $N = \sum_{i=1}^a n = an$

$$\text{Variabilité totale : } SCT = \sum_{i=1}^a \sum_{j=1}^n (y_{ij} - \bar{y}_{..})^2$$

3. Modèle

Soit le modèle suivant :

$$Y_{ij} = \mu + \tau_i + \varepsilon_{ij}$$

où y_{ij} : $j^{\text{ème}}$ observation prise lors du traitement i

μ : paramètre commun à tous les traitements, appelé moyenne générale

τ_i : paramètre associé au $i^{\text{ème}}$ traitement

ε_{ij} : composante (erreur) aléatoire

Ainsi, $Y_{ij} \sim N(\mu + \tau_i, \sigma^2)$, $i = 1, 2, \dots, a$, $j = 1, 2, \dots, n$.

Contrainte *pour le cas balancé*: $\sum_{i=1}^a \tau_i = 0$

Exemple :

Soit 3 populations (toutes de loi Normale) : $N(\mu_1, \sigma^2)$, $N(\mu_2, \sigma^2)$, $N(\mu_3, \sigma^2)$.

$$n_1 = n_2 = n_3 = 6$$

$$Y_{1j} \sim N(7, \sigma^2)$$

$$Y_{2j} \sim N(12, \sigma^2)$$

$$Y_{3j} \sim N(5, \sigma^2) \quad j = 1, 2, \dots, 6$$

$$Y_{ij} = \mu + \tau_i + \varepsilon_{ij} \quad i = 1, 2, 3$$

$$\mu = \frac{7+12+5}{3} = 8$$

$$\tau_1 = 7 - 8 = -1$$

$$\tau_2 = 12 - 8 = 4$$

$$\tau_3 = 5 - 8 = -3$$

$$\sum_{i=1}^3 \tau_i = -1 + 4 - 3 = 0 \Rightarrow \text{contrainte pour le cas balancé}$$

Hypothèse nulle :

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_a \Leftrightarrow H_0 : \tau_1 = \tau_2 = \dots = \tau_a$$

Partition de la somme des carrés :

$$\sum_{i=1}^a \sum_{j=1}^n (y_{ij} - \bar{y}_{..})^2 = \underbrace{\sum_{i=1}^a n(\bar{y}_{i.} - \bar{y}_{..})^2}_{\text{Variation de Y expliquée par les traitements (modèle)}} + \underbrace{\sum_{i=1}^a \sum_{j=1}^n (y_{ij} - \bar{y}_{i.})^2}_{\text{Variation de Y inexpliquée par les traitements}}$$

Variation totale de Y

$$\text{SCT} = \text{SCM} + \text{SCE}$$

SCT : Somme des carrés totale

SCM : Somme des carrés due au modèle

SCE : Somme des carrés des erreurs

4. Table d'analyse de la variance (ANOVA)

Source de variation	Somme des carrés	Degrés de liberté	Carrés moyens	F _{observé}
Modèle	SCM	a – 1	MCM = SCM/(a – 1)	MCM/MCE
Erreur	SCE	N – a	MCE = SCE/(N – a)	
Totale	SCT	N – 1		

Sous H_0 , nous avons :

$$F = \frac{MCM}{MCE} = \frac{SCM / (a - 1)}{SCE / (N - a)} \sim F_{a-1, N-a}$$

Exemple :

Marque	1	2	3	4	n	$\bar{y}_{i\cdot}$	$n(\bar{y}_{i\cdot} - \bar{y}_{..})^2$	$\sum_{j=1}^n y_{ij}^2$	$\sum_{j=1}^n (y_{ij} - \bar{y}_{i\cdot})^2$
A	22	23	22	21	4	22	16	1938	2
B	23	26	25	22	4	24	0	2314	10
C	26	28	27	31	4	28	64	3150	14
D	25	23	20	24	4	23	4	2130	14
E	23	27	22	20	4	23	4	2142	26
Total					20		88	11674	66

Regardons maintenant la diapositive suivante pour quelques détails sur ce tableau.

$$N = \sum_{i=1}^5 n = 20$$

$$\bar{y}_{..} = \sum_{i=1}^5 \sum_{j=1}^4 y_{ij} / N = 480 / 20 = 24$$

$$SCM = \sum_{i=1}^5 \frac{y_{i.}^2}{n} - \frac{y_{..}^2}{N} = 88$$

$$SCT = \sum_{i=1}^5 \sum_{j=1}^4 y_{ij}^2 - \frac{y_{..}^2}{N} = 11674 - 480^2 / 20 = 154$$

$$SCE = SCT - SCM$$

À l'aide des résultats précédents, nous pouvons maintenant établir la table d'ANOVA pour cet exemple (voir la diapositive suivante).

Table d'ANOVA

Source de variation	Somme des carrés	Degrés de liberté	Carrés moyens	$F_{\text{observé}}$
Modèle	88	4	22	5
Erreur	66	15	4.4	
Total	154	19		

Sous $H_0 : \tau_1 = \tau_2 = \dots = \tau_a = 0$

$$\frac{SCT}{\sigma^2} \sim \chi^2_{N-1}$$

$$\frac{SCM}{\sigma^2} \sim \chi^2_{a-1}$$

$$\frac{SCE}{\sigma^2} \sim \chi^2_{N-a}$$

Les variables $\frac{SCM}{\sigma^2}$ et $\frac{SCE}{\sigma^2}$ étant indépendantes alors

$$F = \frac{SCM / \sigma^2 \times (a-1)}{SCE / \sigma^2 \times (N-a)} = \frac{SCM / (a-1)}{SCE / (N-a)} \sim F_{a-1, N-a}$$

La loi de Fisher est tabulée aux pages 551 à 555 du livre de référence.

$H_0 : \mu_1 = \mu_2 = \dots = \mu_a$ vs $H_1 : \text{au moins deux des moyennes } \mu_i \text{ ne sont pas égales.}$

$$\text{Sous } H_0 : F_{\text{observé}} = \frac{SCM/(a-1)}{SCE/(N-a)};$$

on rejette H_0 au seuil α si $F_{\text{observé}} \geq F_{\alpha, a-1, N-a}$.

Exemple : Consommation d'essence des modèles de voiture

$$\text{Sous } H_0 : F_{\text{observé}} = 5. \quad F_{0.05, 4, 15} = 3.055$$

On rejette donc H_0 au seuil de 5 %, car $F_{\text{observé}} > F_{0.05, 4, 15}$ ($5 > 3.055$).

Ainsi, les modèles de voiture diffèrent quant à leur consommation d'essence.

Comparaisons multiples :

On calcule d'abord la plus petite différence significative.

$$PPDS = t_{\alpha/2, N-a} \sqrt{2 \times MCE / n}$$

On ordonne en croissance les moyennes des traitements.

On déclare significativement différentes les moyennes dont l'écart est supérieur à la PPDS.

Exemple : La consommation d'essence

Pour $\alpha = 0.05$, $PPDS = t_{0.025, 15} \sqrt{2 \times 4.4 / 4} = 3.16$

On écrit en ordre croissant les 5 moyennes:

$\bar{y}_A$	$\bar{y}_D$	$\bar{y}_E$	$\bar{y}_B$	$\bar{y}_C$
22	23	23	24	28

On déclare significativement différentes les moyennes dont l'écart est supérieur à la PPDS.

On constate que :

$$\mu_A < \mu_C$$

$$\mu_D < \mu_C$$

$$\mu_E < \mu_C$$

$$\mu_B < \mu_C$$

Seule la marque Toyota a une consommation d'essence différente des autres marques d'automobiles.

Ainsi, nous avons les comparaisons multiples suivantes :

A	D	E	B	C
22	23	23	24	28

Notons qu'une ligne droite lie les moyennes qui ne sont pas significativement différentes les unes des autres.

5. Validation du Modèle

2 hypothèses à vérifier :

- Normalité des erreurs
- Homogénéité des variances

Nous avons le modèle suivant :

$$Y_{ij} = \mu + \tau_i + \varepsilon_{ij} \text{ avec } \varepsilon_{ij} \text{ iid } N(0, \sigma^2)$$

On vérifie ces hypothèses au moyen des résidus.

$$\text{Résidu : } e_{ij} = y_{ij} - \bar{y}_{i.}$$

Exemple :


Marque	1	2	3	4	n	$\bar{y}_{i.}$	e_{ij}			
A	22	23	22	21	4	22	0	1	0	-1
B	23	26	25	22	4	24	-1	2	1	-2
C	26	28	27	31	4	28	-2	0	-1	3
D	25	23	20	24	4	23	2	0	-3	1
E	23	27	22	20	4	23	0	4	-1	-3

Vérification de la normalité :

Cette vérification s'effectue par un diagramme en boîte ou par un histogramme des résidus.


Histogramme

Valeurs	-3	-2	-1	0	1	2	3	4
Fréquence	2	2	4	5	3	2	1	1



Il n'y a pas de problème avec la normalité car la distribution des résidus est assez symétrique et possède un seul maximum.


Vérification de l'homogénéité des variances




Étant donné que la distribution des points est assez symétrique autour de l'axe des x, on peut conclure qu'il n'y a pas de problème d'homogénéité.

Cas où il y a hétérogénéité

$$Y_i \sim N(\mu_i, \sigma_i^2) \quad \text{avec } i = 1, 2, \dots, a$$



La variance augmente avec la catégorie
(tendance)



La variance est inégale

Transformations pour stabiliser la variance lorsque les points représentent une tendance systématique :

$$Y_{ij}^* = \sqrt{Y_{ij}} \quad \text{ou} \quad Y_{ij}^* = \ln(Y_{ij})$$