

**Master 1 Informatique**  
Analyse de Données  
Module 1 Introduction à l'analyse de données  
Exercices conceptuels et corrigé

Département d'Informatique, Université Joseph KI-ZERBO

**Table des matières**

|                      |          |
|----------------------|----------|
| Énoncé des exercices | <b>2</b> |
| Corrigé magistral    | <b>5</b> |

# ÉNONCÉ DES EXERCICES

## Exercice 1 Donnée, information, connaissance

On dispose du jeu de données suivant :

| ID | Température | Ville | Date  |
|----|-------------|-------|-------|
| 1  | 39.2        | A     | 01/03 |
| 2  | 36.8        | A     | 01/03 |
| 3  | 40.1        | B     | 01/03 |

1. Identifier les données brutes.
2. Donner deux exemples dinformation.
3. Proposer une connaissance possible et discuter sa validité.
4. Expliquer pourquoi la connaissance peut être fausse.

## Exercice 2 Typologie des variables

Classer les variables suivantes :

- Adresse IP
- Niveau détude (Licence, Master, Doctorat)
- Nombre de connexions par jour
- Score de satisfaction (1 à 5)
- Image JPEG

1. Donner leur type.
2. Préciser lespace mathématique associé.
3. Discuter les erreurs possibles si elles sont toutes traitées comme numériques.
4. Proposer une représentation exploitable pour limage.

## Exercice 3 Formalisation mathématique

On observe  $n$  étudiants décrits par :

- âge
- moyenne générale
- filière
- nombre dabsences

1. Formaliser le jeu de données.
2. Préciser les espaces dappartenance.
3. Identifier les variables nécessitant un encodage.
4. Discuter si une matrice  $X \in \mathbb{R}^{n \times p}$  suffit sans transformation.

## Exercice 4 Analyse critique dun pipeline

Pipeline proposé :

1. Charger les données
  2. Appliquer K-means
  3. Faire un graphique
  4. Interpréter
1. Identifier les étapes manquantes.
  2. Expliquer les risques méthodologiques.
  3. Proposer un pipeline correct.
  4. Discuter les cas où K-means est inadapté.

## Exercice 5 Corrélation et causalité

On observe :

$$\text{Corr}(X, Y) = 0.82$$

1. Peut-on conclure à une causalité ?
2. Proposer trois scénarios explicatifs.
3. Que faudrait-il pour approcher une relation causale ?
4. Discuter le rôle des variables latentes.

## Exercice 6 Biais de sélection

Un modèle est entraîné uniquement sur les étudiants admis.

1. Identifier le biais.
2. Expliquer limpact sur la généralisation.
3. Proposer une correction.
4. Discuter les implications éthiques.

## Exercice 7 Haute dimension

On compare :

- Cas A :  $n = 10^6$ ,  $p = 5$
  - Cas B :  $n = 50$ ,  $p = 10\,000$
1. Quel cas est le plus problématique ?
  2. Expliquer la malédiction de la dimension.
  3. Proposer une stratégie pour le cas B.
  4. Discuter la stabilité des estimations.