

Projets Analyse des Données

M1 Informatique

UJKZ

KFV

March 24, 2026

Consignes générales

Chaque groupe travaille sur un jeu de données spécifique.

Les analyses doivent être réalisées avec R.

Important :

- Toute réponse doit être justifiée.
- Les graphiques doivent être interprétés.
- Les résultats numériques sans commentaire ne seront pas pris en compte.

Organisation du travail :

1. Exploration des données
2. ACP
3. Clustering
4. Classification
5. Régression
6. Discussion

1 Groupe 1 : Données de santé

1.1 Exploration

1. Donner un résumé statistique des variables.
2. Identifier les variables les plus corrélées.
3. Représenter graphiquement les distributions.
4. Interpréter les relations entre IMC, tension et cholestérol.

1.2 ACP

1. Standardiser les données.
2. Calculer les valeurs propres.
3. Combien d'axes retenir ? Justifier.
4. Interpréter les deux premiers axes.

1.3 Clustering

1. Appliquer K-means pour $K = 2, 3, 4$.
2. Proposer un nombre optimal de clusters.
3. Interpréter les groupes obtenus.

1.4 Classification

1. Proposer un modèle de régression logistique.
2. Identifier les variables significatives.
3. Construire une matrice de confusion.

1.5 Régression

1. Modéliser la tension systolique.
2. Interpréter les coefficients.
3. Analyser les résidus.

1.6 Discussion

1. Les résultats sont-ils cohérents médicalement ?
2. Quelles limites identifiez-vous ?

2 Groupe 2 : Données agronomiques

2.1 Exploration

1. Comparer les variables selon la saison.
2. Étudier l'effet de l'espèce sur le rendement.
3. Identifier les corrélations principales.

2.2 ACP

1. Réaliser une ACP sur les variables quantitatives.
2. Interpréter les axes.
3. Visualiser les individus par espèce.

2.3 Clustering

1. Appliquer une classification hiérarchique.
2. Comparer avec K-means.
3. Les clusters correspondent-ils aux espèces ?

2.4 Classification

1. Transformer le rendement en variable binaire.
2. Construire un modèle prédictif.

2.5 Régression

1. Modéliser le rendement.
2. Interpréter l'effet de la pluie et de la biomasse.

2.6 Discussion

1. L'effet saisonnier est-il dominant ?
2. Quelles recommandations agronomiques peut-on proposer ?

3 Groupe 3 : Données financières

3.1 Exploration

1. Décrire les distributions des variables.
2. Identifier les variables les plus instables.

3.2 ACP

1. Réaliser une ACP.
2. Interpréter les axes (facteurs de marché ?).

3.3 Clustering

1. Identifier des groupes d'actifs.
2. Interpréter économiquement les clusters.

3.4 Classification

1. Prédire la performance.
2. Évaluer la qualité du modèle.

3.5 Régression

1. Expliquer le rendement par les autres variables.
2. Le modèle est-il pertinent ?

3.6 Discussion

1. Pourquoi les résultats sont-ils plus bruités ?
2. Quelles limites des modèles statistiques en finance ?

4 Groupe 4 : Données marketing

4.1 Exploration

1. Décrire les profils clients.
2. Identifier les variables clés du comportement d'achat.

4.2 ACP

1. Réduire la dimension.
2. Interpréter les axes (profil économique vs comportemental).

4.3 Clustering

1. Identifier des segments clients.
2. Décrire chaque segment.

4.4 Classification

1. Prédire les clients premium.
2. Interpréter les variables importantes.

4.5 Régression

1. Modéliser le score de dépense.

4.6 Discussion

1. Quelle stratégie marketing proposer ?

5 Groupe 5 : Données simulées

5.1 Exploration

1. Identifier les variables pertinentes.
2. Détecter les variables bruitées.

5.2 ACP

1. Quelles variables dominant les axes ?

5.3 Clustering

1. Retrouver le nombre de groupes.
2. Comparer avec la variable vraie.

5.4 Classification

1. Prédire la classe.
2. Mesurer la précision.

5.5 Régression

1. Tester un modèle (même si peu pertinent).
2. Interpréter les résultats.

5.6 Discussion

1. Quelles variables sont inutiles ?
2. Les méthodes ont-elles retrouvé la vraie structure ?

5.7 Groupe 6 : Données de santé

Objectif : Étudier les facteurs influençant la présence d'une maladie.

1. Réaliser une analyse descriptive complète des variables.
2. Étudier les corrélations entre les variables explicatives.
3. Effectuer une ACP et interpréter les axes principaux.
4. Proposer un modèle de régression logistique pour expliquer la variable cible.
5. Tester la pertinence du modèle obtenu.
6. **Question critique :** Le modèle linéaire est-il adapté ? Justifier.
7. Proposer une amélioration du modèle si nécessaire.
8. Conclure sur les facteurs de risque identifiés.

5.8 Groupe 7 : Données agronomiques

Objectif : Analyser les facteurs influençant le rendement.

1. Réaliser une analyse descriptive des variables.
2. Étudier les relations entre les variables climatiques et agronomiques.
3. Réaliser une ACP et interpréter les axes.
4. Proposer un modèle de régression du rendement.
5. **Question critique :** Existe-t-il des effets d'interaction entre variables ?
6. Tester l'ajout d'un terme d'interaction et comparer les modèles.
7. Interpréter les résultats obtenus.
8. Discuter les limites du modèle.

5.9 Groupe 8 : Données financières

Objectif : Identifier les facteurs expliquant la performance.

1. Décrire les variables du jeu de données.
2. Étudier les corrélations entre les variables financières.
3. Réaliser une ACP et interpréter les axes principaux.
4. **Question critique :** Peut-on identifier des facteurs latents ?
5. Réaliser une classification des observations.
6. Comparer les groupes obtenus avec la variable cible.
7. Proposer un modèle de classification.
8. Discuter la qualité des résultats obtenus.

5.10 Groupe 9 : Données marketing

Objectif : Identifier les profils de clients et prédire les clients premium.

1. Réaliser une analyse descriptive des variables.
2. Mettre en évidence des groupes de clients (clustering).
3. Interpréter les segments obtenus.
4. Proposer un modèle de classification.
5. **Question critique :** La répartition des classes pose-t-elle problème ?
6. Évaluer les performances du modèle.
7. Discuter les erreurs de classification.
8. Proposer des améliorations.

5.11 Groupe 10 : Données simulées

Objectif : Retrouver la structure des données.

1. Réaliser une analyse descriptive.
2. Effectuer une ACP et analyser la structure.
3. Appliquer des méthodes de clustering.
4. Déterminer le nombre optimal de groupes.
5. Comparer les résultats avec la variable de référence.
6. **Question critique :** Toutes les variables sont-elles utiles ?
7. Identifier les variables pertinentes.
8. Discuter la qualité de la classification obtenue.