

TD 1 : Introduction à R

Créer un nouveau répertoire sur votre clé que vous nommez **TDStat** puis dans ce répertoire un répertoire que vous nommez **TD1**.

NB : les noms des répertoires ne doivent pas comporter d'espace ou de point.

Lancer RStudio et grâce à l'onglet *Session – Set Working Directory – Choose Directory*, choisir ce répertoire **TD1**. Créer un R Script (*File – New File – R Script*) et le sauvegarder sous le nom **codeTD1**.

NB : Pour faire des commentaires en R, on met le caractère **#** devant la ligne de commentaires.

Le point-virgule permet d'écrire plusieurs instructions sur une même ligne.

Exercice 0 : objets de R

1. **Les vecteurs (vector c(...))** : Penser à un vecteur comme étant une colonne d'un tableau, d'où le **c(...)**. C'est une suite ordonnée finie de chaînes de caractères ou de nombres. Les chaînes de caractères sont écrites entre guillemets. Attention à l'écriture décimale des nombres qui se fait avec un point, la virgule sert de séparateur.

Exemples : taper les instructions suivantes

```
a=c(5,18,15,21,4) ; b=c("F","G", "H")      # Création de deux vecteurs
a[2] ; b[1] ; 2*a ; a+a ; a^2 ; a/2          # Opérations sur les vecteurs
a1=a[-c(1,3)] ; a2= a[c(1,3)]               # Enlève / sélectionne une ou plusieurs données
suite=seq(10,20,by=2)                       # Construction d'un vecteur à l'aide d'une séquence
```

2. **Les tableaux de données (data.frame(...))** : c'est un tableau dont les *colonnes sont les variables* (les vecteurs vus plus haut) et les *lignes sont les observations* (individus) : chaque ligne correspond à un seul individu. Par exemple, on considère 5 individus (3 femmes et 2 hommes) et pour chacun on a deux VD : X et Y.

Exemples :

- Taper

```
S= c("F", "F","H", "H", "F") ; X=c(12,15,13,8,18) ; Y=c(10,18,11,12,22)
Donnees=data.frame(S,X,Y) ; Donnees          # Création puis affichage du tableau
I3=Donnees[3,] ; V2=Donnees[,2]              # Accéder à un individu ou à une variable
```

- Construction d'un sous-tableau selon un critère :

```
DonneesF=Donnees[S=="F",]                   # Sélection des femmes
```

En exercice, sélectionner les hommes

- Ajouter une observation ou une variable à la fin :

```
l=c("H",4,9) ; Donneesmod1=rbind(Donnees,l)      # Ajouter une observation
Z=c(17,21,9,11,15) ; Donneesmod2=cbind(Donnees,Z) # ajouter une donnée
```

Exercice 1 : création et importation d'un fichier tableur (excel ou libre office) -statistiques descriptives-

On a suivi l'évolution d'un groupe de 15 femmes et de 15 hommes adultes répartis en trois groupes équilibrés selon leur âge (20-30 ans codé 1, 30-45 ans codé 2, +45 ans codé 3). Tous ces sujets suivaient la même formation d'apprentissage dans un centre pour adultes. Ils ont été évalués à trois périodes de leur formation (début, milieu, fin).

1. Écrire le plan expérimental sous-jacent.
2. Faire un fichier LibreOffice nommé **apprentissage** contenant en colonne 5 variables : *sujet*, *sexe*, *age*, *debut*, *milieu*, *fin*. Compléter les valeurs des trois premières variables en numérotant les sujets de 1 à 30, les 15 premiers étant les femmes (codé F) et les 15 derniers des hommes (codé H). Pour les âges, mettre aux 5 premières femmes le code 1, aux 5 suivantes le code 2 et aux 5 dernières de code 3. Faire de même pour les hommes.

Attention : ne mettez pas de lettres accentuées ni d'espaces dans les noms des variables.

3. Ouvrez le fichier **VDapprentissage** avec LibreOffice, copier et coller les valeurs des 3 VD.
4. Sauver ce fichier en format CSV.
5. Importer ce fichier sous R Studio (*File - import DataSet - from CSV*)
6. L'attacher avec l'instruction `attach(apprentissage)` pour pouvoir accéder aux variables.
7. Déclaration des variables qualitatives (ou facteurs) : `sexe=factor(sexe)` ; `age=factor(age)`

Exercice 2 : manipulations de fichier et statistiques descriptives

1. Calculs de moyennes, variances et écart-types :
 - a. Avec les fonction `mean()`, `var()` et `sd()`, calculer les moyennes, variances et écart-types corrigés des VD

Ex : `mean(debut)`

- b. Utiliser sur les VD la fonction `summary()` : quels résultats donne-t-elle ?

2. Statistiques par groupes : fonction `tapply()`

Chercher de l'aide sur cette fonction à l'aide de `help(tapply)` et l'utiliser pour calculer les moyennes de la VD *debut* pour les hommes et pour les femmes puis pour les trois tranches d'âge. Enfin calculer les moyennes des 6 groupes *sexe* age* en utilisant en plus la fonction `interaction()`.

3. Table des effectifs des modalités d'un ou deux facteurs : fonction `table()` et table des fréquences : fonction `prop.table()`.

- Taper : `effectifsexe=table(sexe)` ; `effectifsexe` ; `prop.table(effectifsexe)`
- Faire de même pour la variable *age*.
- Table de contingence de deux facteurs : `SA=table(sexe,age)` ;
- Table des fréquences de deux facteurs : `PSA=prop.table(SA)` ;
- Pourcentage lignes et colonnes : `PSAL=prop.table(SA,1)` ; `PSAC=prop.table(SA,2)`

4. Codage d'une variable quantitative en facteur : fonction `cut()`.

On veut créer une nouvelle variable nommée *classesdebut* qui contiendra le codage suivant de la VD *debut* :

debut < 8 : faible ; *debut* ≥ 8 *debut* < 10 : passable ;
debut ≥ 10 et *debut* < 12 : moyen ; *debut* ≥ 12 : bon

On déclare dans un premier temps le **vecteur des points de rupture**, sans oublier le minimum et le maximum : `Rup=c(0,8,10,12,20)`

et les étiquettes des catégories : `etiq=c("faible","passable","moyen","bon")`

Taper : `classesdebut=cut(debut,breaks=Rup);table(classesdebut)`

Que remarquez-vous ? Corrigez pour fermer les classes à gauche et les ouvrir à droite en changeant les options de `cut()` en tapant :

`classesdebut=cut(debut,Rup,right=FALSE,include.lowest=TRUE);table(classesdebut)`

Insérer les étiquettes des classes (chercher dans l'aide de `cut()`)

5. Graphiques

- Histogrammes : taper successivement une à une les instructions suivantes et constater le résultat d'une instruction avant de passer à la suivante.

`hist(debut)`

`hist(debut,probability=TRUE)`

`hist(debut,probability=TRUE,main="Histogramme de debut",ylab="")`

`hist(debut,probability=TRUE,breaks=seq(6,20),main="Histogramme de debut",ylab="")`

`hist(debut,probability=TRUE,breaks=seq(6,20),col='blue',main="Histogramme de debut",ylab="")`

`hist(debut,probability=TRUE,breaks=seq(6,20,by=2),col='orange',main="Histogramme de debut",ylab="")`

`curve(dnorm(x,mean(debut),sd(debut)),add=TRUE,col='red')`

`curve(dnorm(x,mean(debut),sd(debut)),add=TRUE,col='red',lwd=2)`

- Boîtes à moustaches: fonction `boxplot()`

`boxplot(debut)`

`boxplot(debut,range=0)`

`boxplot(debut, main="debut")`

`boxplot(debut, main="debut",col="red")`

`boxplot(debut~age,main="debut",xlab="age",col="blue")`

Dessiner les boîtes à moustache de la variable *fin* pour les hommes et les femmes sur le même graphique.

- Nuages de points et droite de régression : fonctions `plot()`, `lm()` et `abline()`

`plot(milieu,debut)`

`plot(milieu,debut,main="Nuage de points")`

`plot(milieu,debut, main="Nuage de points",col="red",pch=8)`

`modele=lm(debut~milieu)`

`abline(modele,col="blue")`

- Plusieurs graphiques sur la même fenêtre :

`par(mfrow=c(1,2))`

`hist(debut)`

`boxplot(debut)`

Changer `c(1,2)` en `c(2,1)`