

TP : Manipuler les expressions régulières avec Python

Objectifs

Ce TP vous permet de pratiquer les expressions régulières avec le module `re` de Python. Vous allez :

- Écrire des regex simples pour rechercher des motifs dans du texte,
- Utiliser `re.findall`, `re.match`, `re.sub`,
- Créer des scripts de filtrage ou nettoyage de texte.

Partie 1 : Recherche de motifs simples

1.1 Trouver tous les mots d'un texte

```
import re
texte = "Bonjour, je suis en L3 Génie Logiciel en 2024."
mots = re.findall(r"\w+", texte)
print(mots)
```

Résultat attendu : liste des mots sans ponctuation

1.2 Extraire les nombres

```
nombres = re.findall(r"\d+", texte)
print(nombres)    # ['3', '2024']
```

1.3 Trouver tous les mots qui commencent par une majuscule

```
maj = re.findall(r"\b[A-Z][a-zéèêîâù]+", texte)
print(maj)    # ['Bonjour', 'Génie', 'Logiciel']
```

Partie 2 : Remplacement et nettoyage

2.1 Supprimer tous les chiffres

```
nettoye = re.sub(r"\d+", "", texte)
print(nettoye)
```

2.2 Remplacer tous les espaces multiples par un seul

```
texte = "Bonjour      tout      le      monde !"
print(re.sub(r"\s+", " ", texte))
```

Partie 3 : Filtrage de lignes

3.1 Texte multiligne (MULTILINE)

```
log = """
2024-01-01: Connection établie
2024-01-02: ERREUR système
2024-01-03: OK
2024-01-04: ERREUR mémoire
"""
```

3.2 Trouver les lignes avec "ERREUR"

```
erreurs = re.findall(r"^.*ERREUR.*$", log, re.MULTILINE)
print(erreurs)
```

Partie 4 : Email et téléphone

4.1 Extraire tous les emails d'un texte

```
texte = "Contact : alice@example.com, bob@univ.fr"
emails = re.findall(r"[\w.-]+@[ \w.-]+\.\w+", texte)
print(emails)
```

4.2 Reconnaître un numéro FR

```
num = "Mon numéro est 0612345678 ou +33612345678."
nums = re.findall(r"(?:\+33|0)[1-9]\d{8}", num)
print(nums)
```

Partie 5 : Discussion

1. Que fait `re.findall()` vs `re.search()` ?
2. Que se passe-t-il si la regex ne matche rien ?
3. À quoi sert `re.MULTILINE` dans un texte à plusieurs lignes ?