

TP 2-0 : Initiation aux expressions régulières (Regex)

Objectifs

Ce TP vise à introduire les étudiants aux **expressions régulières** (regex), un outil fondamental pour l'analyse lexicale.

Les étudiants apprendront à :

- Lire et écrire des regex simples,
- Identifier des motifs (patterns) dans une chaîne,
- Utiliser le module `re` de Python pour appliquer des regex,
- Appliquer les regex à des cas concrets (identifiants, nombres, mots-clés).

Partie 1 – Découverte de la syntaxe

1.1 Table de base à retenir

Symbole	Signification	Exemple
<code>.</code>	n'importe quel caractère	<code>a.c</code> → abc, a+c
<code>*</code>	0 ou plusieurs	<code>ab*</code> → a, ab, abb
<code>+</code>	1 ou plusieurs	<code>ab+</code> → ab, abb
<code>?</code>	0 ou 1	<code>ab?</code> → a, ab
<code>[]</code>	ensemble de caractères	<code>[abc]</code> → a ou b ou c
<code>[^]</code>	exclusion	<code>[^a]</code> → tout sauf a
<code>\d</code>	chiffre	<code>\d+</code> → 123, 42
<code>\w</code>	mot (lettre ou chiffre)	<code>\w+</code> → abc123
<code>\s</code>	espace	<code>\s+</code> → " " ou "\t"

Partie 2 – Test interactif de regex simples

2.1 Objectif : utiliser des regex pour trouver des motifs dans une chaîne

Exemple de code Python

```
import re

pattern = r"[a-zA-Z_][a-zA-Z0-9_]*"
text = "int x = total123 + y_var;"
matches = re.findall(pattern, text)
```

```
print(matches)
```

Sortie : ['int', 'x', 'total123', 'y_var']

2.2 Exercices pratiques

1. Trouvez tous les **mots** dans la chaîne : "Bonjour le monde 123 !"
2. Trouvez tous les **nombres** dans : "Total = 45, taux = 3.14, bonus = 100"
3. Trouvez les identifiants valides dans : "int x1 = 5; float _result = 9;"
4. Trouvez les **symboles non alphanumériques** : () {} ; = + * /

Partie 3 – Construction de regex

3.1 Complétez les regex suivantes :

1. Nombres entiers positifs : _____
2. Identifiants valides (lettre/underscore suivi de lettres/chiffres) : _____
3. Mot-clé exact if : _____
4. Commentaires C sur une ligne (//...) : _____

3.2 Correction attendue :

1. [0-9]+
2. [a-zA-Z_][a-zA-Z0-9_]*
3. \bif\b
4. //.*

Partie 4 – Mini-projet d'extraction de motifs

Objectif : à partir d'un texte, extraire toutes les catégories suivantes :

- Tous les mots
- Tous les nombres
- Tous les opérateurs (+, -, *, /)
- Tous les identifiants

Exemple de code

```
text = "if (x1 > 0) { total_sum = total_sum + 1; }"
pattern_id = r"[a-zA-Z_][a-zA-Z0-9_]*"
pattern_op = r"[\+\-\*\/] "
print("Identifiants:", re.findall(pattern_id, text))
print("Opérateurs:", re.findall(pattern_op, text))
```