

Synthèse : Regex & Tokens – De la compilation à l'intelligence artificielle

1. Expressions régulières (Regex) – Fondamentaux

Les **regex** permettent de **décrire des motifs** dans du texte. Elles sont :

- le cœur de l'analyse lexicale dans les compilateurs,
- une **puissante technique de pattern matching**,
- utilisées dans presque tous les langages : Python, JavaScript, Java, C++, etc.

Des plateformes comme :

- regex101.com
- regexr.com
- pythex.org

...permettent de tester, comprendre et déboguer des expressions régulières en temps réel.

2. Tokens – Unité de base pour structurer le texte

Un **token** est une entité catégorisée extraite d'un texte par une regex :

Exemple de texte	Token extrait	Type
<code>int x = 5;</code>	<code>int</code> → KEYWORD	Lexical
	<code>x</code> → ID	Sémantique
	<code>5</code> → NUM	Lexical

Les tokens sont utilisés :

- dans les compilateurs,
- dans les moteurs de recherche,
- en **traitement automatique du langage naturel (TAL/NLP)**,
- en **prétraitement de données textuelles** pour des algorithmes d'intelligence artificielle.

3. Transition vers l'Intelligence Artificielle & NLP

Dans des domaines comme l'**analyse de sentiments**, la **classification de texte**, la **détection de spam** ou les **modèles de langage**, les regex et les tokens sont utilisés pour :

Nettoyer les données (préprocessing) :

- Supprimer les balises HTML : <[^>]+>
- Retirer les emojis ou caractères spéciaux
- Extraire les dates, e-mails, URLs, hashtags, etc.

Tokeniser un texte :

```
text = "Python est génial !"
tokens = re.findall(r'\w+', text.lower()) # ['python', 'est', 'génial']
```

Créer des vecteurs à partir des tokens :

- TF-IDF
- Word2Vec
- BERT embeddings
- etc.

Exemples concrets :

- En NLP : transformer `input text` → `tokens` → `vecteurs` → `modèle`
- En classification : spam/ham, émotions, types de documents
- En IA conversationnelle : extraction d'intention, d'entités (NER)

Conclusion – Vers un usage intelligent

Regex et Tokens ne sont pas uniquement des outils “de bas niveau” :

Ils sont les fondations du traitement du langage naturel moderne.

La capacité à manipuler efficacement les tokens avec des regex est donc essentielle pour :

- Préparer les données d'un modèle d'IA
- Filtrer l'information utile
- Structurer le contenu non structuré
- Et même **augmenter la précision** d'un modèle grâce à un bon prétraitement