

Distance Euclidienne vs Distance de Manhattan : Différences et Applications

Dr. Clotilde Djuikem

Contexte

En analyse de données et en apprentissage automatique, la manière de mesurer les distances impacte directement les performances des algorithmes. Deux mesures couramment utilisées sont la distance Euclidienne et la distance de Manhattan.

Question : Quelles sont leurs différences, leurs définitions mathématiques et leurs implications dans l'analyse de données ?

Définition : C'est la distance en ligne droite entre deux points dans un espace multidimensionnel.

$$d_E(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (1)$$

Caractéristiques :

- Sensible aux valeurs extrêmes et aux changements d'échelle.
- Adaptée aux données continues et normalement distribuées.
- Utilisée dans des algorithmes comme K-Means, KNN, PCA.

Exemple de la Distance Euclidienne

Données :

Point	X	Y
A	1	2
B	4	6

Calcul :

$$d_E(A, B) = \sqrt{(4 - 1)^2 + (6 - 2)^2} = \sqrt{9 + 16} = 5$$

Interprétation : La distance minimale entre A et B est de 5 unités.

Définition : Mesure la distance en suivant uniquement les axes du plan, comme un déplacement en grille.

$$d_M(x, y) = \sum_{i=1}^n |x_i - y_i| \quad (2)$$

Caractéristiques :

- Moins sensible aux valeurs extrêmes.
- Plus adaptée aux données ordinales ou catégorielles.
- Utilisée dans des modèles de clustering basés sur la densité.

Exemple de la Distance de Manhattan

Données :

Point	X	Y
A	1	2
B	4	6

Calcul :

$$d_M(A, B) = |4 - 1| + |6 - 2| = 3 + 4 = 7$$

Interprétation : Contrairement à la distance euclidienne, la distance de Manhattan suit un chemin en ligne brisée.


Conséquences sur un jeu de données :

- **Distance Euclidienne** favorise les clusters sphériques et est sensible aux variations d'échelle.
- **Distance de Manhattan** fonctionne mieux lorsque les variables ont des unités différentes ou sont hétérogènes.
- **Effet sur les algorithmes** : En K-Means, la distance Euclidienne est privilégiée. En clustering basé sur la densité, la distance de Manhattan est souvent plus pertinente.

Comparaison des Deux Distances

Critère	Euclidienne	Manhattan
Formule	$\sqrt{\sum_i (x_i - y_i)^2}$	$\sum_{i=1}^n x_i - y_i $
Sensibilité aux extrêmes	Forte	Faible
Données adaptées	Continues et normalement distribuées	Ordinales ou catégorielles
Applications	K-Means, PCA	Clustering basé sur la densité

Comparaison en Graphe



Résumé :

- **Euclidienne** : Recommandée pour des données continues et bien distribuées, mais sensible aux outliers.
- **Manhattan** : Meilleure robustesse aux valeurs extrêmes, adaptée aux données où les dimensions sont hétérogènes.
- **Choix optimal** : dépend du type de données et de l'algorithme utilisé.

Conclusion

Envie d'en apprendre plus ?

Suivez **Clotilde Djuikem** sur LinkedIn et **Tioh Academy** sur YouTube !