

Apprentissage non-supervisé

Thanh-Nghi Do
Université de Can Tho
dtngchi@cit.ctu.edu.vn

Hanoi
Oct. 2015


Plan

- Introduction
- Clustering hiérarchique
- k -moyennes

Plan

- **Introduction**
- Clustering hiérarchique
- k -moyennes

Méthodes de fouille de données (Kdnuggets, 2003)




Méthodes de fouille de données (Kdnuggets, 2004)

KDnuggets : Polls : Deployed data mining techniques

Poll

Which data mining techniques you used in a successfully deployed application?
[173 voters, 509 votes total]




Méthodes de fouille de données (Kdnuggets, 2005)

[KDnuggets](#) : [Polls](#) : Data Mining Techniques (Feb 2005)

Poll

Data mining/analytic techniques you use frequently: [784 votes total]




Méthodes de fouille de données (Kdnuggets, 2006)

KDnuggets : Polls : Data Mining Methods (Apr 2006)

Poll


Data mining/ analytic methods you used frequently in the last year: [176 voters]



Méthodes de fouille de données (Kdnuggets, 2007)


KDnuggets : Polls : Data Mining Methods (Mar 2007)

Poll
Data mining/analytic methods you used frequently in the past 12 months: [203 voters]



Succès des méthodes (Kdnuggets)

KDnuggets : **Polls** : Deployed data mining techniques



Introduction

- Apprentissage non-supervisé (clustering)
 - Recherche de structures naturelles dans les données (pas de cible ou classe)
 - Construire des clusters (groupes) automatiquement en fonction des individus disponibles (ensemble d'apprentissage)
 - Cluster (groupe): les individus dans un groupe sont aussi similaires que possible (homogène), les individus de différents groupes sont aussi différents que possible (séparé)
 - Famille de méthodes: clustering hiérarchique, partitionnement, densité
 - Méthodes très utilisées: k -moyennes, Dendrogram, SOM, EM

Introduction

- Apprentissage non-supervisé (clustering)
 - Cherche à maximiser la similarité intra-cluster et à minimiser la similarité inter-cluster
 - Critère de similarité: fonction de distance
 - Notion de similarité est fonction du type des données: numérique, binaire, nominale
 - Type numérique: distance de *Minkowski*, *Manhattan*, *euclidienne*

Plan


- Introduction
- **Clustering hiérarchique**
- k -moyennes

Clustering hiérarchique

- Bottom up (approche ascendente)
 - Commence avec un individu dans chaque cluster
 - Fusionne successivement les 2 clusters les plus proches
 - S'arrête quand il n'y a plus qu'un cluster contenant tous les individus
- Top down (approche descendente)
 - Tous les individus sont initialement dans le même cluster
 - Puis division du cluster en sous-clusters jusqu'à ce qu'il y ait suffisamment de niveaux ou que les clusters ne contiennent plus qu'un seul individu

- Introduction
- Clustering hiérarchique
- *k*-moyennes

Clustering hiérarchique



Clustering hiérarchique

- Distance entre les clusters
 - Lien simple: distance des deux individus les plus proches des clusters
 - Lien complet: distance des deux individus les plus éloignés dans les deux clusters
 - Lien des moyennes: distance entre deux individus est donnée par la distance des centres

- Introduction
- Clustering hiérarchique
- k -moyennes

Clustering hiérarchique (lien simple)



- Introduction
- Clustering hiérarchique
- k -moyennes

Clustering hiérarchique (lien simple)



- Introduction
- **Clustering hiérarchique**
- k -moyennes

Clustering hiérarchique (lien simple)




- Introduction
- Clustering hiérarchique
- k -moyennes

Clustering hiérarchique (lien simple)




- Introduction
- **Clustering hiérarchique**
- k -moyennes

Clustering hiérarchique (lien simple)




- Introduction
- **Clustering hiérarchique**
- *k*-moyennes

Clustering hiérarchique (lien simple)




- Introduction
- **Clustering hiérarchique**
- k -moyennes

Clustering hiérarchique (lien simple)




- Introduction
- **Clustering hiérarchique**
- k -moyennes

Clustering hiérarchique (lien simple)




- Introduction
- **Clustering hiérarchique**
- *k*-moyennes

Clustering hiérarchique (lien simple)




- Introduction
- **Clustering hiérarchique**
- *k*-moyennes

Clustering hiérarchique (lien simple)




- Introduction
- Clustering hiérarchique
- k -moyennes

Clustering hiérarchique (lien simple)



- Introduction
- Clustering hiérarchique
- k -moyennes

Clustering hiérarchique (lien simple)



Clustering hiérarchique (lien simple)

- Commentaires
 - Simple, compréhensible, non-paramétrique
 - Résultat: dendrogramme (arbre de cluster)
 - Complexité: très coûteuse
 - BIRCH (Zhang et al., 1996) utilise la méthodes d'accès rapides nécessaires

Plan

- Introduction
- Clustering hiérarchique
- ***k*-moyennes**

k-moyennes

- Principe
 - Partitionner un ensemble d'individus en k clusters
 - Un cluster est représenté par son centre de gravité
 - Un individu appartient au cluster dont le centre de gravité lui est le plus proche


k -moyennes

■ Algorithme

1. Fixer le nombre de clusters a priori: k
2. Initialiser aléatoirement k centres (k individus tirés au hasard comme représentants des clusters)
3. Affecter chaque individu au cluster qui minimise la distance entre le centre et l'individu (centre le plus proche)
4. Recalculer les nouveaux centres (la moyenne)
5. Itérer l'opération jusqu'à la stabilité

k -moyennes


- Introduction
- Clustering hiérarchique
- k -moyennes



- Introduction
- Clustering hiérarchique
- k -moyennes

k -moyennes


Choix des 3
centres
initiaux
au hasard



k -moyennes

- Introduction
- Clustering hiérarchique
- k -moyennes


affecter
chaque
individu au
cluster le plus
proche



k -moyennes

- Introduction
- Clustering hiérarchique
- k -moyennes


recalcul des 3
centres



k -moyennes

- Introduction
- Clustering hiérarchique
- k -moyennes


affecter
chaque
individu au
cluster le plus
proche



- Introduction
- Clustering hiérarchique
- k -moyennes


k -moyennes

recalcul des 3
centres



k -moyennes

- Introduction
- Clustering hiérarchique
- k -moyennes



k -moyennes

- Commentaires
 - Simple, compréhensible
 - Paramètre k (le nombre de clusters a priori)
 - Sensibilité aux conditions d'initialisation (on n'obtiendra pas forcément les mêmes clusters avec des partitionnements initiaux différents)
 - Sensible au bruit et aux anomalies
 - Ne permet pas de définir des clusters aux formes non convexes

k-moyennes: variantes

- *k*-medoids
 - Même principe que les *k*-moyennes, il utilise à la place de la moyenne le medoid
 - Medoid: individu le plus central dans le cluster
 - Moins sensible au bruit et aux individus isolés
- *k*-moyennes floues
 - Recouvrement possible des clusters
- Clustering à base de modèle: les mixtures de gaussiennes
 - *k* est le nombre de composantes de la mixture
 - Algorithme EM: un individu est affecté à un cluster selon un poids qui représente sa probabilité d'appartenance au cluster
 - Autorise des formes plus flexibles pour les clusters



Merci !