

10 Notions d'Optimisation Mathématiques en IA, LLM et Data Science

Dr. Clotilde Djuikem

21. Descente de Gradient

Formule :

$$\theta_{t+1} = \theta_t - \eta \nabla J(\theta_t)$$

où θ_t représente les paramètres du modèle à l'itération t , η est le taux d'apprentissage et $\nabla J(\theta_t)$ est le gradient de la fonction de coût.

Applications

- Apprentissage des réseaux neuronaux.
- Optimisation des paramètres en machine learning.
- Ajustement des coefficients en régression.

22. Descente de Gradient Stochastique (SGD)

Formule :

$$\theta_{t+1} = \theta_t - \eta \nabla J_i(\theta_t)$$

où $\nabla J_i(\theta_t)$ est le gradient calculé sur un échantillon unique de données.

Applications

- Optimisation des modèles en mini-batches.
- Réduction du coût de calcul en deep learning.
- Accélération de l'apprentissage des grands modèles.

23. Algorithme d'Adam

Formules :

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

où m_t et v_t sont les moyennes mobiles des gradients et β_1, β_2 sont des coefficients d'atténuation.

Applications

- Accélération de la convergence en deep learning.
- Optimisation des modèles complexes.
- Stabilisation de l'entraînement des réseaux neuronaux profonds.

Formule :

$$x_{t+1} = x_t - H^{-1} \nabla f(x_t)$$

où H est la matrice hessienne de la fonction $f(x)$.

Applications

- Optimisation des fonctions convexes.
- Calcul des points critiques en optimisation.
- Convergence rapide pour les fonctions bien conditionnées.

25. Méthode de Lagrange

Formule :

$$\mathcal{L}(x, \lambda) = f(x) + \lambda g(x)$$

où λ est un multiplicateur de Lagrange, utilisé pour prendre en compte la contrainte $g(x) = 0$.

Applications

- Régularisation des réseaux de neurones.
- Optimisation sous contrainte en IA.
- Calcul des optima en économie et en physique.

Définition : Ensemble de variables liées par des contraintes formalisées mathématiquement.

Applications

- Résolution de problèmes d'optimisation sous contrainte.
- Planification et allocation de ressources.
- Intelligence artificielle et systèmes experts.

27. Relaxation Convexe

Principe : Transformation d'un problème d'optimisation combinatoire en un problème convexe plus facile à résoudre.

Applications

- Formulation de problèmes complexes en optimisation.
- Approximations en machine learning.
- Simplification des problèmes NP-difficiles.

Formule Générale :

$$\max_x \quad c^T x \quad \text{sous contraintes} \quad Ax \leq b$$

où c est le vecteur de coefficients, x les variables à optimiser, et A, b définissent les contraintes.

Applications

- Allocation des ressources en apprentissage.
- Optimisation des chaînes logistiques et industrielles.
- Planification des tâches et gestion de production.

29. Régularisation L1 et L2

Formules :

$$\text{L1: } \lambda \sum |w_i|, \quad \text{L2: } \lambda \sum w_i^2$$

où λ est un coefficient de régularisation et w_i les poids du modèle.

Applications

- Réduction du surajustement (overfitting).
- Sélection de variables en machine learning.
- Amélioration de la généralisation des modèles.

Exemple : Problème du Voyageur de Commerce (TSP)

$$\min \sum d(i, j) x_{ij}$$

où $x_{ij} = 1$ si la ville i est visitée avant la ville j , et $d(i, j)$ est la distance entre elles.

Applications

- Recherche de chemins optimaux en graphes.
- Planification de tournées et logistique.
- Séquençage génétique et réseaux de transport.

Conclusion

Les méthodes d'optimisation sont essentielles pour améliorer l'efficacité et la performance des modèles d'IA, de machine learning et de data science. Elles permettent d'ajuster les paramètres, d'accélérer la convergence et d'assurer la robustesse des solutions aux problèmes complexes.

Envie d'en apprendre plus ?

Suivez **Clotilde Djuikem** sur LinkedIn et **Tioh Academy** sur YouTube pour découvrir plus de contenus sur l'IA, les mathématiques et l'optimisation !