

Travaux pratiques en binôme

k plus proches voisins

1) Soit la base d'individus:

X1	X2	Classe
0.376000	0.488000	0
0.312000	0.544000	0
0.298000	0.624000	0
0.394000	0.600000	0
0.506000	0.512000	0
0.488000	0.334000	1
0.478000	0.398000	1
0.606000	0.366000	1
0.428000	0.294000	1
0.542000	0.252000	1

**Manuellement
Distance L1**

- Utiliser 1NN, 3NN pour classier les individus suivants:

X1	X2	Classe
0.550000	0.364000	?
0.558000	0.470000	?
0.456000	0.450000	?
0.450000	0.570000	?

2) Ecrire un programme en C/C++ (ou Matlab/Octave/R/Python/Java) prend les paramètres en entrée

- nom fichier de la base d'apprentissage
- nom fichier de la base de test
- k (le nombre de plus proches voisins)

Programmer

Le format des bases de m individus en n dimensions et c classes ($0, 1, \dots, c-1$) est:

```
val_i1_a1 val_i1_a2 ... val_i1_an classe_i1
val_i2_a1 val_i2_a2 ... val_i2_an classe_i2
...
val_im_a1 val_im_a2 ... val_im_an classe_im
```

Le programme classifie les individus dans la base de test à l'aide de l'algorithme k plus proches voisins. En sortie, le programme fournit le résultat sous la matrice de confusion et le taux de bon classement.

- Utiliser le programme pour classier les ensembles de données:

- Iris (**.trn** pour l'apprentissage, **.tst** pour le test)
- Optics (**.trn** pour l'apprentissage, **.tst** pour le test)
- Letter (**.trn** pour l'apprentissage, **.tst** pour le test)
- Fp (**hold-out**)

- Essayer de changer le paramètre k pour obtenir les meilleurs résultats
- Faire les commentaires sur les résultats
- Proposer l'amélioration du programme

3) Démonstration du théorème:

Pour un suffisamment grand ensemble d'apprentissage de taille m , le taux d'erreur de $1NN$ est inférieure à deux fois le taux d'erreur minimal obtenu par la classification bayésienne.

Arbres de décision

1) Soit l'ensemble d'apprentissage correspondant à un ensemble de conditions météorologiques qui permettent (Play pour Positif) ou pas (Don't Play pour Négatif) la pratique du Golf

Outlook	Temperature	Humidity	Windy	Class
sunny	85	85	false	Don't Play
sunny	80	90	true	Don't Play
overcast	83	78	false	Play
rain	70	96	false	Play
rain	68	80	false	Play
rain	65	70	true	Don't Play
overcast	64	65	true	Play
sunny	72	95	false	Don't Play
sunny	69	70	false	Play
rain	75	80	false	Play
sunny	75	70	true	Play
overcast	72	90	true	Play
overcast	81	75	false	Play
rain	71	80	true	Don't Play

- Construire l'arbre de décision à partir de cet ensemble d'apprentissage au-dessus qui permet de prédire la pratique du Golf. La fonction de split se base sur l'entropie de Shannon

- Extraire des règles inductives (si ... alors) à partir de l'arbre obtenu.

Manuellement

- Classifier les individus suivants:

Outlook	Temperature	Humidity	Windy	Class
overcast	63	70	false	?
rain	73	90	true	?
sunny	70	73	true	?

2) Expliquer pourquoi l'ensemble d'arbres de décision améliore la prédiction d'un seul ?

3) Démontrer que le bagging de k plus proches voisins n'améliore pas le comportement d'un seul.
