

Master 1 Informatique

Analyse de données

TP – Clustering et segmentation

Objectifs

Ce TP vise à :

- appliquer l'algorithme K-means
- comprendre l'effet de la standardisation
- choisir le nombre de clusters
- analyser la qualité d'un clustering
- comparer plusieurs méthodes de clustering

1 Jeu de données

Nous utilisons le jeu de données **Iris**, déjà dans R, contenant :

- longueur des sépales
- largeur des sépales
- longueur des pétales
- largeur des pétales

2 Partie 1 : Exploration des données

1. Charger le jeu de données.
2. Examiner les statistiques descriptives.
3. Visualiser les relations entre variables.

3 Partie 2 : Prétraitement

1. Pourquoi la standardisation est-elle nécessaire pour le clustering ?
2. Standardiser les variables numériques.

4 Partie 3 : Clustering K-means

1. Appliquer K-means avec $K = 3$.
2. Visualiser les clusters.
3. Interpréter les centres des clusters.

5 Partie 4 : Choix du nombre de clusters

1. Calculer l'inertie intra-cluster pour $K = 1, \dots, 10$.
2. Tracer la courbe de la méthode du coude.
3. Déterminer le nombre de clusters pertinent.

6 Partie 5 : Validation par la silhouette

1. Calculer le coefficient de silhouette.
2. Interpréter la qualité du clustering.

7 Partie 6 : Clustering hiérarchique

1. Construire le dendrogramme.
2. Découper l'arbre en trois clusters.
3. Comparer avec K-means.

8 Travail demandé

Rédiger un rapport contenant :

- description des données

- résultats des différentes méthodes
- choix du nombre de clusters
- interprétation des clusters
- discussion des limites